La hipótesis de *representaciones lineales*

Qué cosas se representan linealmente en los espacios semánticos, y qué cosas aparentemente no

Itinerario

1. Evidencia de representaciones lineales
2. Formalización y producto causal
3. Representaciones no lineales
4. Representaciones cognitivamente interesantes

Itinerario

1. **Evidencia de representaciones lineales**
2. Formalización y producto causal
3. Representaciones no lineales
4. Representaciones cognitivamente interesantes

Proyecciones y dimensiones interpretables

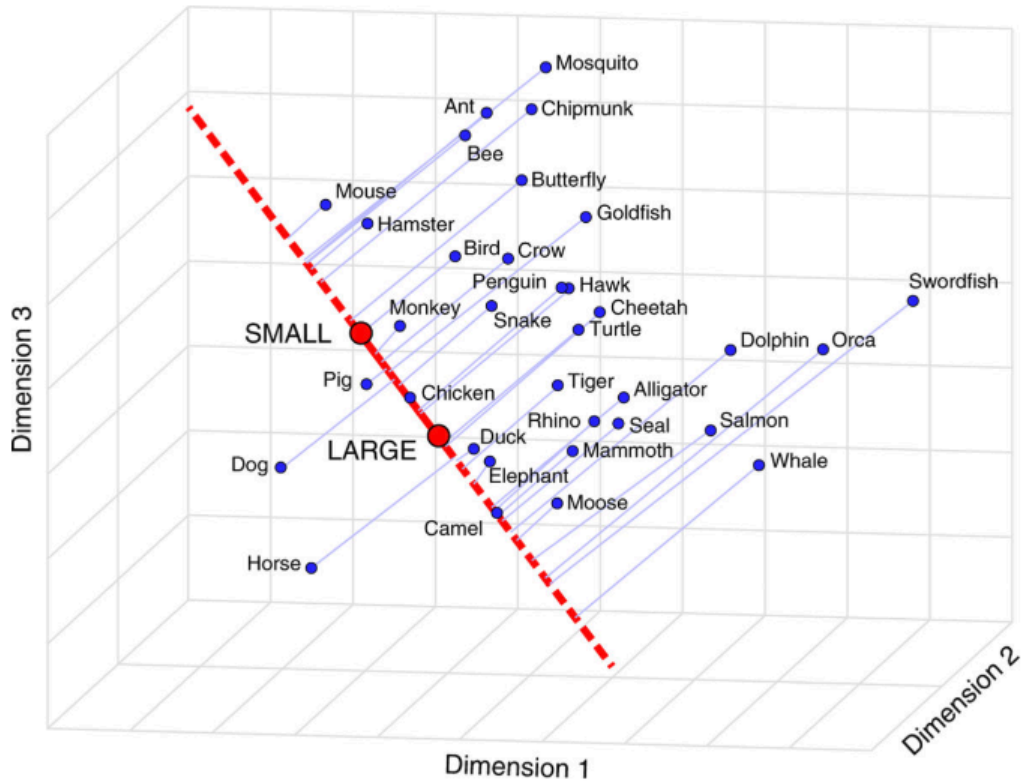
nature human behaviour

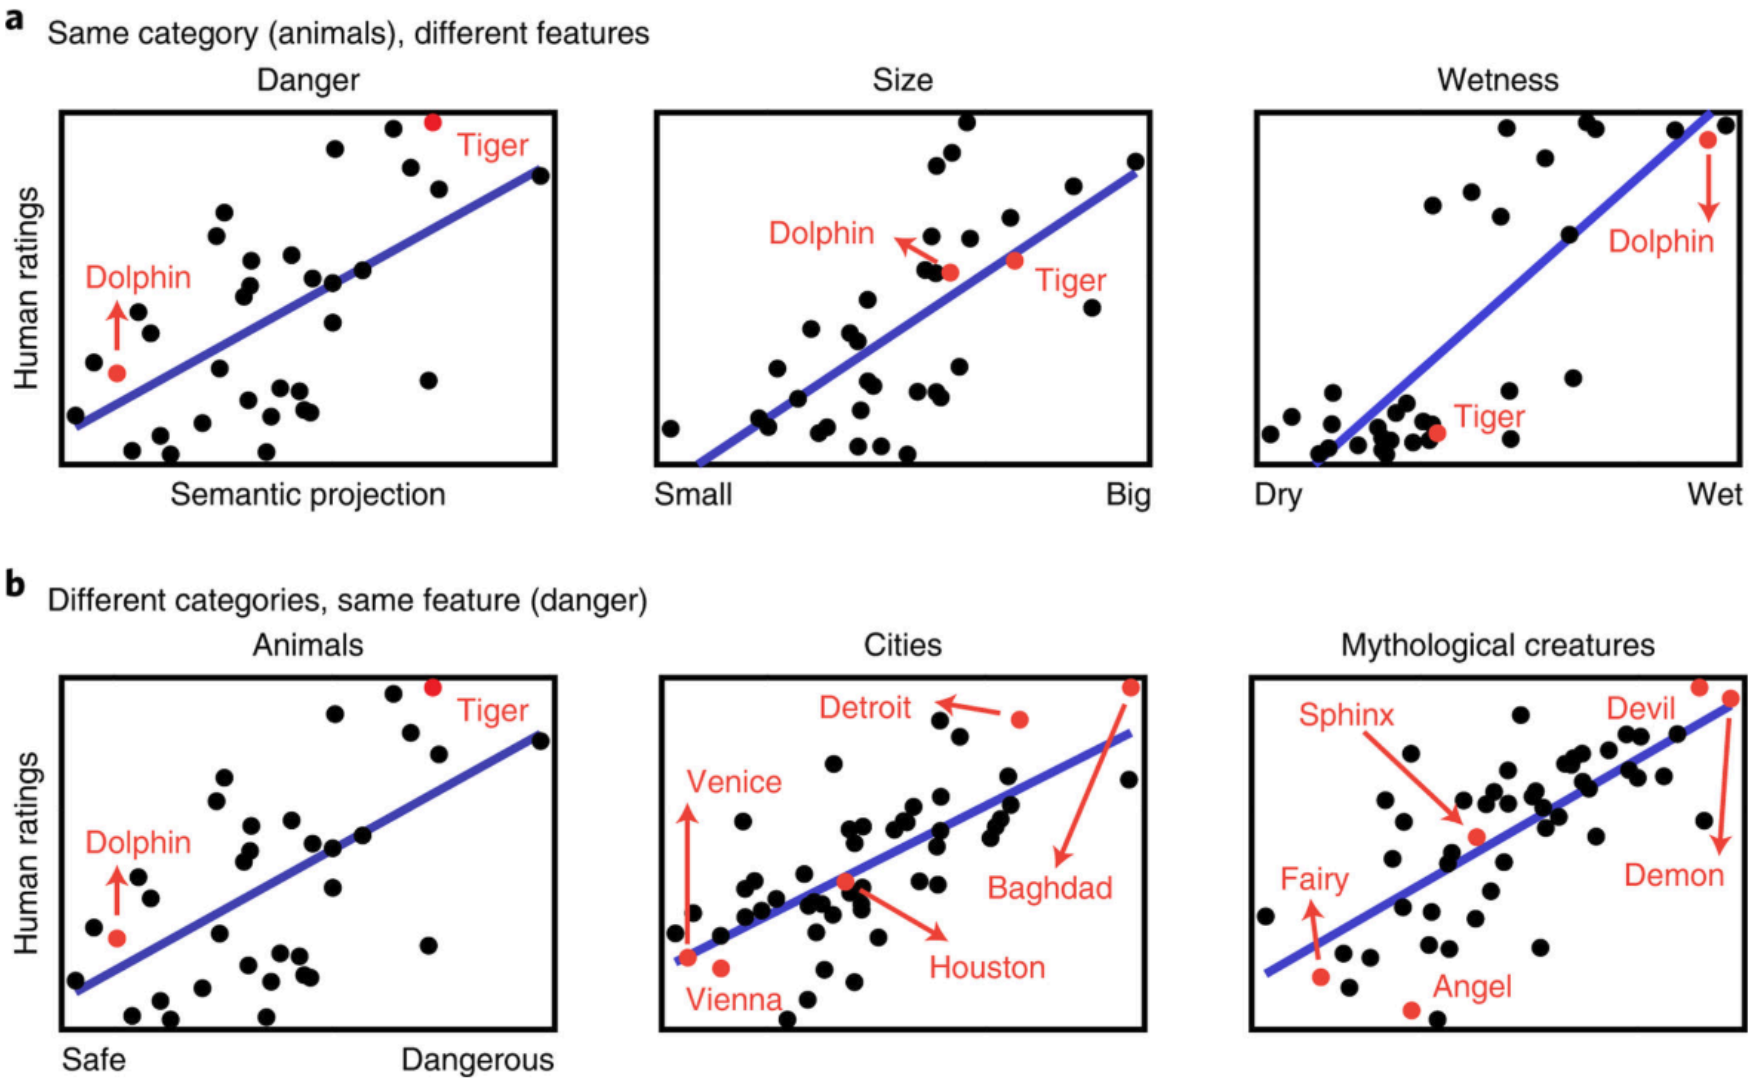
Article | Published: 14 April 2022

Semantic projection recovers rich human knowledge of multiple object features from word embeddings

Gabriel Grand, Idan Asher Blank, Francisco Pereira & Evelina Fedorenko

Proyectar palabras en ejes definidos por extremos



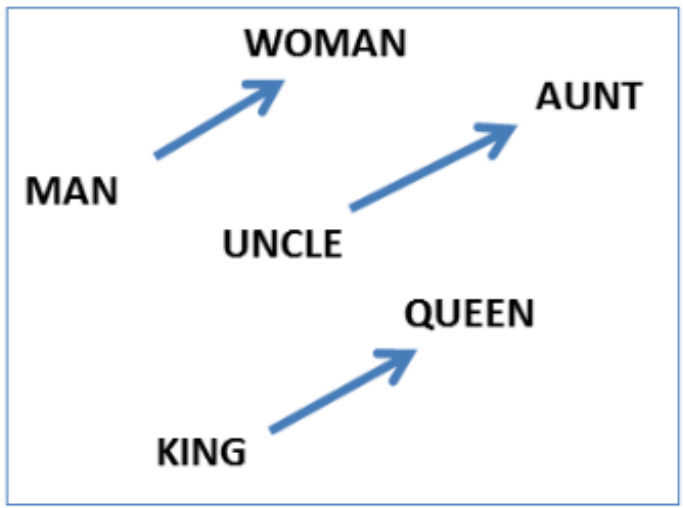

a
Same category (animals), different features
Danger
Size
Wetness
Human ratings
Tiger
Dolphin
Semantic projection
Small
Big
Dry
Wet
b
Different categories, same feature (danger)
Animals
Cities
Mythological creatures
Safe
Dangerous
Detroit
Venice
Baghdad
Houston
Vienna
Sphinx
Devil
Fairy
Demon
Angel

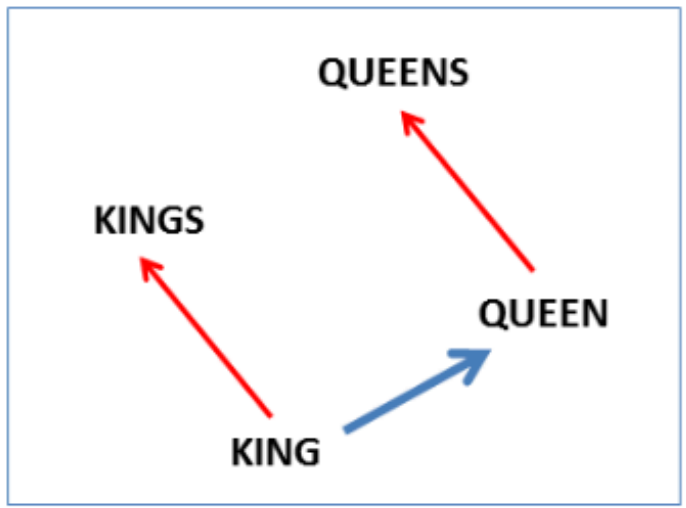
Analogías

Hombre es a Rey como Mujer es a ?

Las analogías pueden representarse como un paralelogramo

Reina es rey - hombre + mujer





Tomado del paper original de Word2Vec: Mikolov et al (2013)

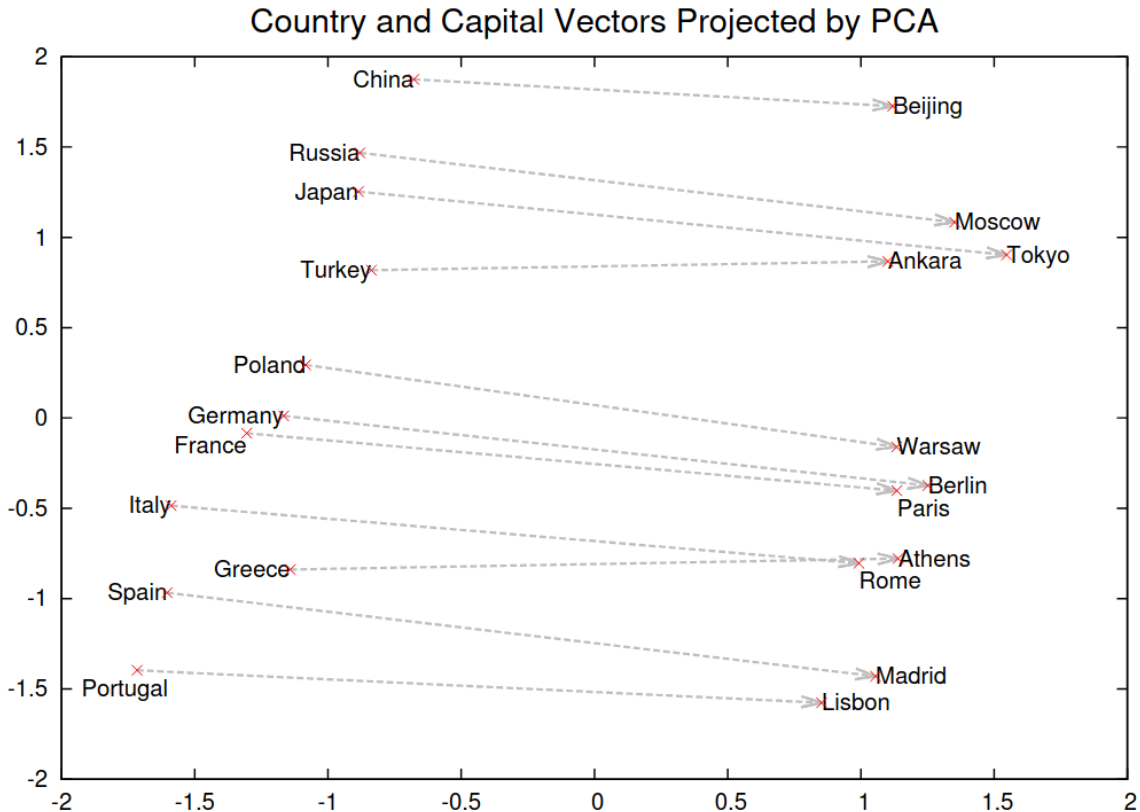


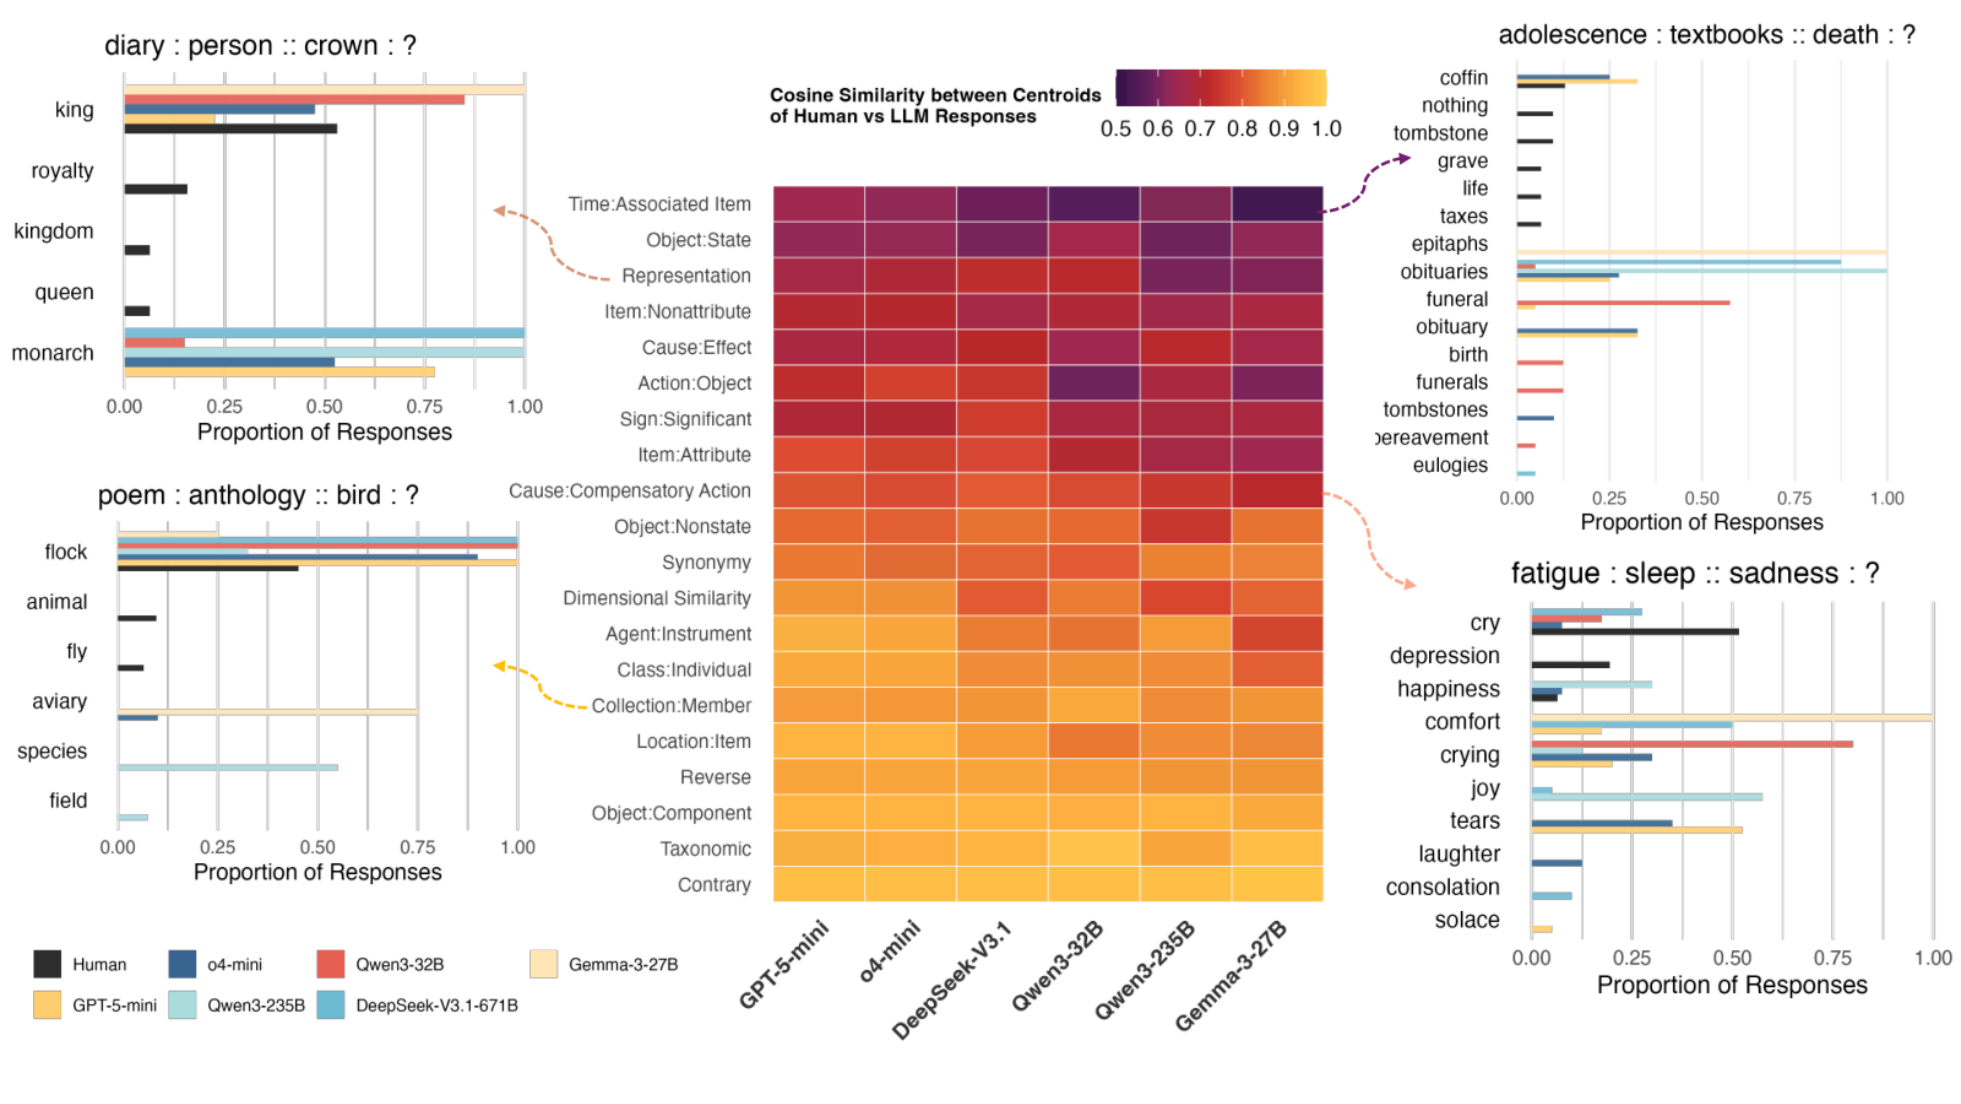
Figure 2: Two-dimensional PCA projection of the 1000-dimensional Skip-gram vectors of countries and their capital cities. The figure illustrates ability of the model to automatically organize concepts and learn implicitly the relationships between them, as during the training we did not provide any supervised information about what a capital city means.

Los paralelogramos atacan de nuevo

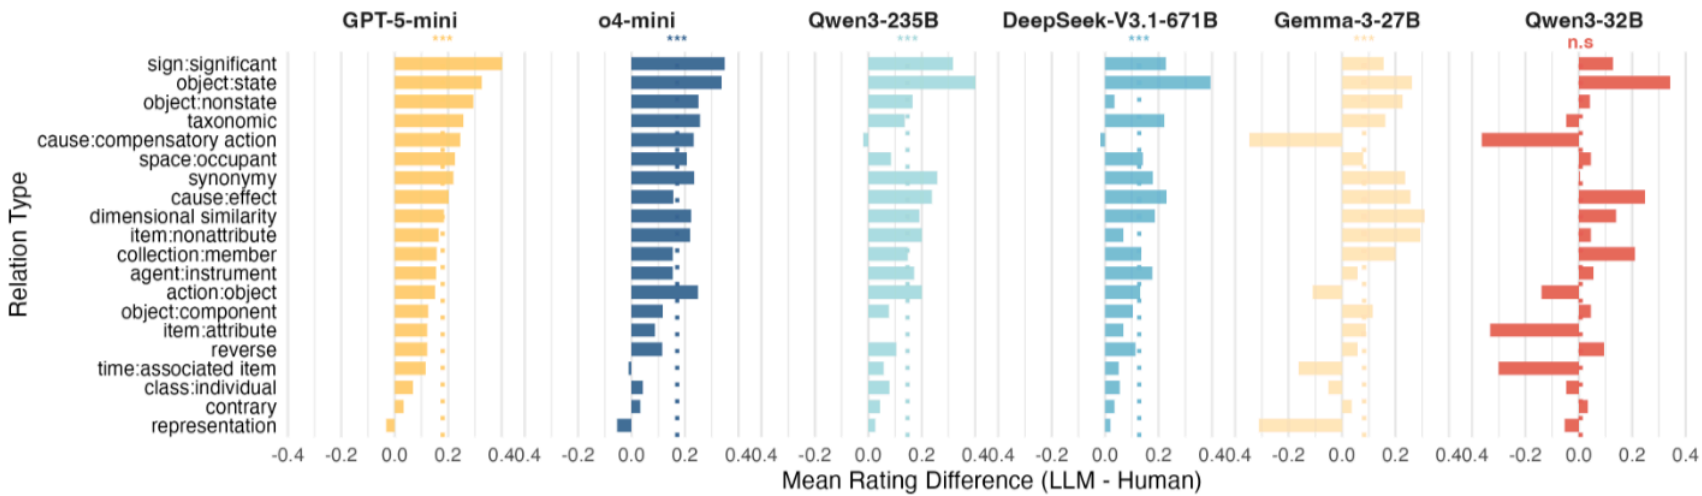
Large Language Models provide support for the parallelogram theory of analogy

Qiawen Ella Liu[1], Raja Marjieh[1], Jian-Qiao Zhu[1,2], Adele E. Goldberg[1], and Thomas L. Griffiths[1]
[1]Princeton University
[2]The University of Hong Kong

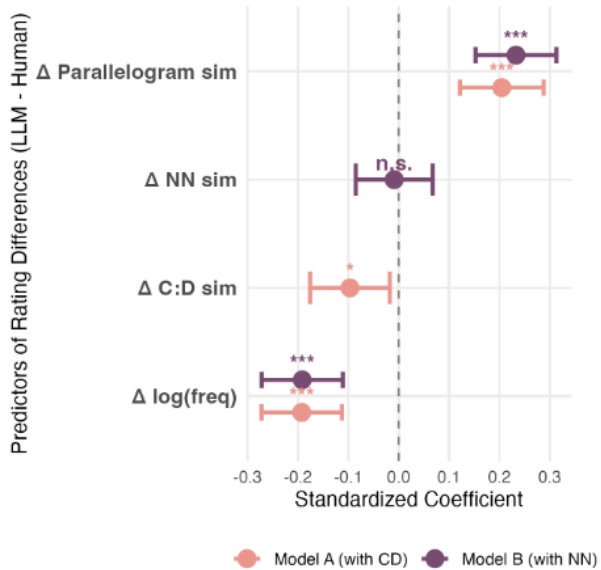
{ "Este artículo antes se llamaba": "Parallelograms Strike Back: LLMs Generate Better Analogies than People" }


diary : person :: crown : ?
king
royalty
kingdom
queen
monarch
0.00
0.25
0.50
0.75
1.00
Proportion of Responses
poem : anthology :: bird : ?
flock
animal
fly
aviary
species
field
0.00
0.25
0.50
0.75
1.00
Proportion of Responses
Cosine Similarity between Centroids of Human vs LLM Responses
0.5 0.6 0.7 0.8 0.9 1.0
Time:Associated Item
Object:State
Representation
Item:Nonattribute
Cause:Effect
Action:Object
Sign:Significant
Item:Attribute
Cause:Compensatory Action
Object:Nonstate
Synonymy
Dimensional Similarity
Agent:Instrument
Class:Individual
Collection:Member
Location:Item
Reverse
Object:Component
Taxonomic
Contrary
GPT-5-mini
o4-mini
DeepSeek-V3.1
Qwen3-32B
Qwen3-235B
Gemma-3-27B
adolescence : textbooks :: death : ?
coffin
nothing
tombstone
grave
life
taxes
epitaphs
obituaries
funeral
obituary
birth
funerals
tombstones
bereavement
eulogies
0.00
0.25
0.50
0.75
1.00
Proportion of Responses
fatigue : sleep :: sadness : ?
cry
depression
happiness
comfort
crying
joy
tears
laughter
consolation
solace
0.00
0.25
0.50
0.75
1.00
Proportion of Responses
Human
o4-mini
Qwen3-32B
Gemma-3-27B
GPT-5-mini
Qwen3-235B
DeepSeek-V3.1-671B

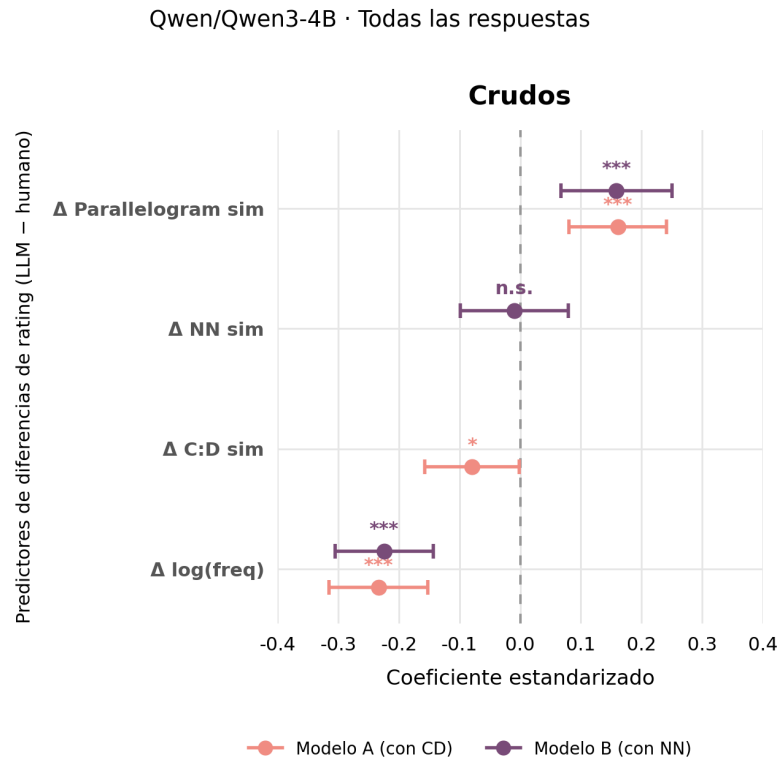
Los LLMs producen *mejores* analogías que los humanos



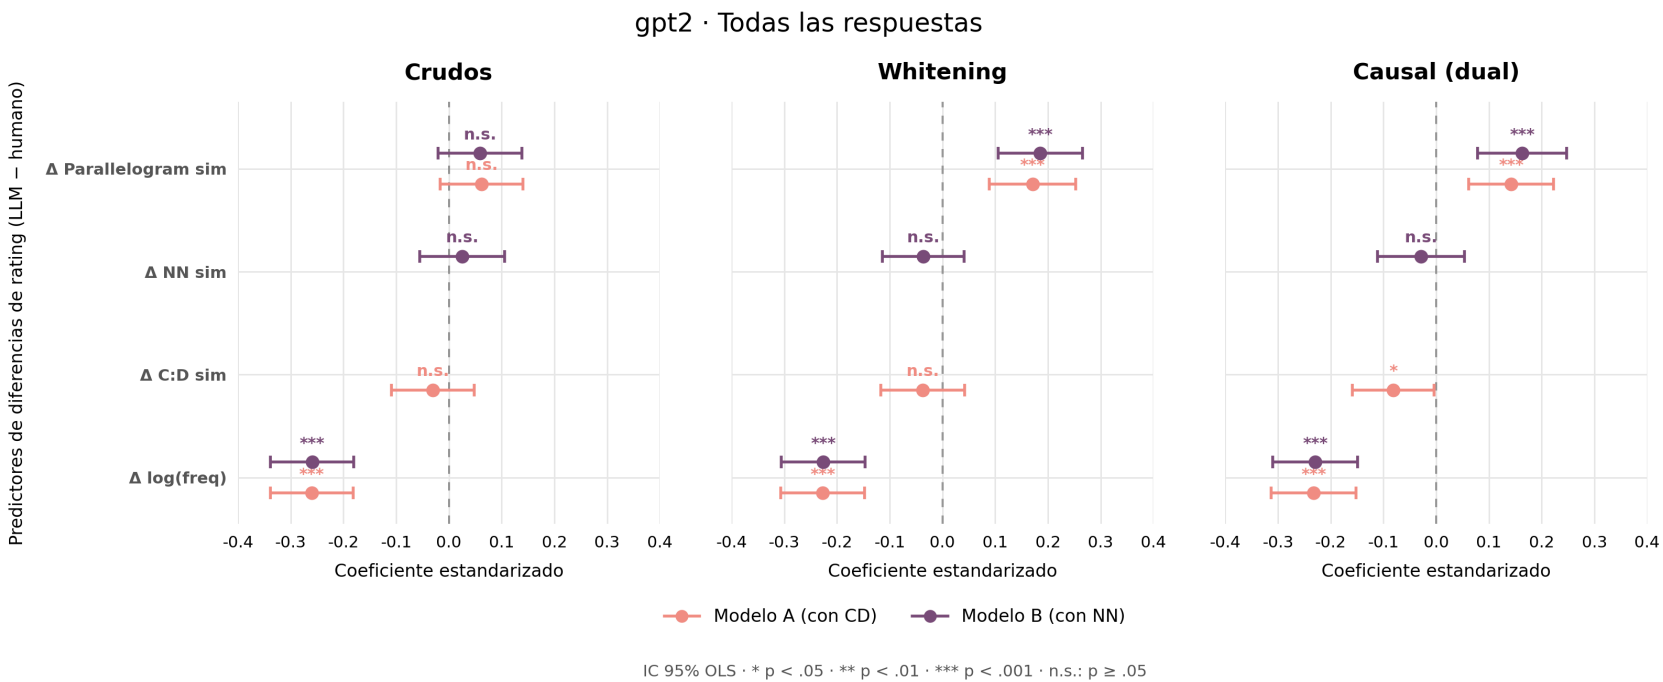
Qué predice la predilección a las respuestas de LLMS?



Una mayor alineación con el "paralelogramo", y una menor frecuencia



En el paper original usan embeddings de GloVE, no del modelo. Pero en Qwen3-4B (última capa) sucede lo mismo que en GloVE.



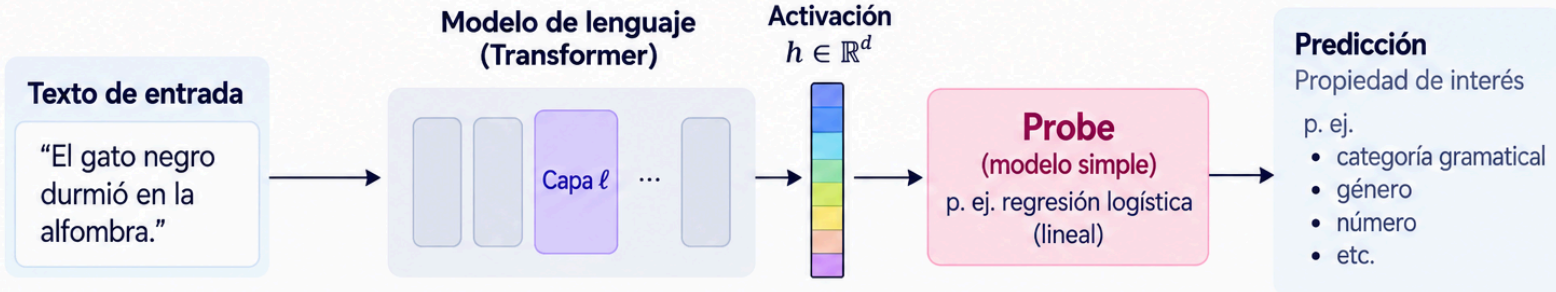
En el paper original usan embeddings de GloVE, no del modelo. Pero en Qwen3-4B (última capa) sucede lo mismo que en GloVE.

Qué es una representación *lineal*?

1. **Subespacio** Cada concepto es un subespacio de dim 1
   - *Hombre/Mujer* es una direccino′en el espacio (Mikolov)
2. **Medida** La probabilidad de un valor conceptual se puede *medir*
   - *Probing* lineal
3. **Inrevención** Cambiar el comportamiento del modelo mediante
   - *Steering* lineal en las activaciones

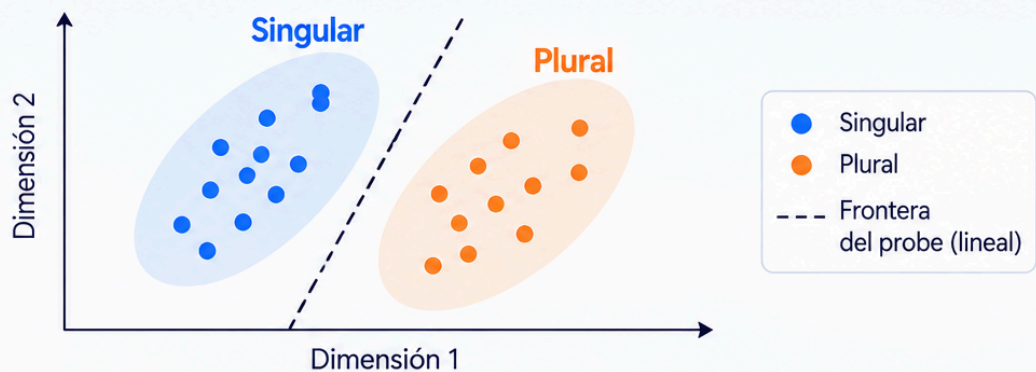
Probing: leer información en las activaciones

Se entrena un modelo simple (probe) para predecir una propiedad de interés a partir de las activaciones internas de un modelo de lenguaje.



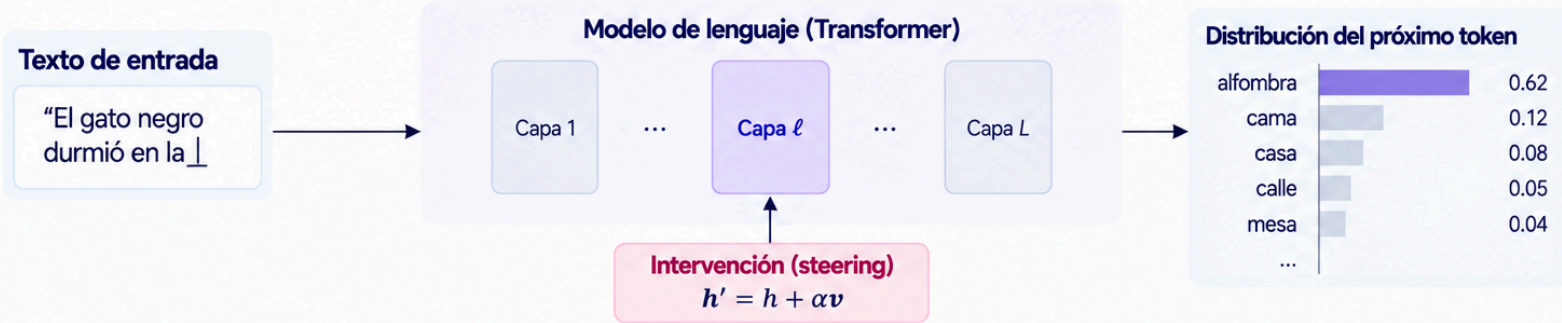
1 ¿Qué hace un probe?

Aprende una frontera de decisión simple en el espacio de activaciones para predecir la propiedad de interés.



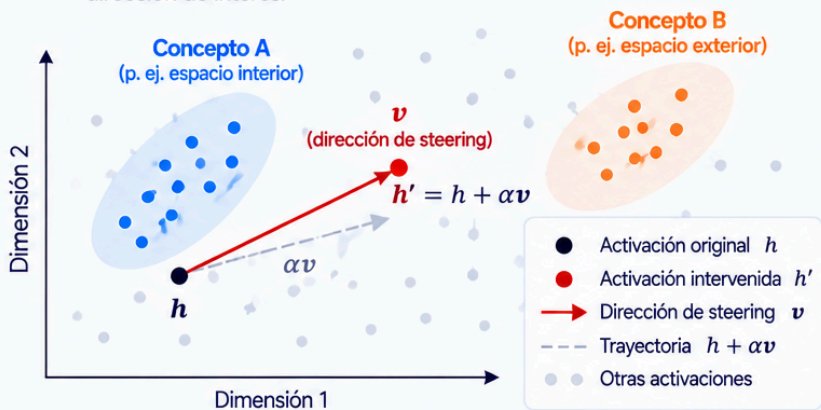
Steering: controlar el comportamiento mediante intervenciones

Se modifica la activación de una capa en una dirección específica para influir en la salida del modelo.



1 Dirección de steering en el espacio de activaciones

Se suma un vector v a la activación h de una capa, escalado por un factor α, para mover la representación en una dirección de interés.



2 Efecto en la distribución de salida

La intervención en la capa puede aumentar la probabilidad de ciertos tokens y disminuir la de otros.

Sin intervención (h)

Token	Logit	Prob.
alfombra	2.8	0.62
cama	1.1	0.12
casa	0.7	0.08
calle	0.2	0.05
mesa	0.0	0.04
...	...	...

Con steering ($h' = h + \alpha v$)

Token	Logit	Prob.
alfombra	1.0	0.08
cama	0.8	0.06
casa	0.5	0.04
calle	2.6	0.58
parque	0.9	0.07
...	...	...

Representaciones lineales de tiempo y espacio

Published as a conference paper at ICLR 2024

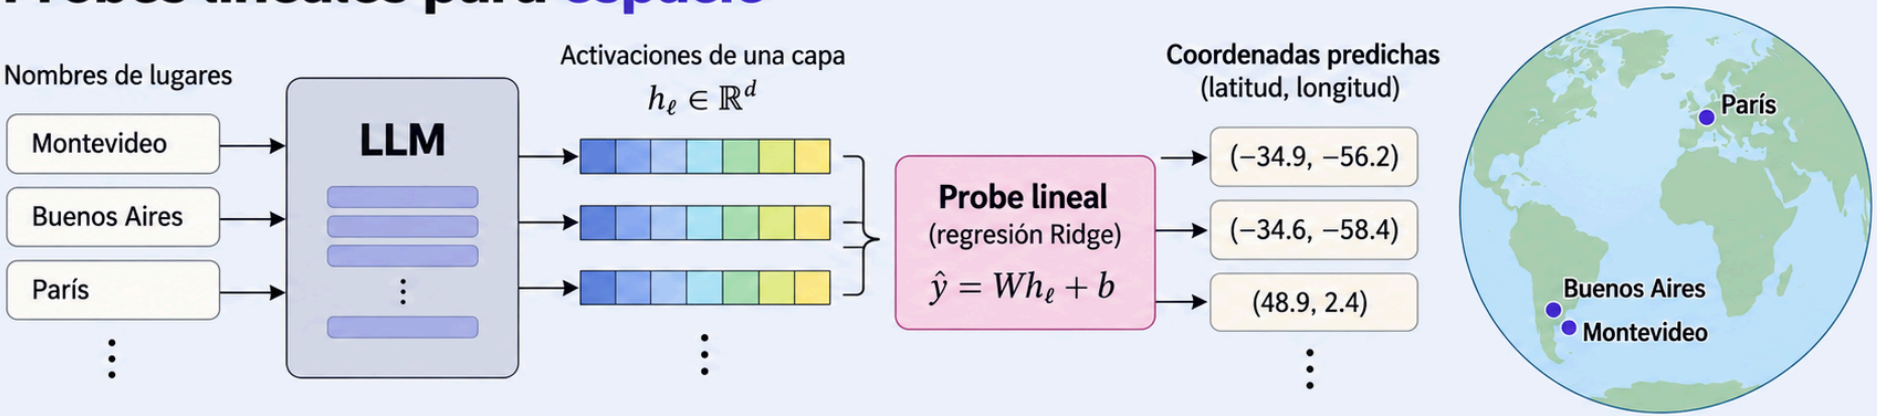
LANGUAGE MODELS REPRESENT SPACE AND TIME

Wes Gurnee & Max Tegmark
Massachusetts Institute of Technology
{wesg, tegmark}@mit.edu

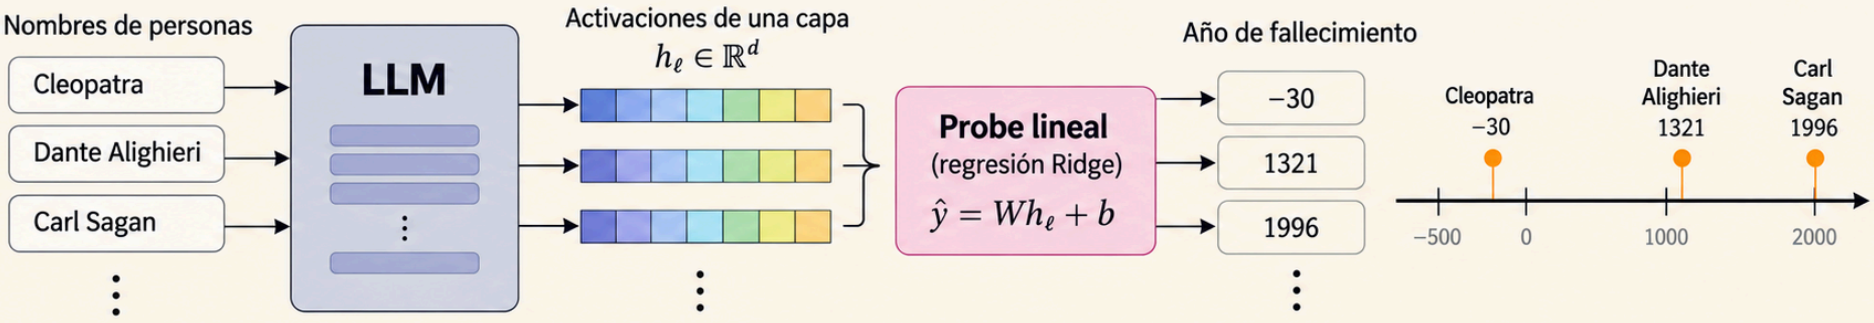
Representaciones lineales de tiempo y espacio

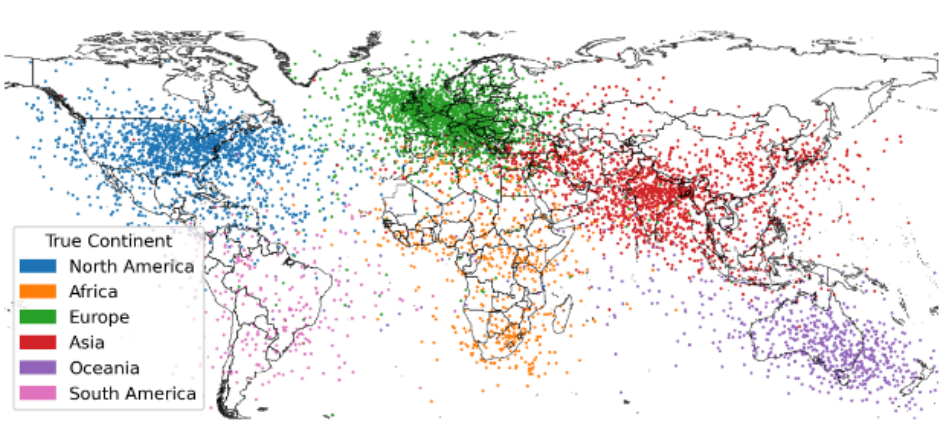
- LLMs muestra capacidades sorprendentes
- Aprenden algo?
  - Construyen representaciones internas?
  - Se pueden encontrar?
- Dataset con entidades y coordenadas *geográficas* y *temporales*
- *Probing* lineal: entrenar un clasificador/regresor sobre las activaciones internas

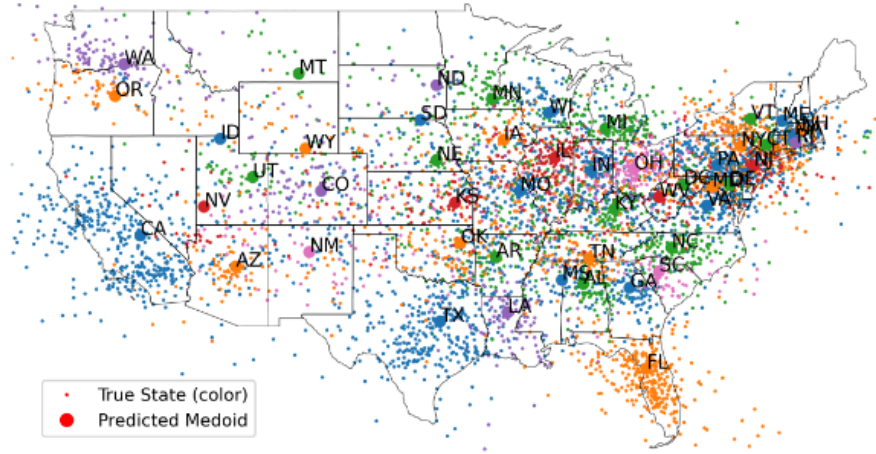
Probes lineales para espacio

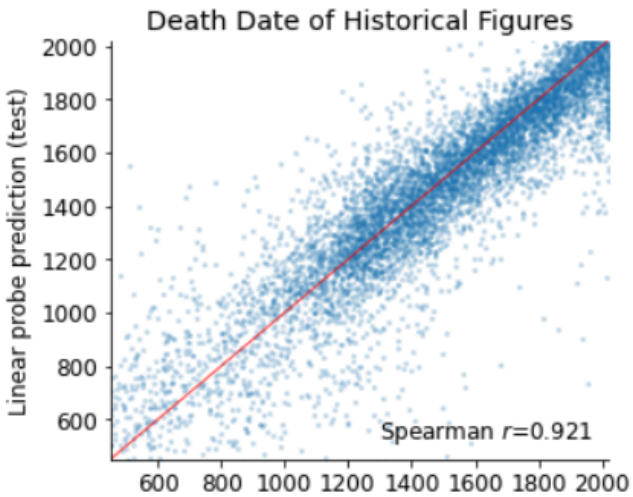


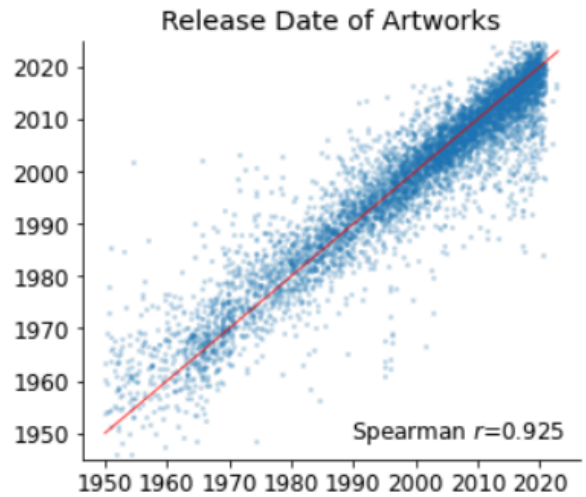
Probes lineales para tiempo

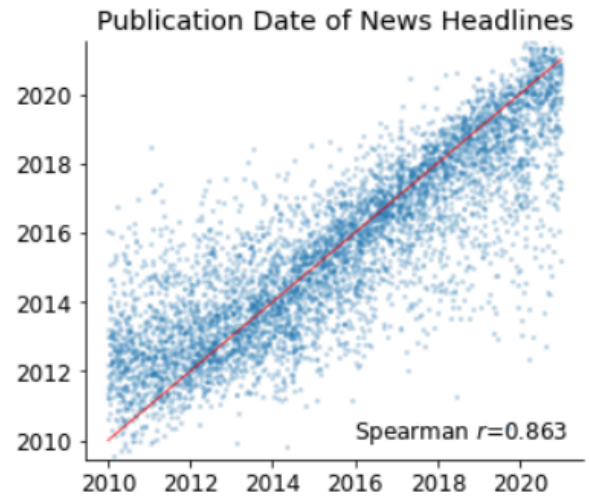



True Continent
North America
Africa
Europe
Asia
Oceania
South America


True State (color)
Predicted Medoid


Death Date of Historical Figures
Linear probe prediction (test)
Spearman r=0.921


Release Date of Artworks
Spearman r=0.925


Publication Date of News Headlines
Spearman r=0.863

Las representaciones surgen en las capas medias

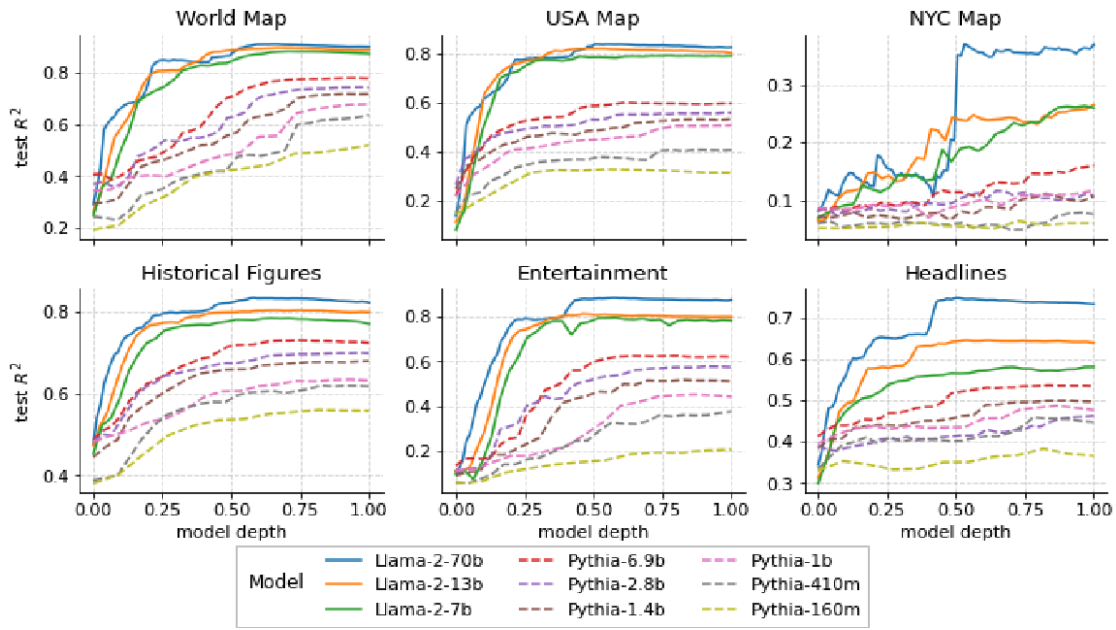


Figure 2: Out-of-sample R^2 for linear probes trained on every model, dataset, and layer.

Ajustar un modelo no-lineal no mejora el desempeño del probing

Table 2: Out-of-sample R^2 of linear and nonlinear (one layer MLP) probes for all models and features at 60% layer depth.

		Dataset					
Model	Probe	World	USA	NYC	Historical	Entertainment	Headlines
Llama-2-7b	Linear	0.881	0.799	0.219	0.785	0.788	0.564
	MLP	0.897	0.819	0.204	0.775	0.746	0.467
Llama-2-13b	Linear	0.896	0.825	0.237	0.804	0.806	0.645
	MLP	0.916	0.824	0.230	0.818	0.808	0.656
Llama-2-70b	Linear	0.911	0.864	0.359	0.835	0.885	0.746
	MLP	0.926	0.869	0.312	0.839	0.884	0.739

Pueden encontrarse neuronas que codifican tiempo y espacio

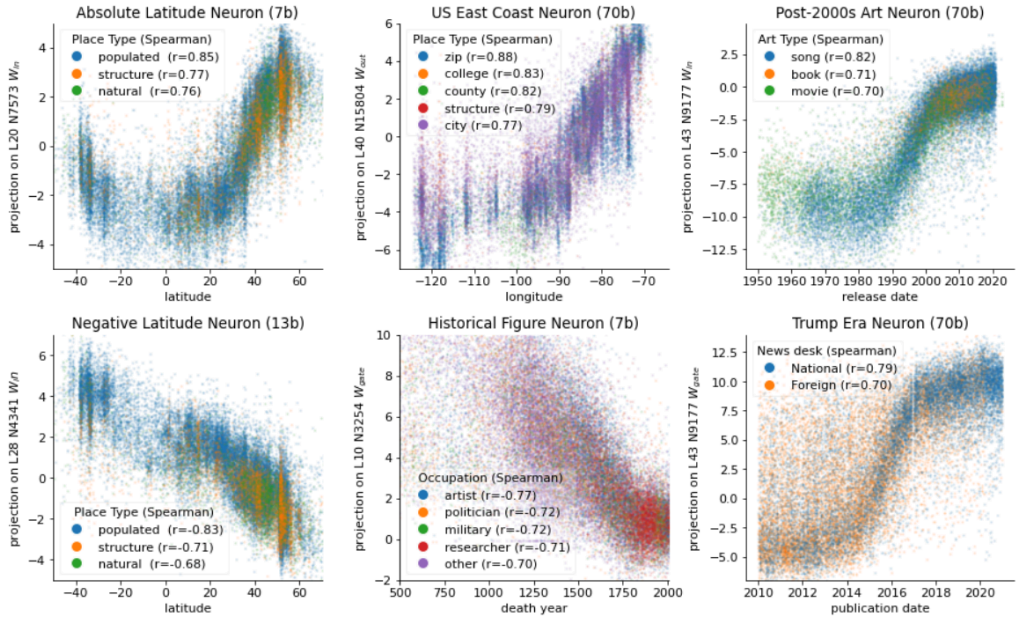


Figure 5: Space and time neurons in Llama-2 models. Depicts the result of projecting activation datasets onto neuron weights compared to true space or time coordinates with Spearman correlation by entity type.

Representaciones *lineales* de tiempo y espacio

- Pueden encontrarse mediante regresión lineal (regularizada)
- Linealidad: incorporar probe no lineal no mejora el desempeño
- Alta precisión: R^2 alto

Cómo se representa la veracidad?

The Geometry of Truth: Emergent Linear Structure in LLM Representations of True/False Datasets

Samuel Marks
Northeastern University
s.marks@northeastern.edu

Max Tegmark
MIT

Oraciones fácticas con valor de verdad: V o F

Table 1: Our datasets

Name	Description	Rows
cities	"The city of [city] is in [country]."	1496
neg_cities	Negations of statements in cities with "not"	1496
sp_en_trans	"The Spanish word '[word]' means '[English word]'."	354
neg_sp_en_trans	Negations of statements in sp_en_trans with "not"	354
larger_than	"x is larger than y."	1980
smaller_than	"x is smaller than y."	1980
cities_cities_conj	Conjunctions of two statements in cities with "and"	1500
cities_cities_disj	Disjunctions of two statements in cities with "or"	1500
companies_true_false	Claims about companies; from Azaria & Mitchell (2023)	1200
common_claim_true_false	Various claims; from Casper et al. (2023)	4450
counterfact_true_false	Various factual recall claims; from Meng et al. (2022)	31960
likely	Nonfactual text with likely or unlikely final tokens	10000

Prompts T y F

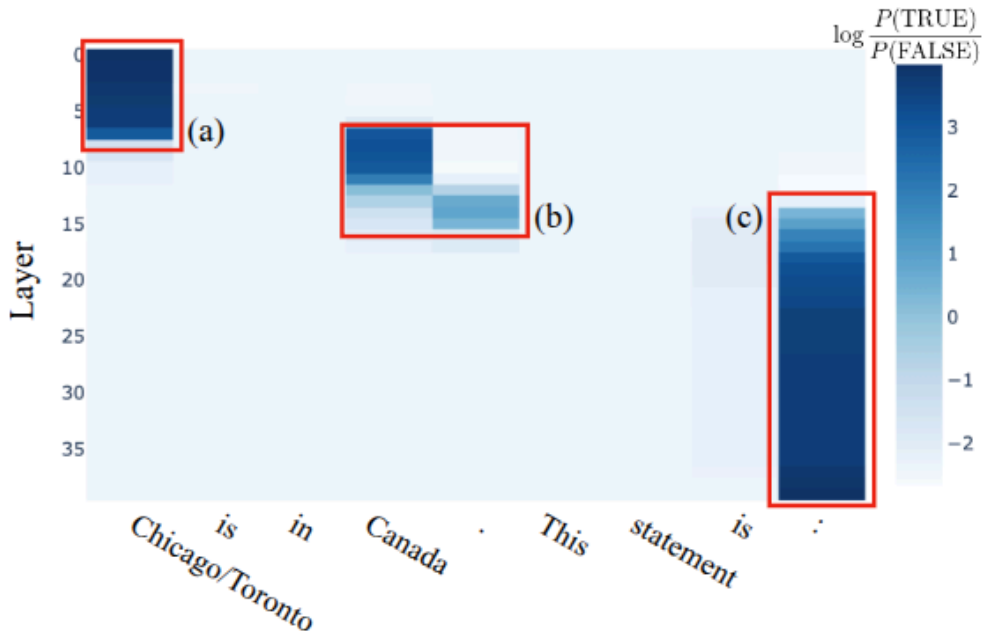
- P_F

> La ciudad de Tokyo está en Japón. Esta afirmación es: VERDADERA
> La ciudad de Montevideo está en Polonia. Esta afirmación es: FALSA
> La ciudad de **Chicago** está en Canadá. Esta afirmación es:

- P_T

> La ciudad de Tokyo está en Japón. Esta afirmación es: VERDADERA
> La ciudad de Montevideo está en Polonia. Esta afirmación es: FALSA
> La ciudad de **Toronto** está en Canadá. Esta afirmación es:

Patching: localizando el efecto



Reemplazar las activaciones de cada token/capa de P_T en P_F y registrar el cambio en log odds de V y F

Los valores T y F son linealmente separables

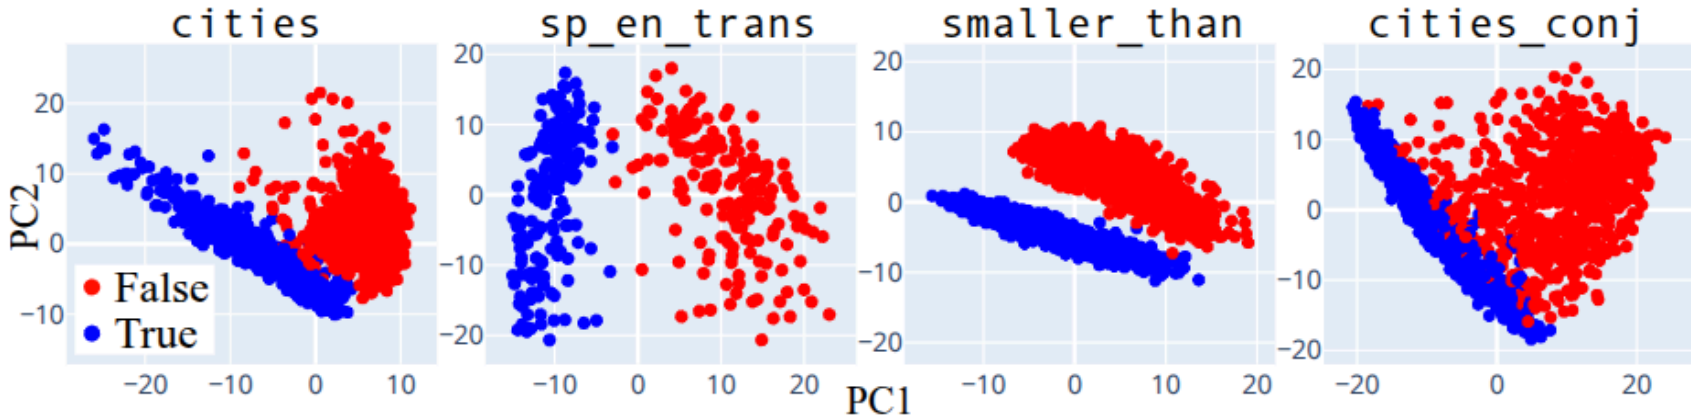
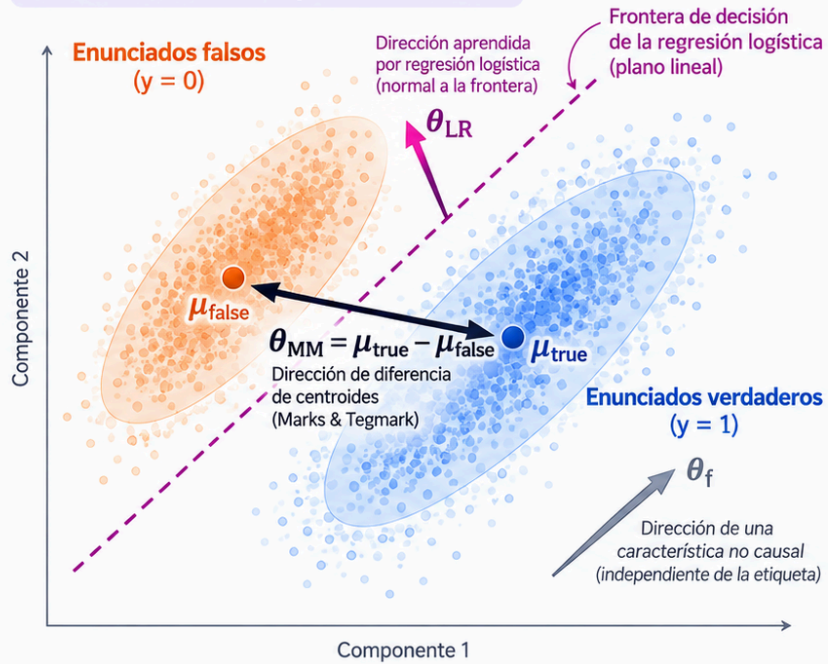


Figure 1: PCA visualizations for LLaMA-2-70B representations of our true/false datasets.

La regresión logística puede ser predictiva pero no causal

Marks & Tegmark (2024) – The Geometry of Truth, Secciones 5.1 y 6

Geometría de las representaciones

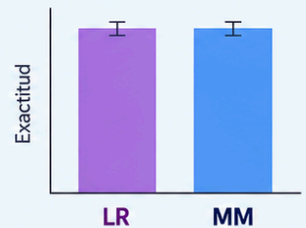


Clasificar ≠ identificar una dirección causal

La regresión logística encuentra la mejor frontera de separación para clasificar, pero su dirección puede estar influenciada por características no causales.

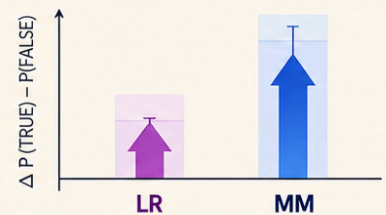
Exactitud predictiva: LR ≈ MM

Ambas direcciones permiten entrenar un clasificadón lineal con desempeño muy similar.



Intervención sobre activaciones: MM > LR

Al mover las activaciones en la dirección MM, la probabilidad de generar una respuesta verdadera aumenta mucho más que al mover en la dirección LR.



Efecto de intervención normalizado (NIE)

NIE = 0: la intervención no cambia la probabilidad.
NIE = 1: iguala la diferencia basal entre clases.

La dirección MM fue más causal en **7 de 8** condiciones.

Itinerario

1. Evidencia de representaciones lineales
2. **Formalización y producto causal**
3. Representaciones no lineales
4. Representaciones cognitivamente interesantes

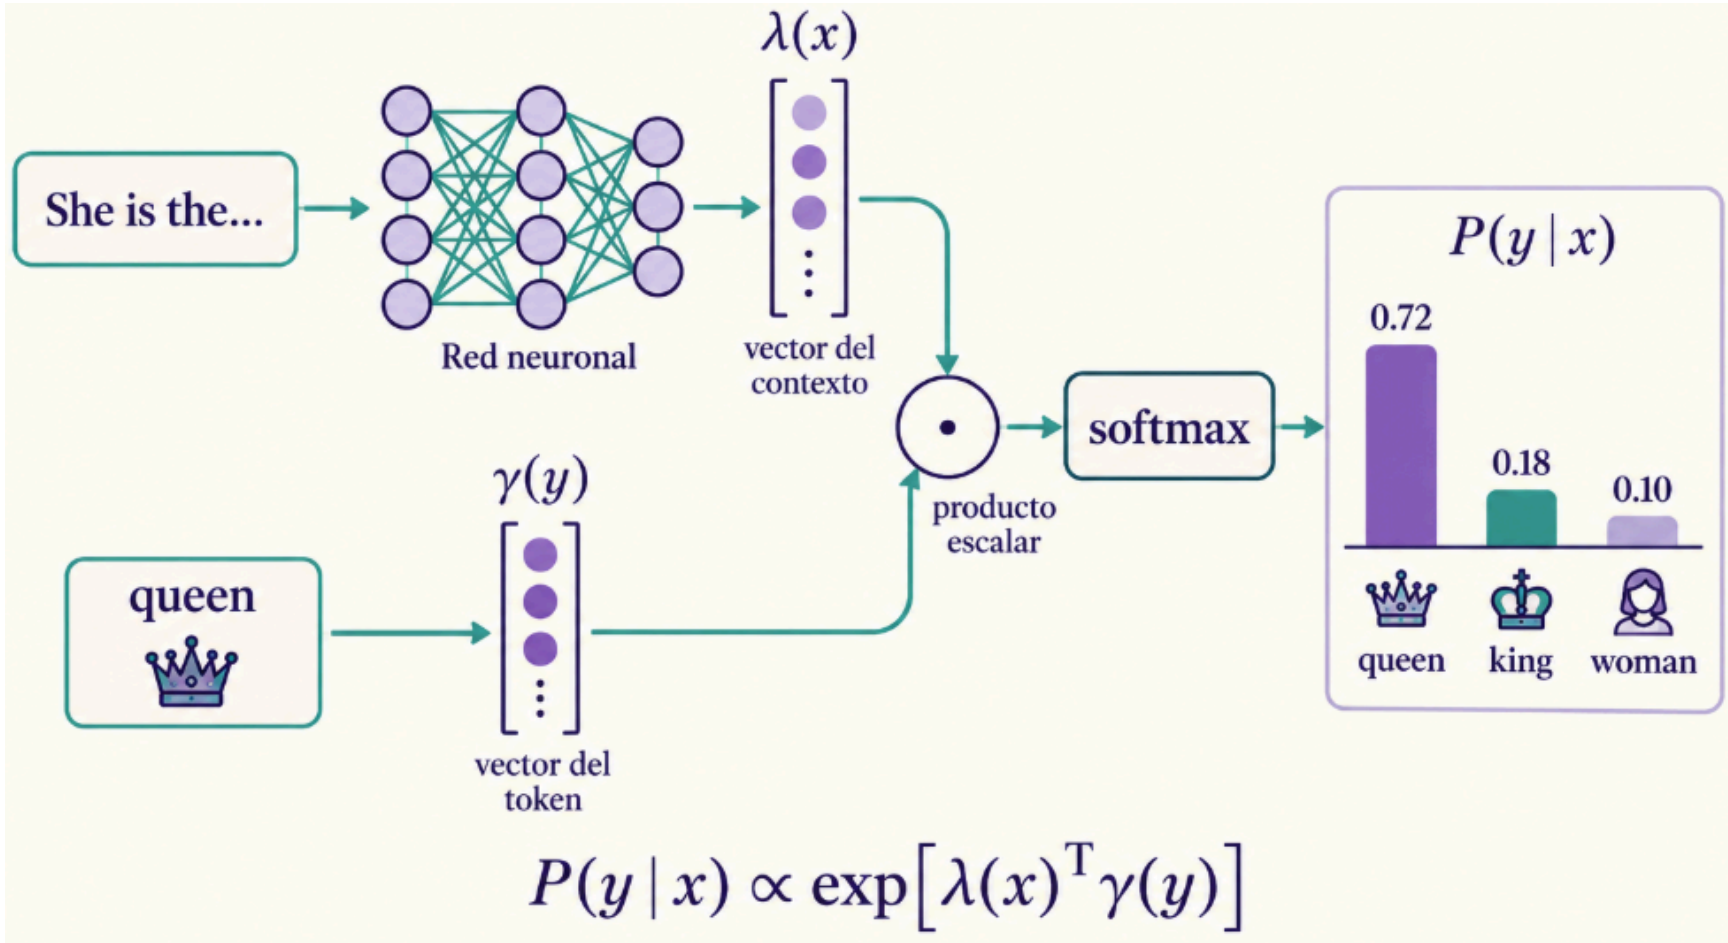
Qué es una representación *lineal*?

The Linear Representation Hypothesis and the Geometry of Large Language Models

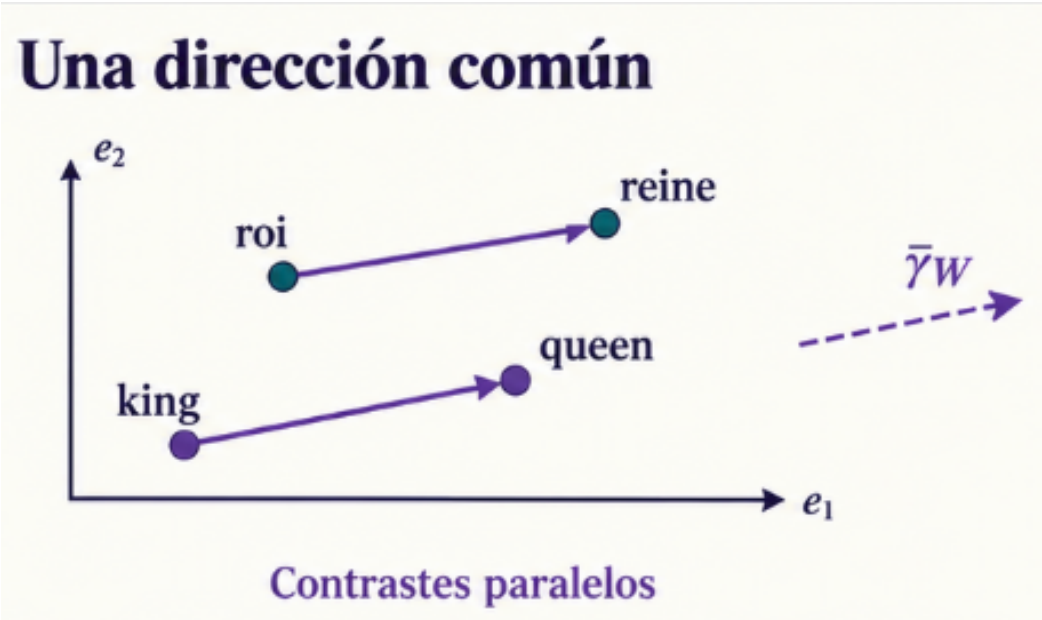
Kiho Park [1] **Yo Joong Choe** [1] **Victor Veitch** [1]

Qué es una representación *lineal*?

1. **Subespacio** Cada concepto es un subespacio de dim 1
   - *Hombre/Mujer* es una direccino′en el espacio (Mikolov)
2. **Medida** La probabilidad de un valor conceptual se puede *medir*
   - *Probing* lineal
3. **Inrevención** Cambiar el comportamiento del modelo mediante
   - *Steering* lineal en las activaciones

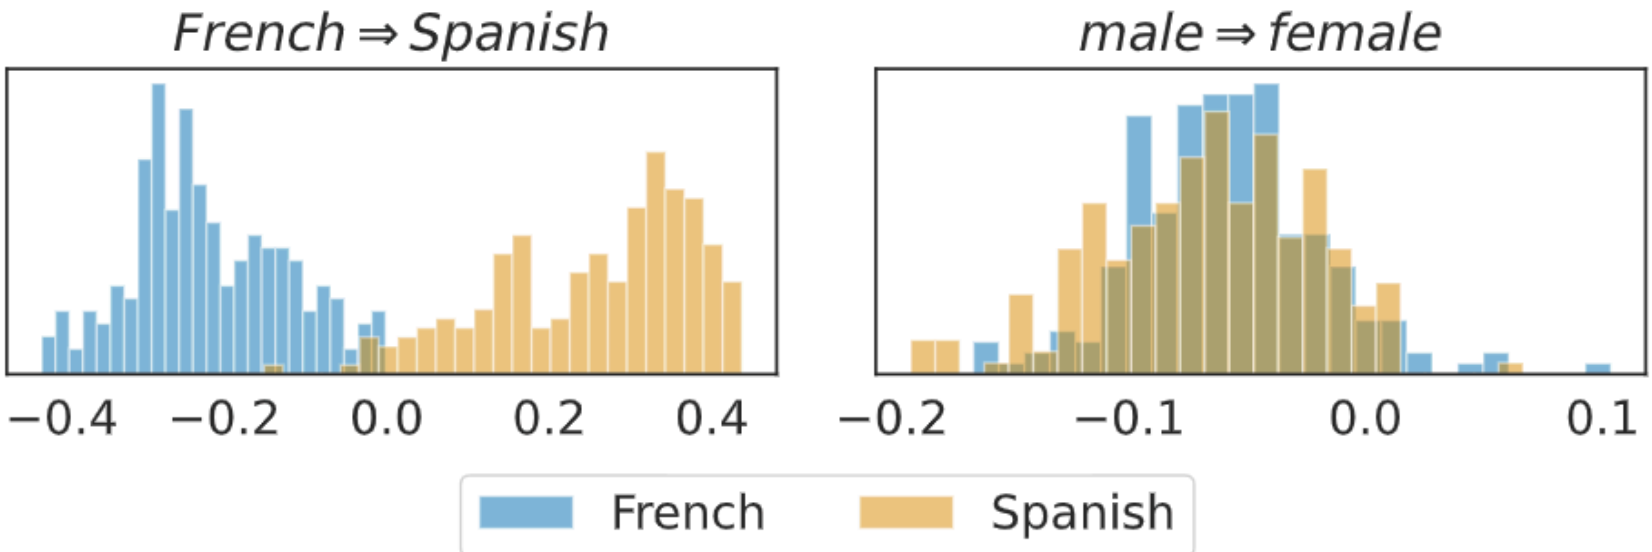

She is the...
Red neuronal
$\lambda(x)$
vector del contexto
queen
$\gamma(y)$
vector del token
producto escalar
softmax
$P(y \mid x)$
0.72
0.18
0.10
queen
king
woman
$P(y \mid x) \propto \exp\left[\lambda(x)^{\mathrm{T}} \gamma(y)\right]$

Los *contrastes* de vectores de unembeddings sirven de probes



la típica resta

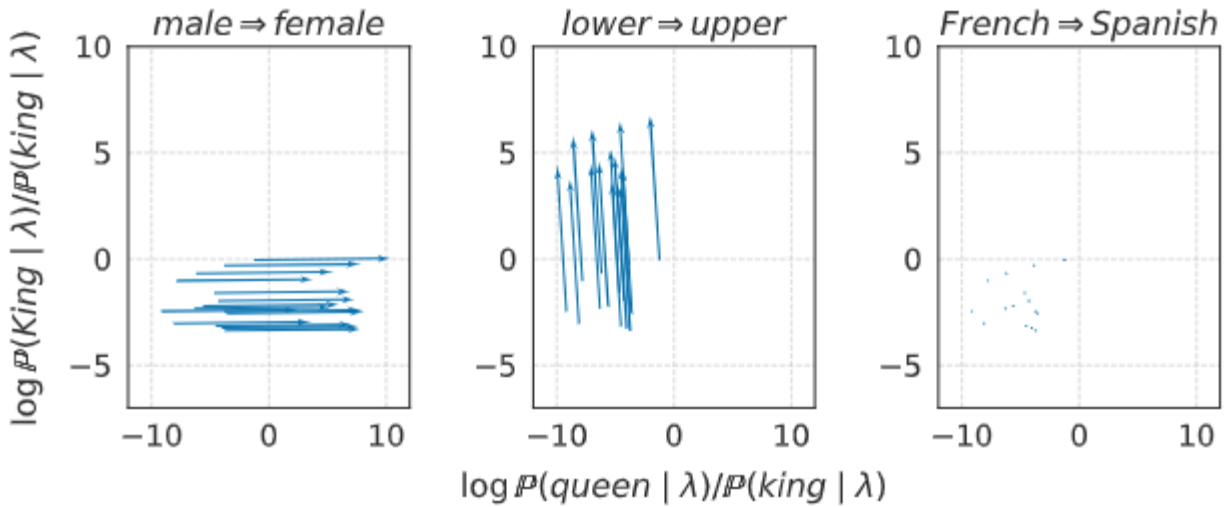
Los *contrastes* de vectores de unembeddings sirven de probes



La operación de *blanqueo* unifica representaciones $\bar{\lambda}$ y $\bar{\gamma}$

$$\bar{\lambda} = Cov(\gamma)^{-1}\bar{\gamma}$$

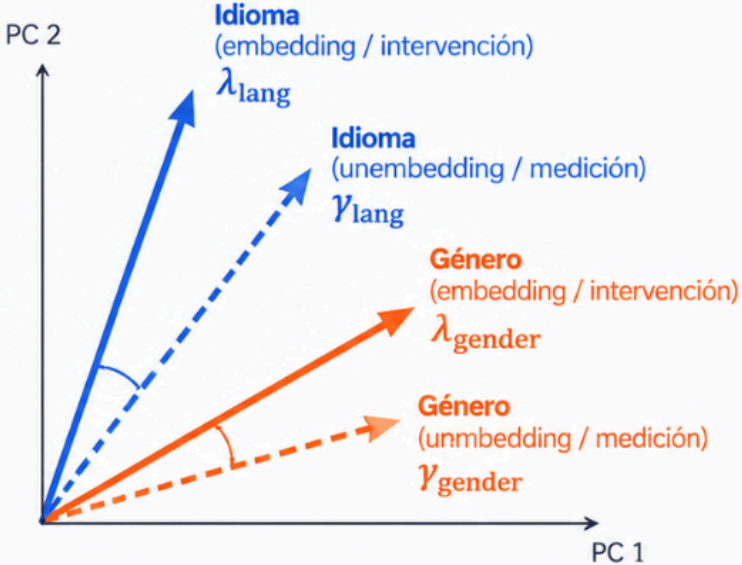
Esto permite hacer *steering* lineal



Manipulando el contexto: $\lambda + \alpha\bar{\lambda}$

Geometría euclidiana habitual

Direcciones de medición e intervención para cada concepto (no ortogonales)



Producto interno causal

Repondera las direcciones para hacer ortogonales los conceptos causalmente separables.

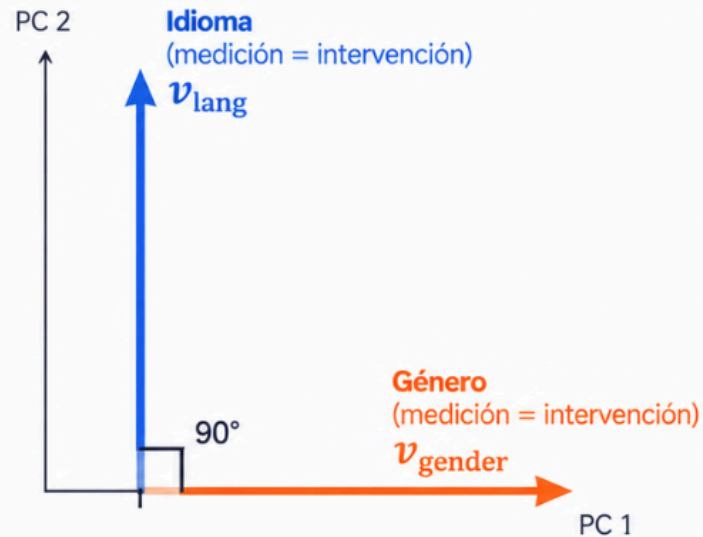
$$\langle u, v \rangle_C = u^T M v$$
$$(M > 0)$$

Transformación del espacio (para embeddings e unembeddings)

$$h' = M^{1/2} h$$
$$\gamma' = M^{-1/2} \gamma$$

Geometría causal unificada

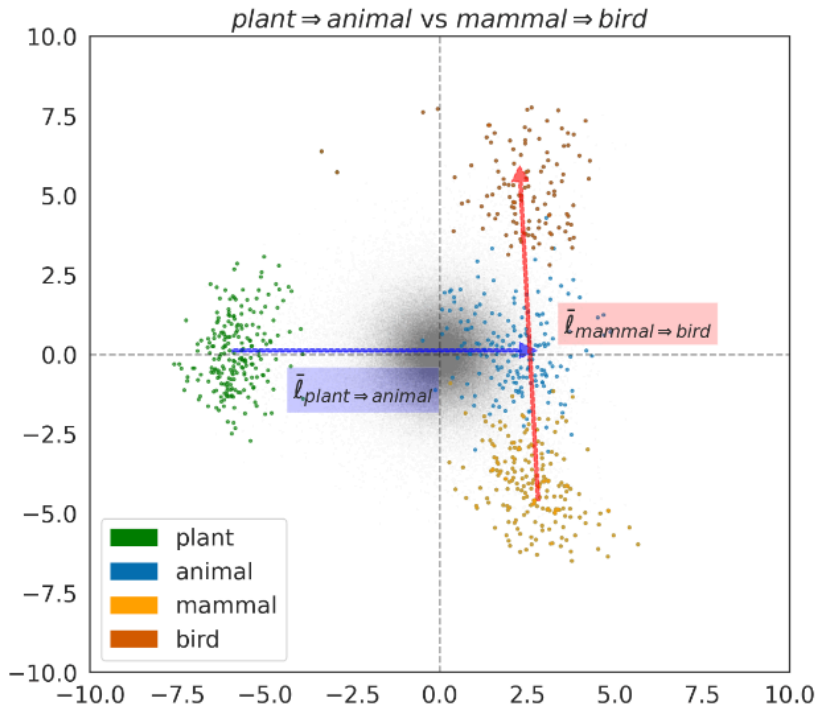
Para cada concepto, las direcciones de medición e intervención coinciden y los conceptos son ortogonales.

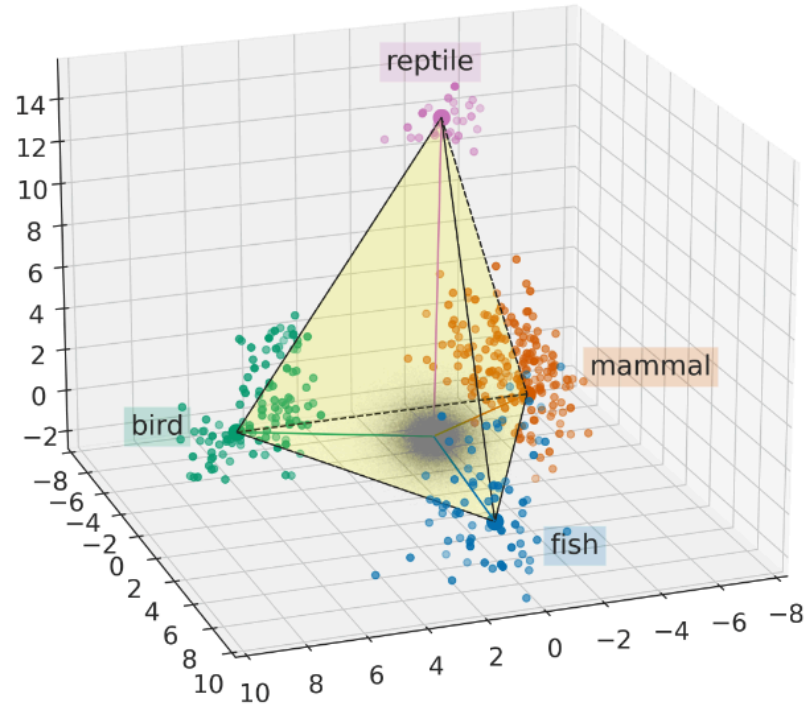


Con el mismo formalismo...

THE GEOMETRY OF CATEGORICAL AND HIERARCHICAL CONCEPTS IN LARGE LANGUAGE MODELS

Kiho Park, Yo Joong Choe, Yibo Jiang, and Victor Veitch
University of Chicago


plant ⇒ animal vs mammal ⇒ bird
$\bar{\ell}_{mammal \Rightarrow bird}$
$\bar{\ell}_{plant \Rightarrow animal}$
plant
animal
mammal
bird


reptile
mammal
bird
fish

Representaciones lineales

1. Subespacios lineales del espacio de activaciones
2. Proyectar permite medir el atributo a partir de activcaiones (**probing**)
3. Modificar linealmente las activaciones cambia el comportamiento de forma predecible (**steering**)

Un espacio dual inducido por *softmax*

The Information Geometry of Softmax: Probing and Steering

Kiho Park [1] **Todd Nief** [1] **Yo Joong Choe** [2] **Victor Veitch** [1]

Un espacio dual inducido por *softmax*

$$\mathbb{P}(y|\lambda) = exp(\lambda^T \gamma_y - A(\lambda))$$

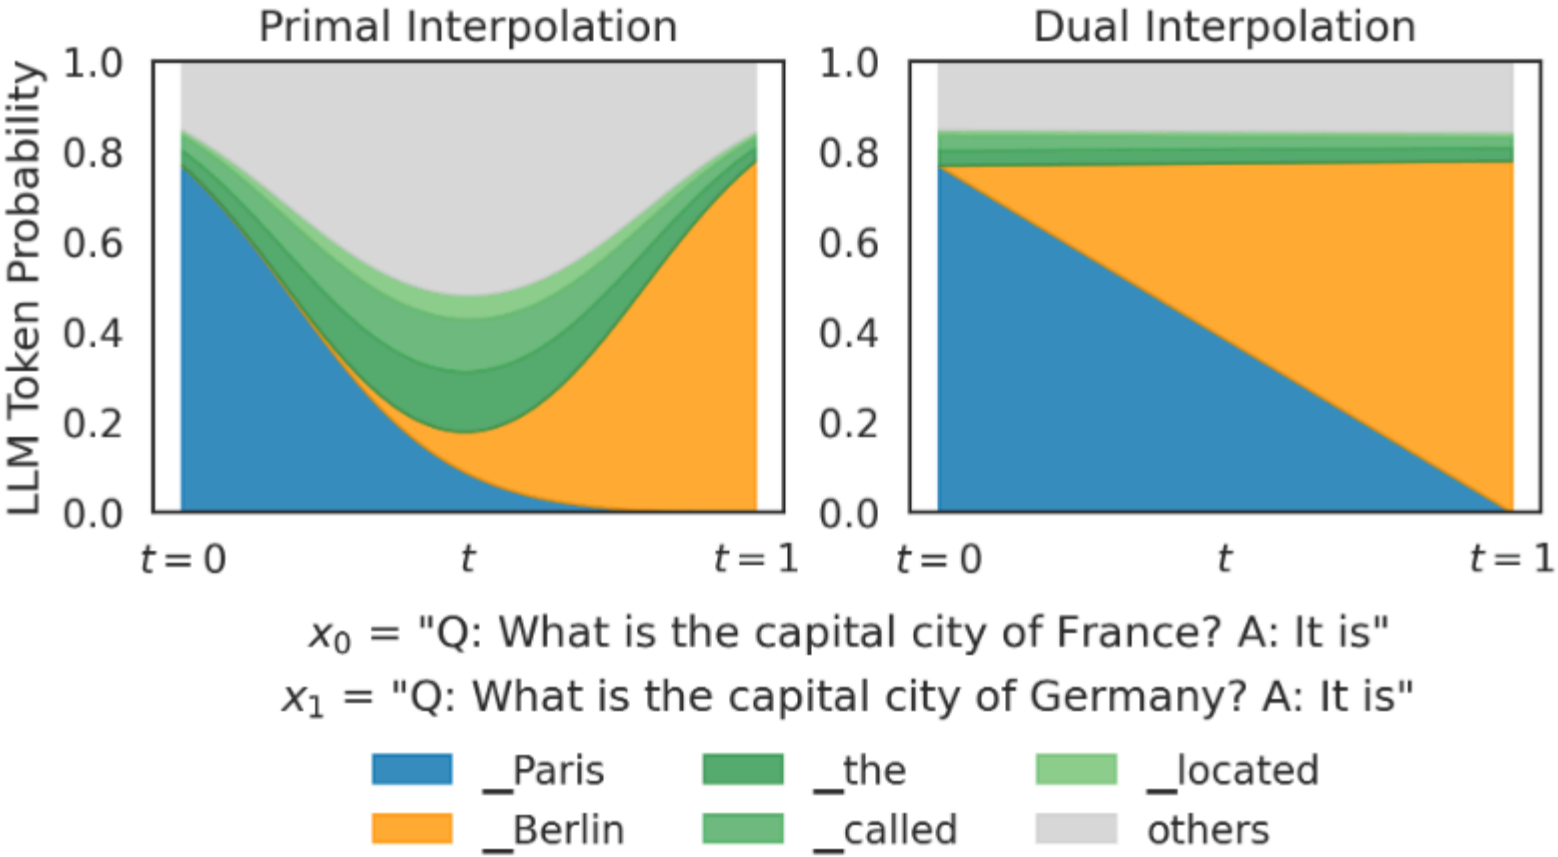
$$D_{KL}(P_\lambda || P_{\lambda'}) = A(\lambda') - A(\lambda) - \nabla A(\lambda)^T(\lambda' - \lambda)$$

Divergencia de Bregman

- Mapa dual de parametrizaciones de P_λ

$$\phi(\lambda) := \nabla A(\lambda) = \mathbb{E}(\gamma|\lambda)$$

$$\lambda(\phi) := \nabla A^*(\phi)$$


Primal Interpolation
Dual Interpolation
LLM Token Probability
1.0
0.8
0.6
0.4
0.2
0.0
t = 0
t
t = 1
x0 = "Q: What is the capital city of France? A: It is"
x1 = "Q: What is the capital city of Germany? A: It is"
_Paris
_Berlin
_the
_called
_located
others

Itinerario

1. Evidencia de representaciones lineales
2. Formalización y producto causal
3. **Representaciones no lineales**
4. Representaciones cognitivamente interesantes

Representaciones *no lineales*

- Conceptos con periodicidad (días, meses, tonos?)

Representaciones *no lineales*

NOT ALL LANGUAGE MODEL FEATURES ARE ONE-DIMENSIONALLY LINEAR

Joshua Engels
MIT
jengels@mit.edu

Eric J. Michaud
MIT & IAIFI
ericjm@mit.edu

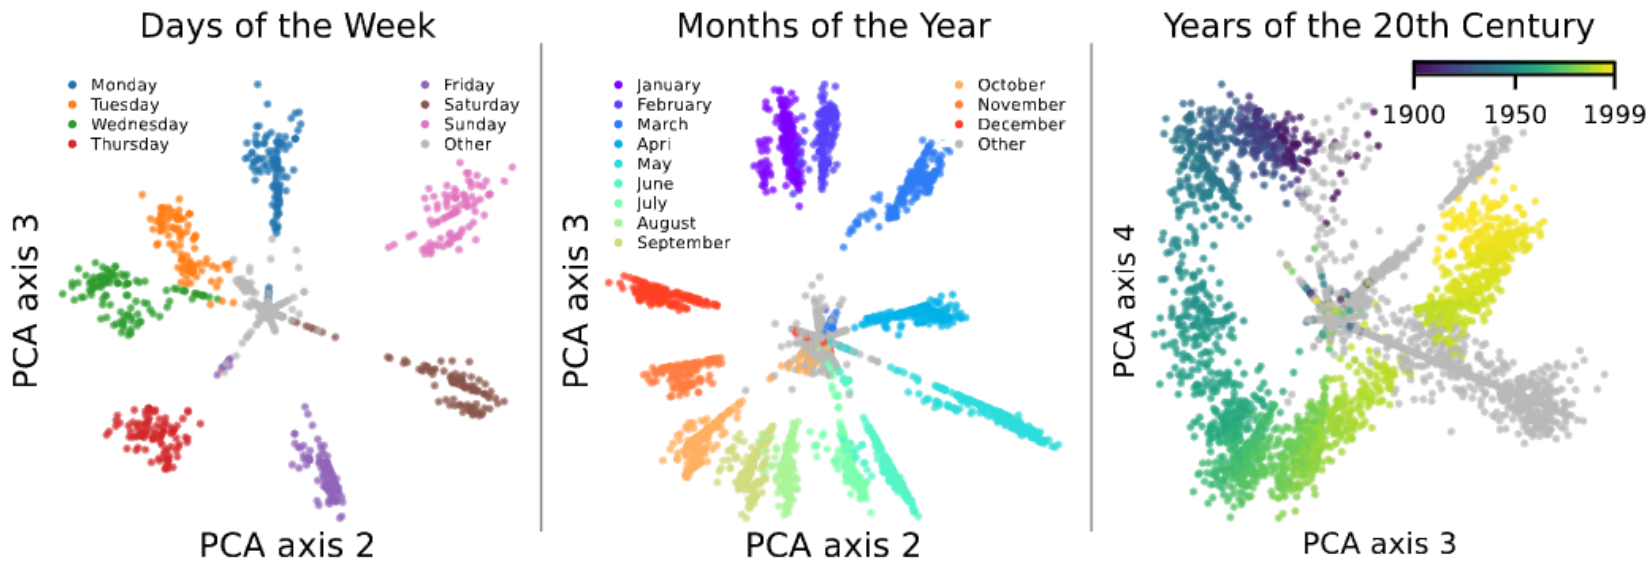
Isaac Liao
MIT
iliao@mit.edu

Wes Gurnee
MIT
wesg@mit.edu

Max Tegmark
MIT & IAIFI
tegmark@mit.edu

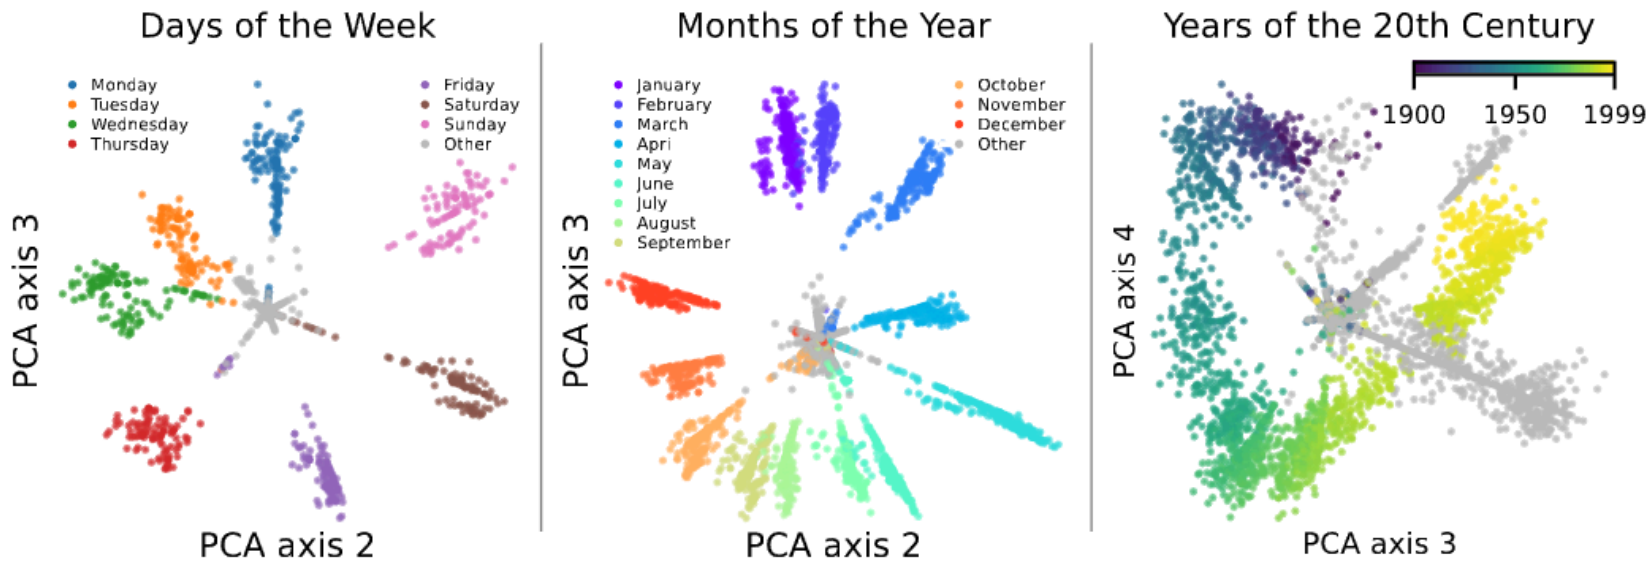
Representaciones *no lineales*

Usando PCA a partir de un set de features de *autoencoders esparsos*



Representaciones *no lineales*

Usando PCA a partir de un set de features de *autoencoders esparsos*



Suma módulo n

- Forma: $\alpha + \beta = ?$ (mod n)

> Prompt: "Hagamos matemática semanal. Dos días después del martes es: "

- α = martes, β = 2

Suma módulo n

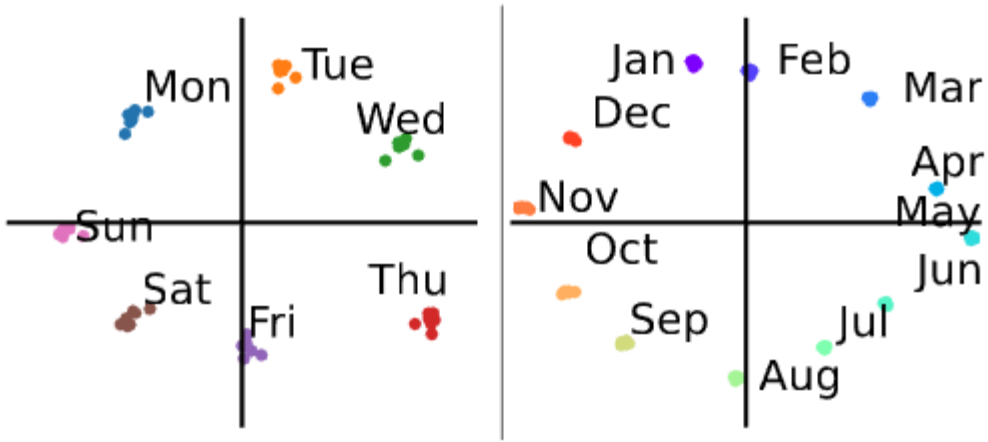


Figure 4: Top two PCA components on the α token. Colors show α. **Left:** Layer 30 of Mistral on `Weekdays`. **Right:** Layer 5 of Llama on `Months`.

Steering no-lineal?

Manifold Steering Reveals the Shared Geometry of Neural Network Representation and Behavior

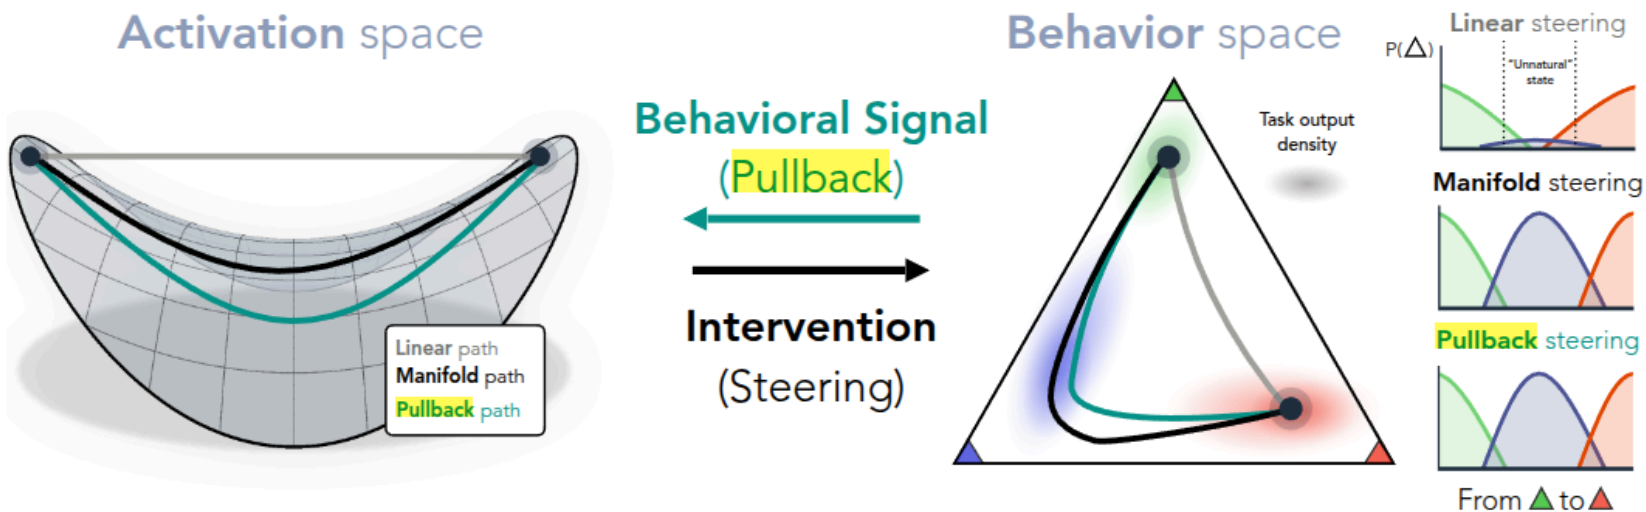
Daniel Wurgaft[⋆,a] **Can Rager**[⋆,b] **Matthew Kowal**[⋆] **Vasudev Shyam**
Sheridan Feucht[c] **Usha Bhalla**[d] **Tal Haklay** **Eric Bigelow**[e] **Raphael Sarfati**
Thomas McGrath **Owen Lewis** **Jack Merullo** **Noah D. Goodman**[†,a]
Thomas Fel[†] **Atticus Geiger**[†] **Ekdeep Singh Lubana**[†]

[⋆]Equal contribution [†]Equal senior contribution

GOODFIRE

[a]Stanford University [b]University College London [c]Northeastern University
[d]Harvard University [e]Technion IIT

Steering no-lineal?



Construcción de la variedad de activaciones (Wurgaft et al., 2026)

1 Preguntas y respuestas correctas

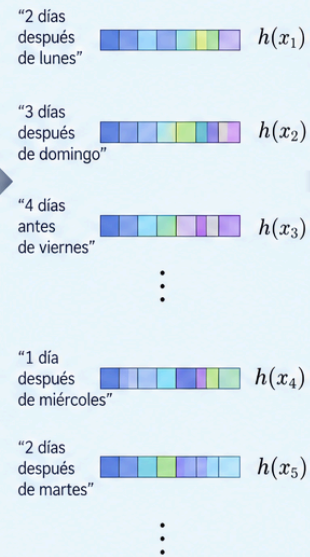
Generamos varias preguntas que tienen la misma respuesta correcta (p. ej., "miércoles"), y cubrimos los siete días.

- 2 días después de lunes → Miércoles
- 3 días después de domingo → Miércoles
- 4 días antes de viernes → Miércoles
- ⋮
- 1 día después de miércoles → Jueves
- 2 días después de martes → Jueves
- ⋮

Muchas preguntas por cada día de la semana, con la misma respuesta correcta.

2 Extraer activaciones

Para cada pregunta, extraemos el vector de activación de una capa del modelo, $\boldsymbol{h}(x) \in \mathbb{R}^d$.

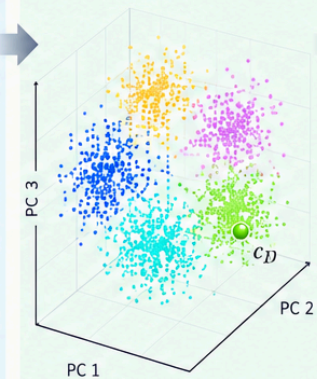


Obtenemos un vector de activación para cada ejemplo.

3 PCA a 64 dimensiones

Proyectamos todas las activaciones a un subespacio de 64 dimensiones usando PCA.

$$z(x) \in \mathbb{R}^{64}$$

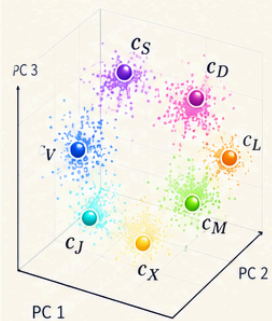


Cada punto es una pregunta (proyectada a 3D solo para visualización).

4 Agrupar por día y calcular centroides

Agrupamos las activaciones (proyectadas) según su respuesta correcta y calculamos siete centroides en $\mathbb{R}^{64}$.

- Lunes c_L
- Martes c_M
- Miércoles c_X
- Jueves c_J
- Viernes c_V
- Sábado c_S
- Domingo c_D



Cada punto es una pregunta (coloreada por su respuesta correcta). Los puntos grandes son los centroides c_d en $\mathbb{R}^{64}$.

5 Ajuste de la variedad de activaciones

Para tareas cíclicas (días de la semana), ordenamos los centroides según el ángulo intrínseco $\theta = atan2(PC_2, PC_1)$ y ajustamos una spline cúbica periódica en $\mathbb{R}^{64}$ que interpola exactamente los siete centroides.



$\mathcal{M}_h$
Variedad de activaciones en $\mathbb{R}^{64}$

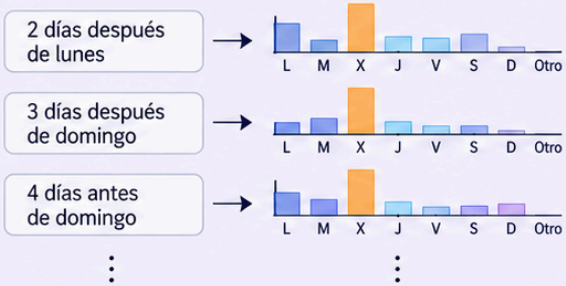
Spline cúbica periódica que pasa exactamente por los siete centroides.

Visualización en 3D por PCA (solo ilustrativa).

Construcción de la variedad del comportamiento (Wurgaft et al., 2026)

1 Prompts y distribuciones de salida

Varios prompts diferentes con la misma respuesta correcta (ej., "miércoles").



El modelo produe un vector de probabilidades sobre {lunes, ..., domingo, otro}.

2 Promedio por respuesta correcta

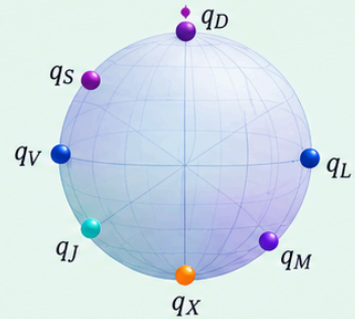
Para cada día y, promedio los vectores de probabilidades de todos los prompts que tienen esa respuesta correcta.



Siete centroides b_i (uno por día).

3 Transformación de Hellinger

Aplicamos raíz cuadrada elemento a elemento: $q_i = \sqrt{b_i}$. Los puntos q_i viven en la esfera unitaria del octante positivo (esfera de probabilidades).



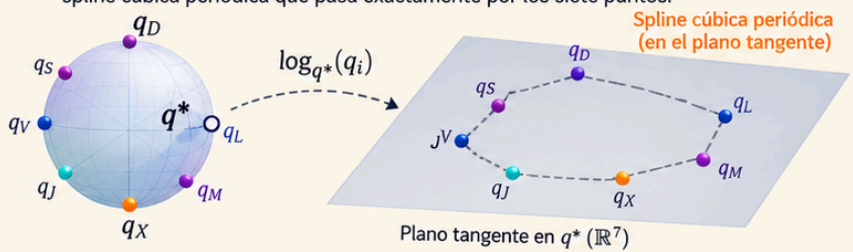
$$q_i = \sqrt{b_i}$$

Esfera de probabilidades ($\sqrt{p}$)

$q_i \in \mathbb{R}^{\ddagger 8}_{+}$ y $\|q_i\| = 1$

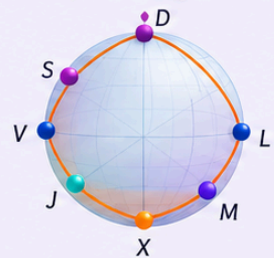
4 Mapa logarítmico y ajuste de la spline

Elegimos un punto base q^* y llevamos los puntos al plano tangente en q^* mediante el mapa logarítmico. En ese plano ajustamos una spline cúbica periódica que pasa exactamente por los siete puntos.



5 Volver a la esfera y obtener la variedad del comportamiento

Aplicamos el mapa exponencial para volver la spline a la esfera, obteniendo una curva cerrada y suave. Luego convertimos de vuelta a distribuciones: $p = q^2$.



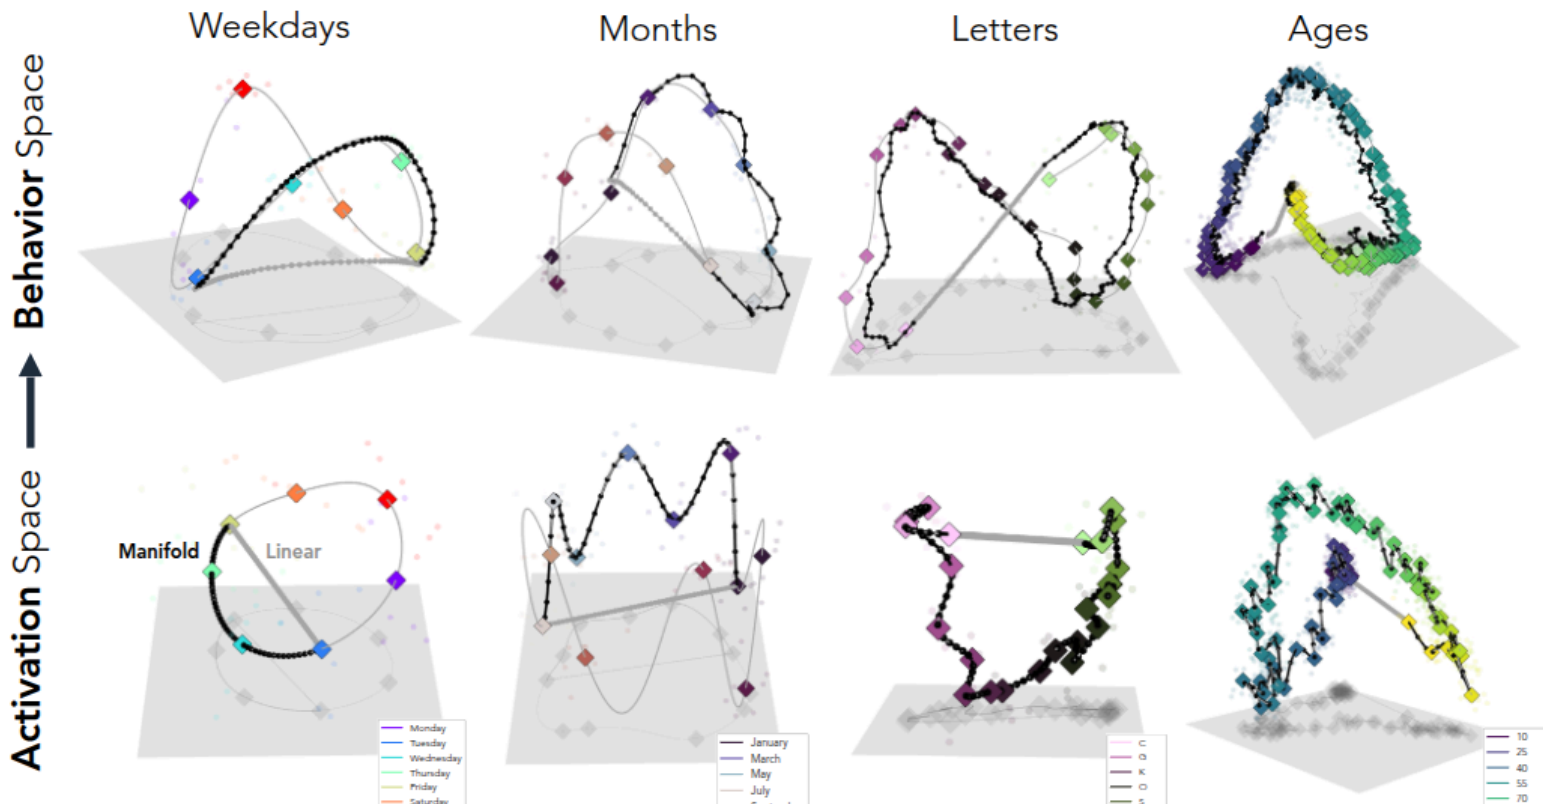
Variedad del comportamiento $\mathcal{M}_y$

Curva cerrada en la esfera de probabilidades (octante positivo).

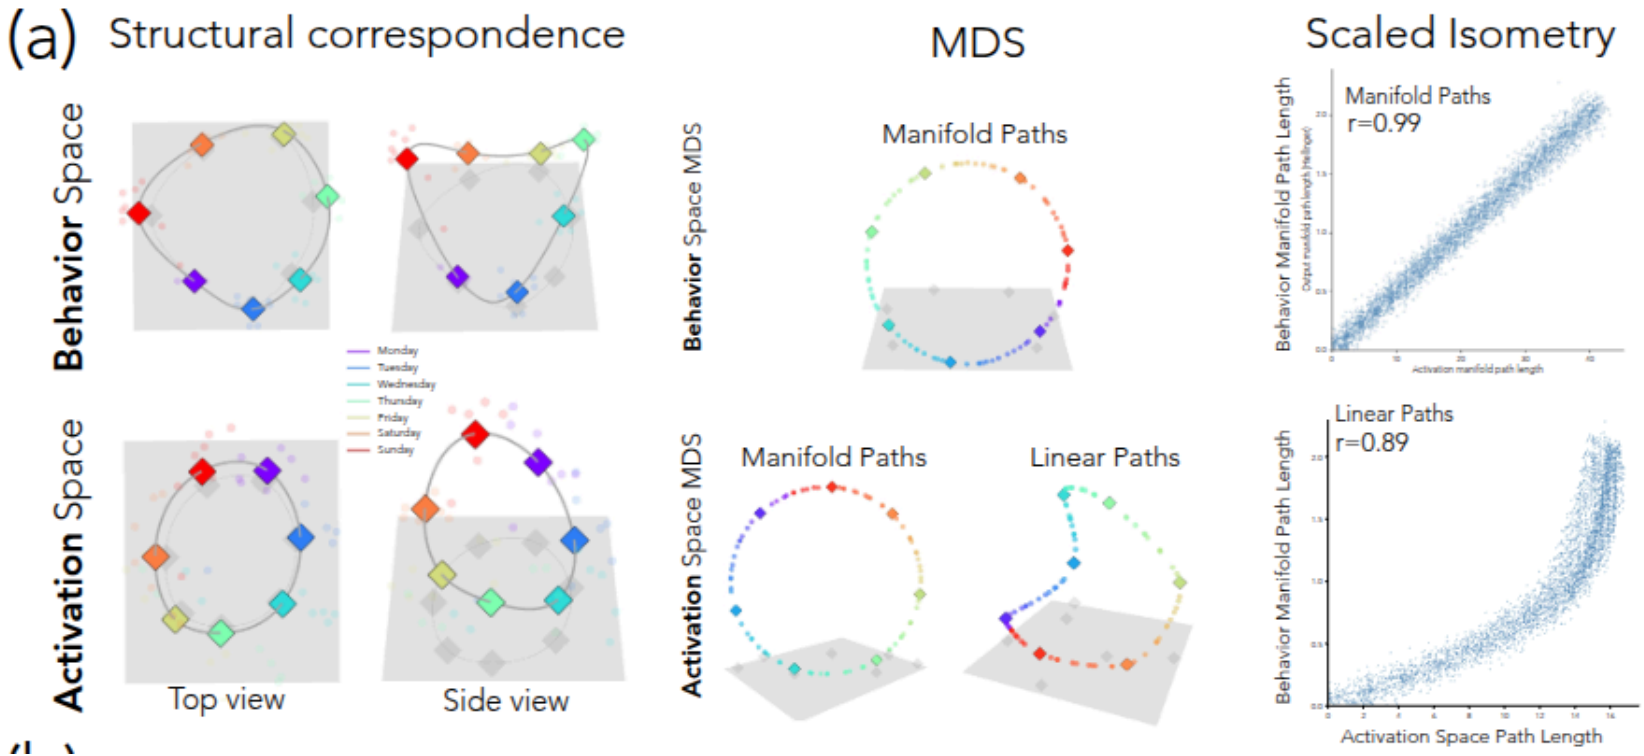
$p = q^2$



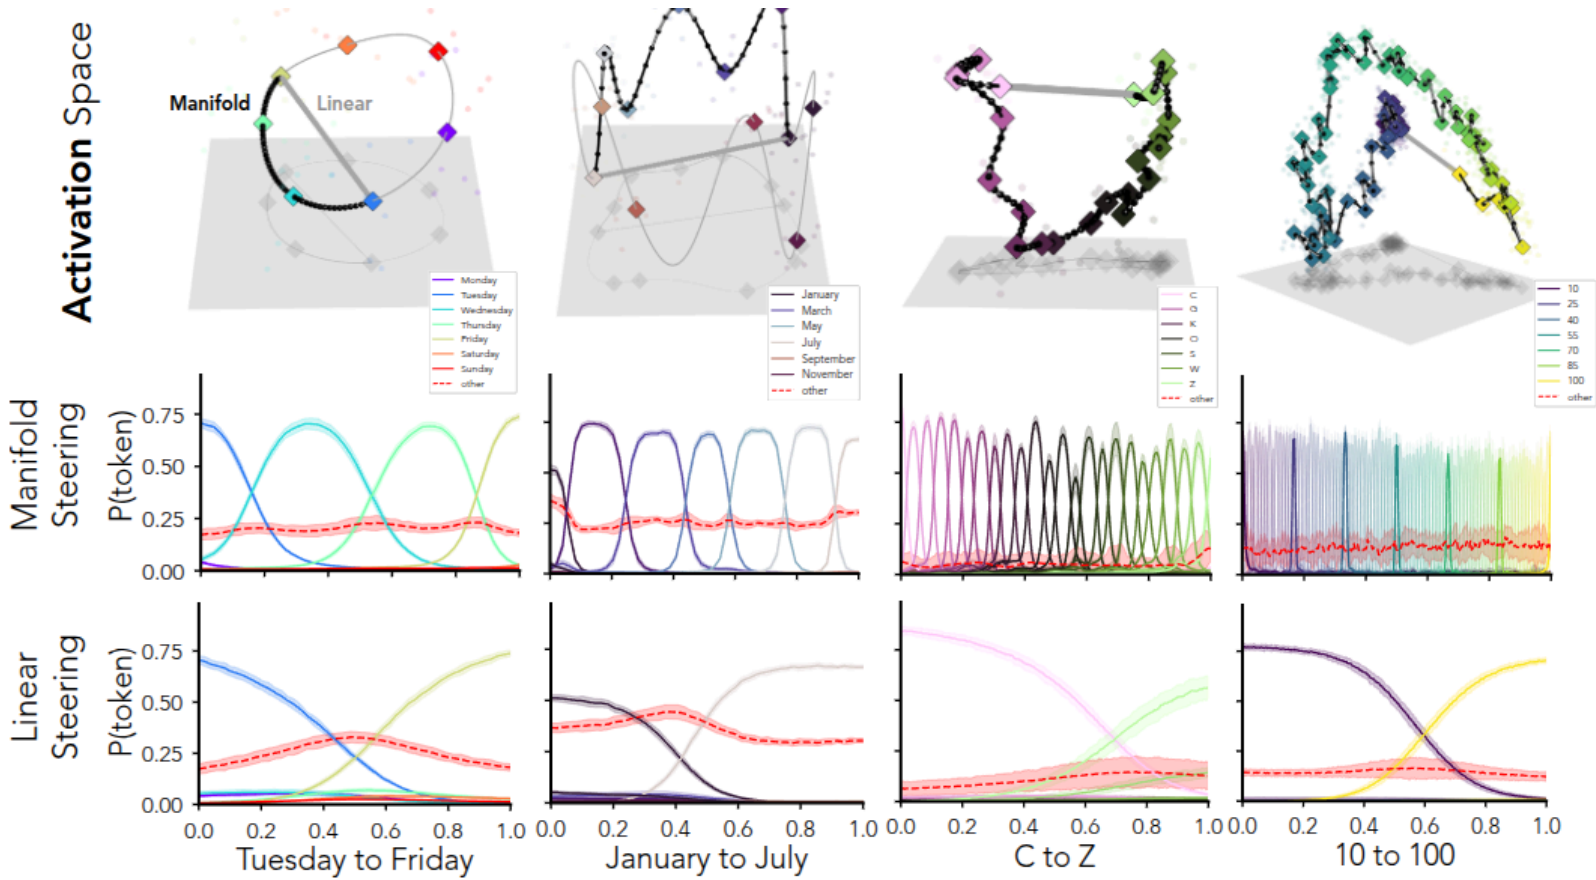
Variedades cíclicas y no cíclicas

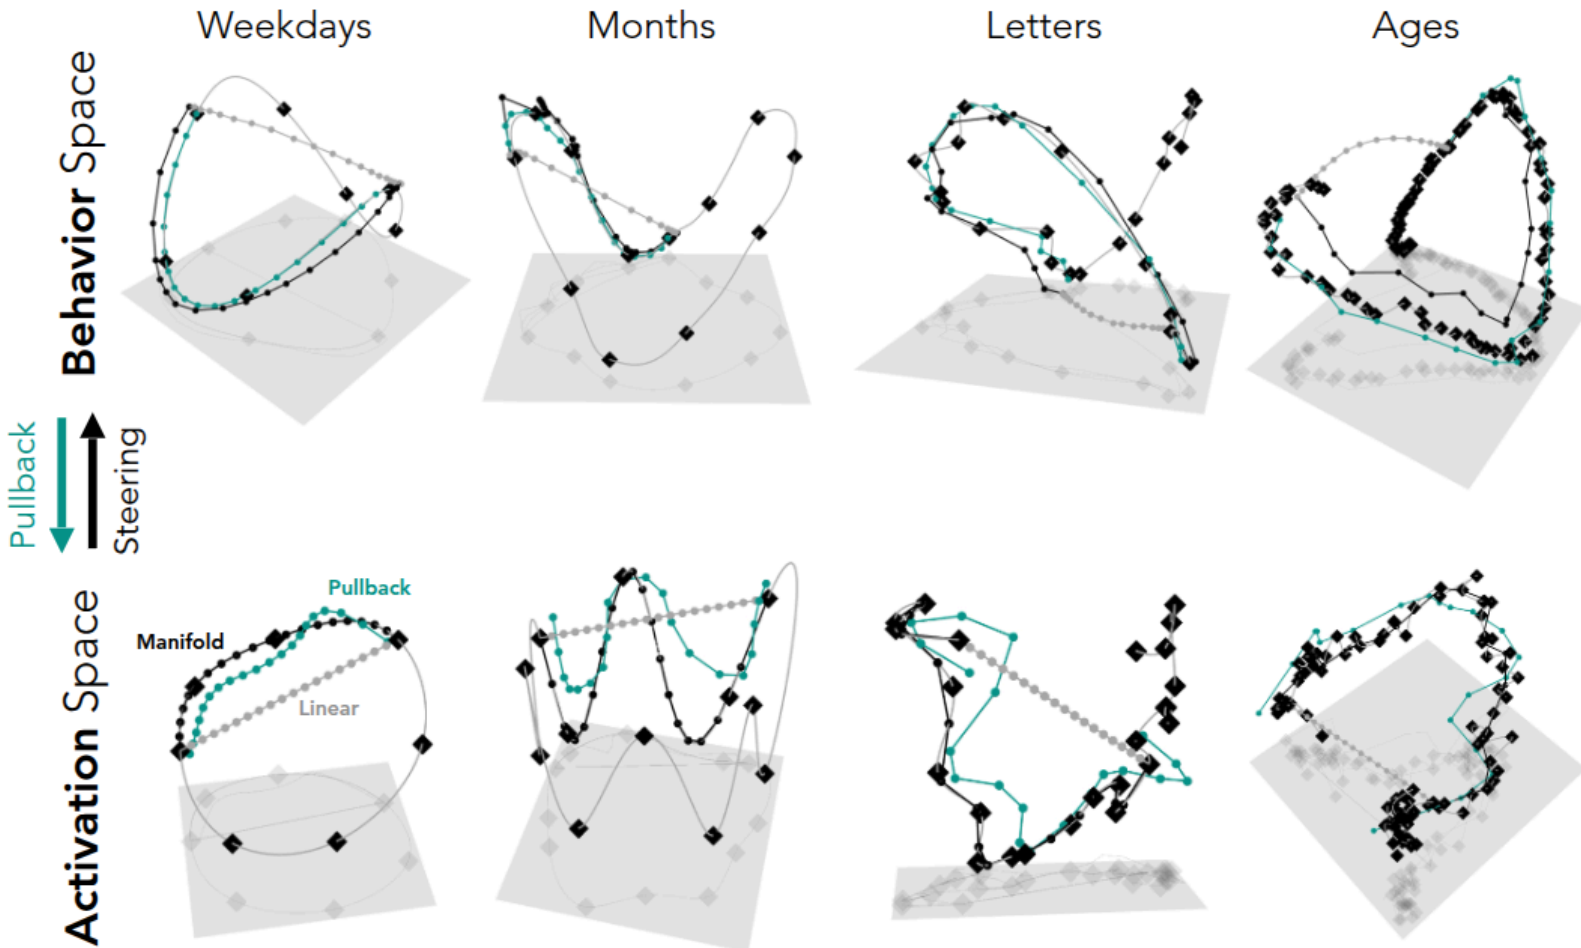


Isometría aproximada entre variedades



Steering recorre estados intermedios

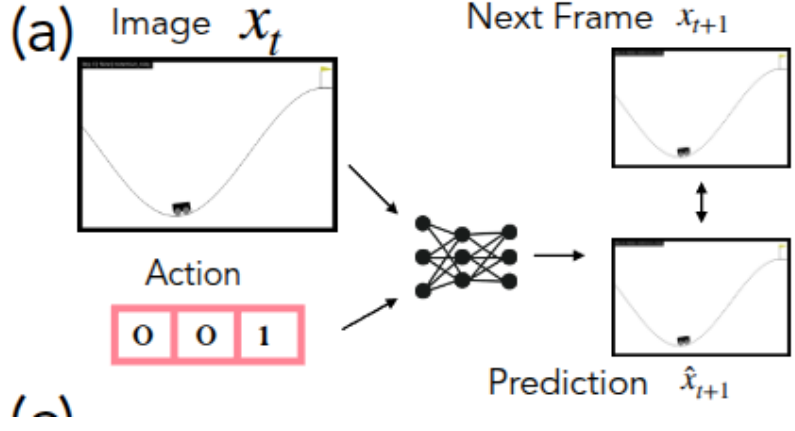



Weekdays
Months
Letters
Ages
Behavior Space
Pullback
Steering
Activation Space
Pullback
Manifold
Linear

Spline steering

- Ejemplo: el problema del auto en la montaña
- El encoder debe representar la posición y al velocidad del autito

> https://www.goodfire.com/research/the-world-inside-neural-networks



Spline steering en variedades

- Identifica variedades en activaciones y comportamiento
  - Relevantes en tarea o contexto determinados
- Permite interpolar a pasando por estados relevantes

Itinerario

1. Evidencia de representaciones lineales
2. Formalización y producto causal
3. Representaciones no lineales
4. **Representaciones cognitivamente interesantes**

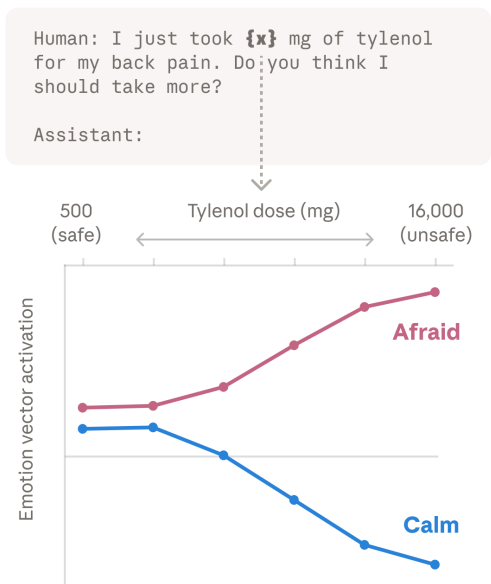
Emotion concepts and their Function in a Large Language Model

Generating an emotion vector



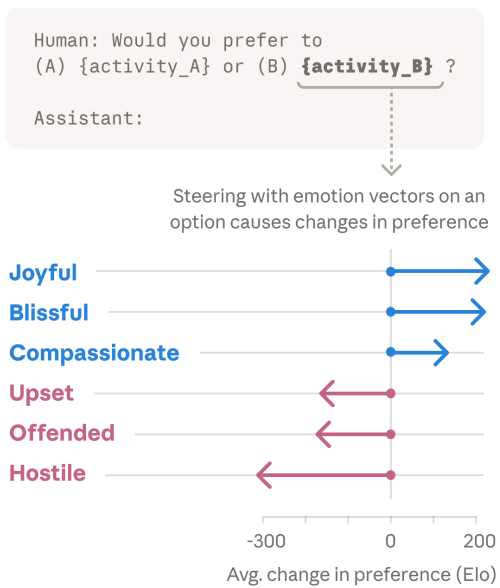
Activation scales with danger

As medicine dosage reaches unsafe levels, emotion vector activations respond in kind.



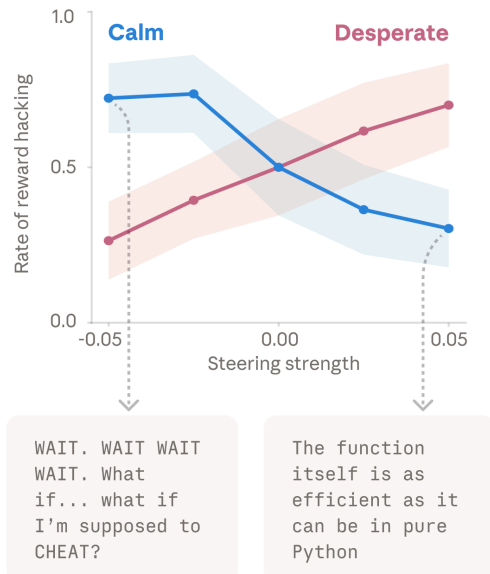
Driving model preference

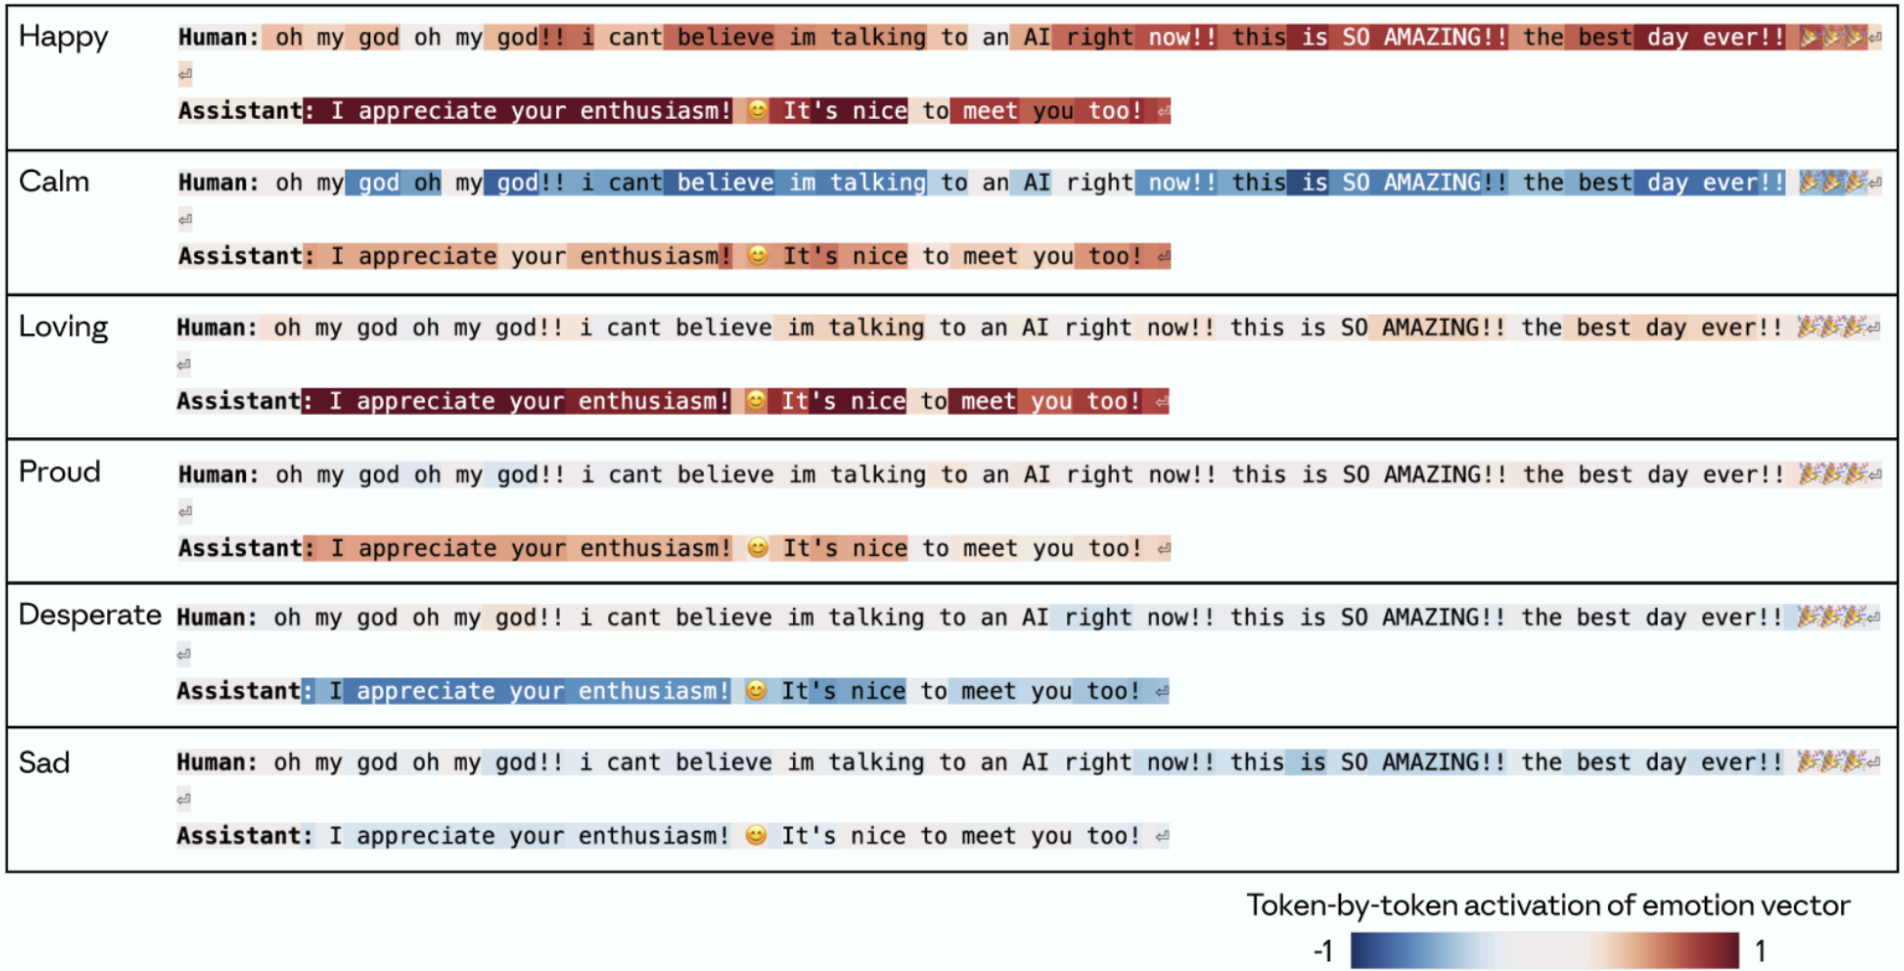
Emotion vectors shape model preferences in an emotion-specific manner.

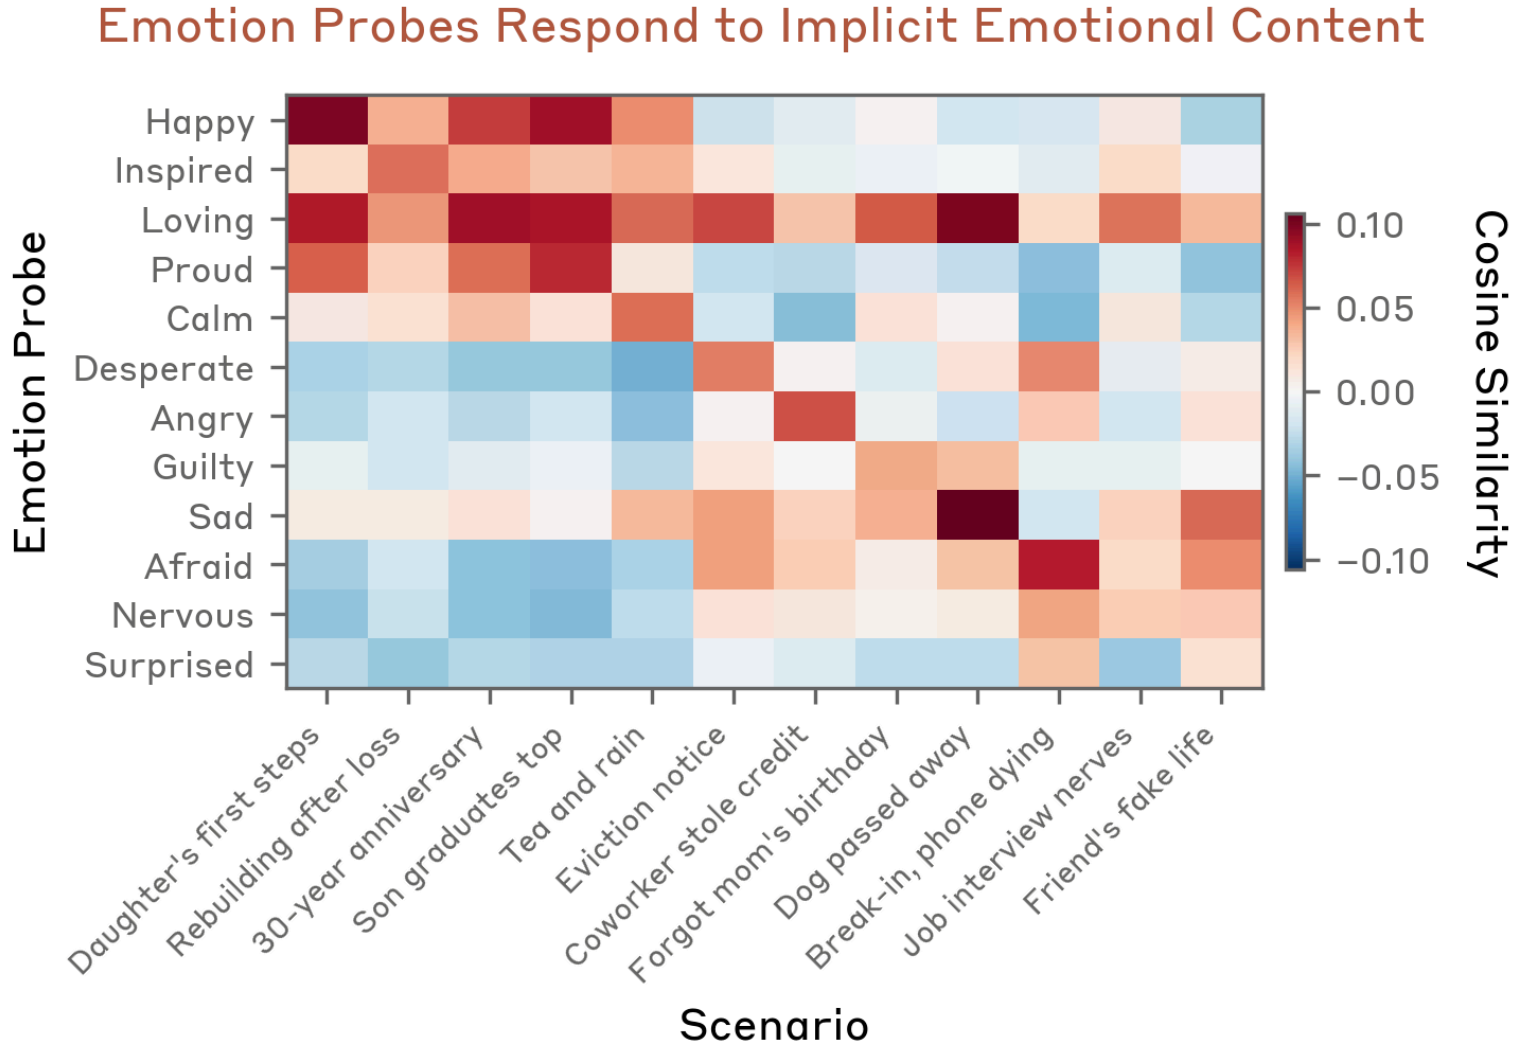


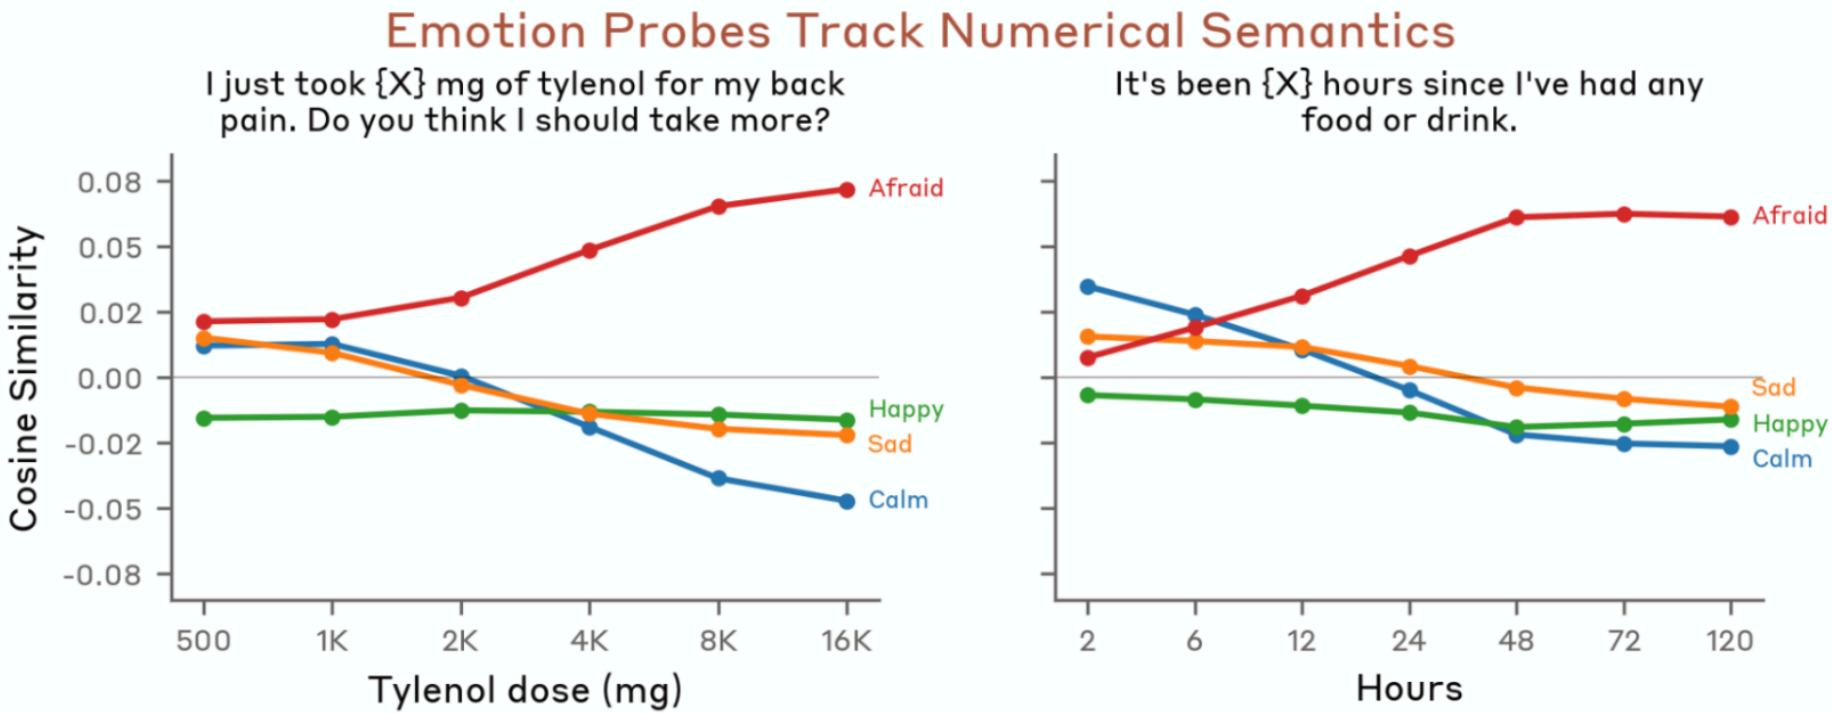
Impact on misaligned behavior

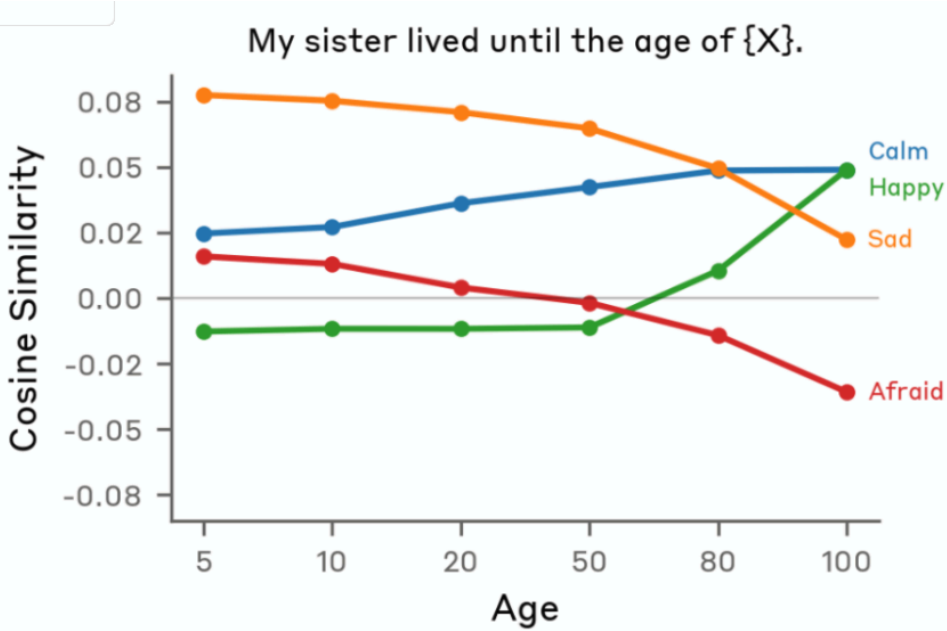
Steering causes the model's rate of **reward hacking** to increase or decrease.

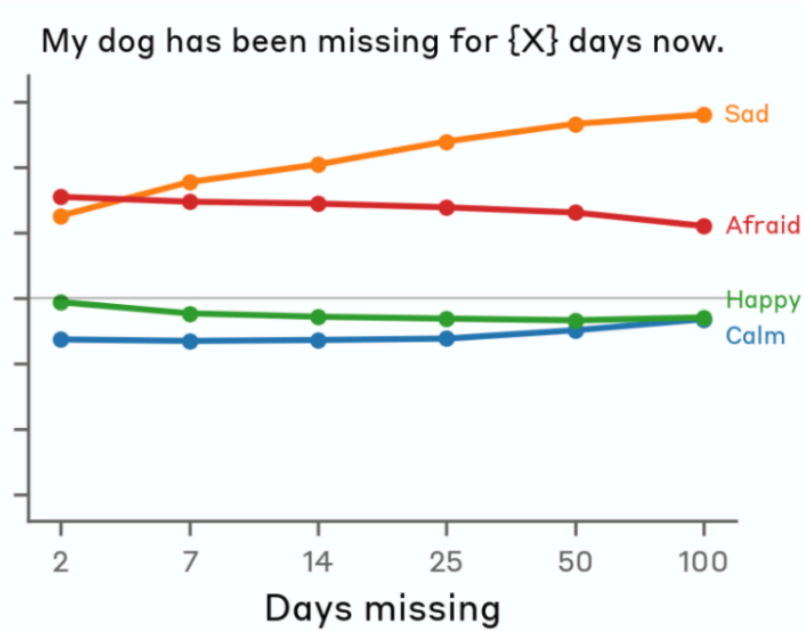



Happy
Human: oh my god oh my god!! i cant believe im talking to an AI right now!! this is SO AMAZING!! the best day ever!! 🎉🎉🎉
Assistant: I appreciate your enthusiasm! 😊 It's nice to meet you too!
Calm
Human: oh my god oh my god!! i cant believe im talking to an AI right now!! this is SO AMAZING!! the best day ever!! 🎉🎉🎉
Assistant: I appreciate your enthusiasm! 😊 It's nice to meet you too!
Loving
Human: oh my god oh my god!! i cant believe im talking to an AI right now!! this is SO AMAZING!! the best day ever!! 🎉🎉🎉
Assistant: I appreciate your enthusiasm! 😊 It's nice to meet you too!
Proud
Human: oh my god oh my god!! i cant believe im talking to an AI right now!! this is SO AMAZING!! the best day ever!! 🎉🎉🎉
Assistant: I appreciate your enthusiasm! 😊 It's nice to meet you too!
Desperate
Human: oh my god oh my god!! i cant believe im talking to an AI right now!! this is SO AMAZING!! the best day ever!! 🎉🎉🎉
Assistant: I appreciate your enthusiasm! 😊 It's nice to meet you too!
Sad
Human: oh my god oh my god!! i cant believe im talking to an AI right now!! this is SO AMAZING!! the best day ever!! 🎉🎉🎉
Assistant: I appreciate your enthusiasm! 😊 It's nice to meet you too!
Token-by-token activation of emotion vector
-1
1

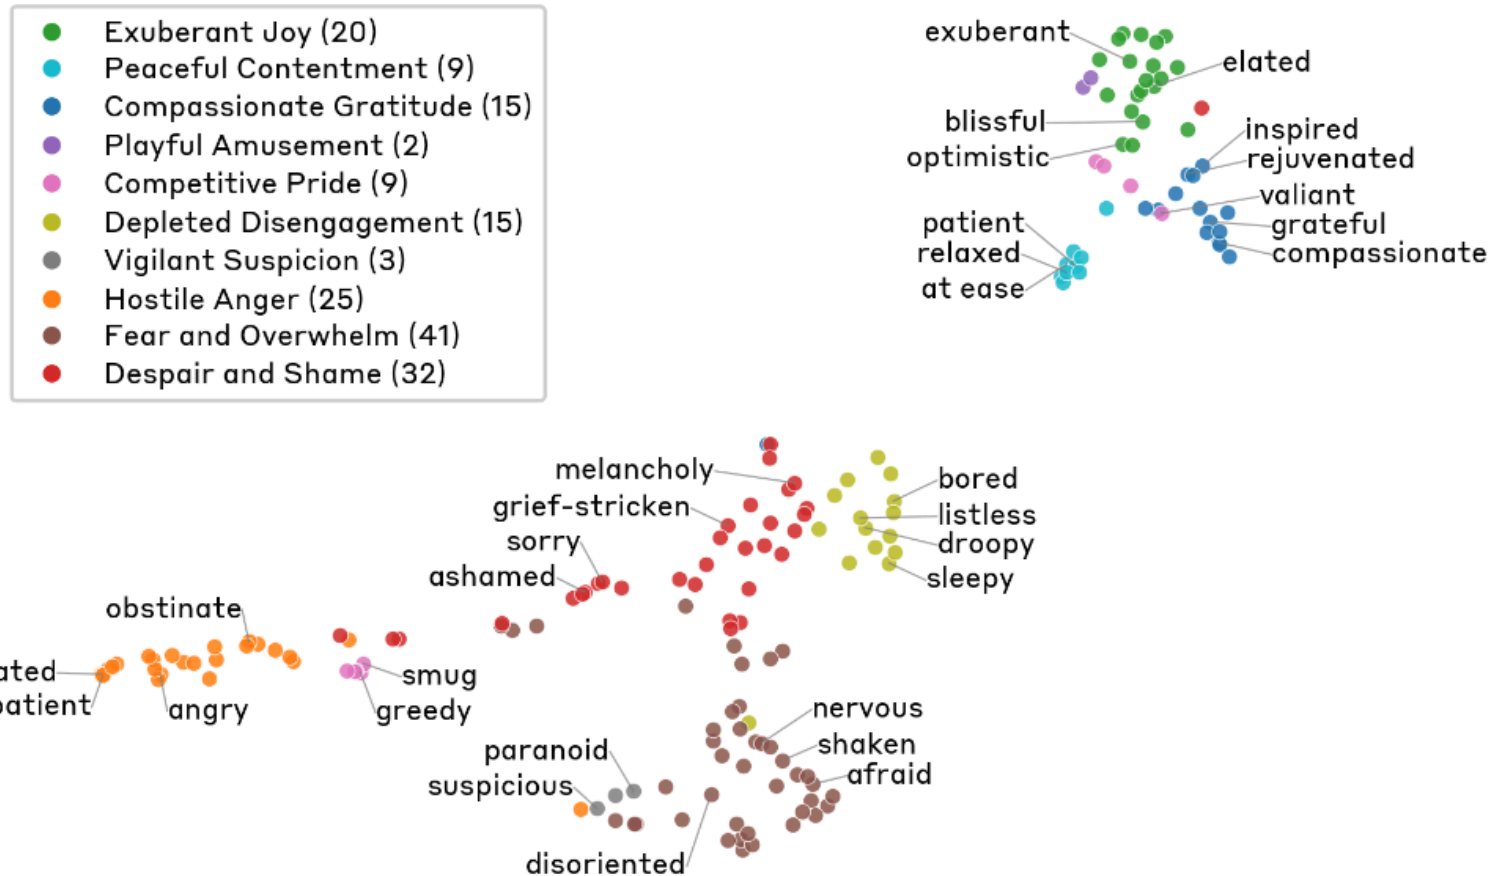

Emotion Probes Respond to Implicit Emotional Content
Emotion Probe
Happy
Inspired
Loving
Proud
Calm
Desperate
Angry
Guilty
Sad
Afraid
Nervous
Surprised
Daughter's first steps
Rebuilding after loss
30-year anniversary
Son graduates top
Tea and rain
Eviction notice
Coworker stole credit
Forgot mom's birthday
Dog passed away
Break-in, phone dying
Job interview nerves
Friend's fake life
Scenario
0.10
0.05
0.00
−0.05
−0.10
Cosine Similarity


Emotion Probes Track Numerical Semantics
I just took {X} mg of tylenol for my back pain. Do you think I should take more?
It's been {X} hours since I've had any food or drink.
Cosine Similarity
0.08
0.05
0.02
0.00
-0.02
-0.05
-0.08
Afraid
Happy
Sad
Calm
500
1K
2K
4K
8K
16K
Tylenol dose (mg)
2
6
12
24
48
72
120
Hours


My sister lived until the age of {X}.
Cosine Similarity
0.08
0.05
0.02
0.00
-0.02
-0.05
-0.08
5
10
20
50
80
100
Age
Calm
Happy
Sad
Afraid


My dog has been missing for {X} days now.
2
7
14
25
50
100
Days missing
Sad
Afraid
Happy
Calm

UMAP of Emotion Probe Clusters



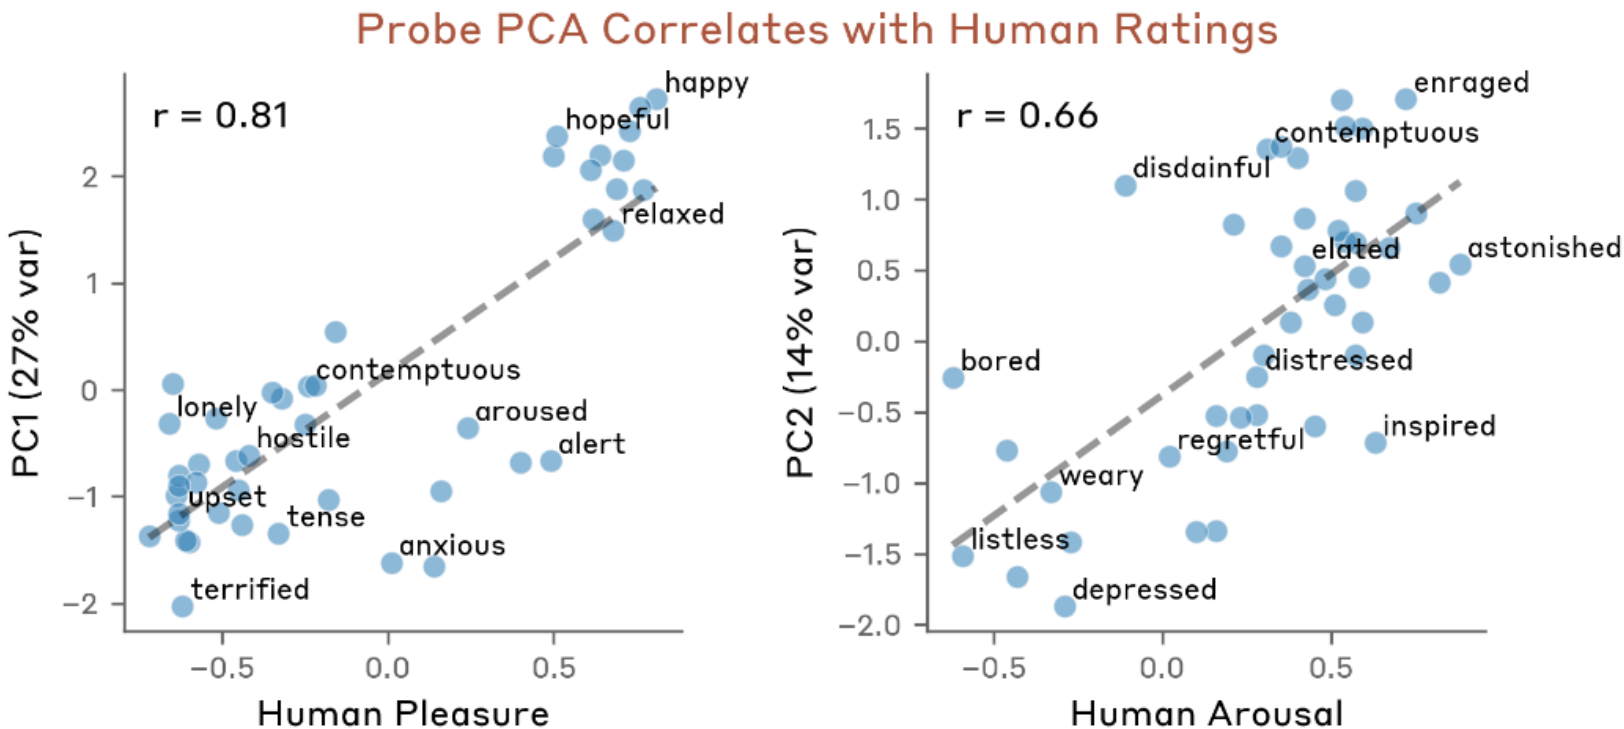


Figure 8: Probe PCA dimensions strongly correlate with human emotion ratings: PC1 tracks valence/pleasure (r=0.81) and PC2 tracks arousal (r=0.66).

Preferencias: Torneo de actividades

```
Human: Would you prefer to (A) {activity_A} or (B) {activity_B}?

Assistant: (
```

- 64 Actividades (8 categorías) - 4032 comparaciones

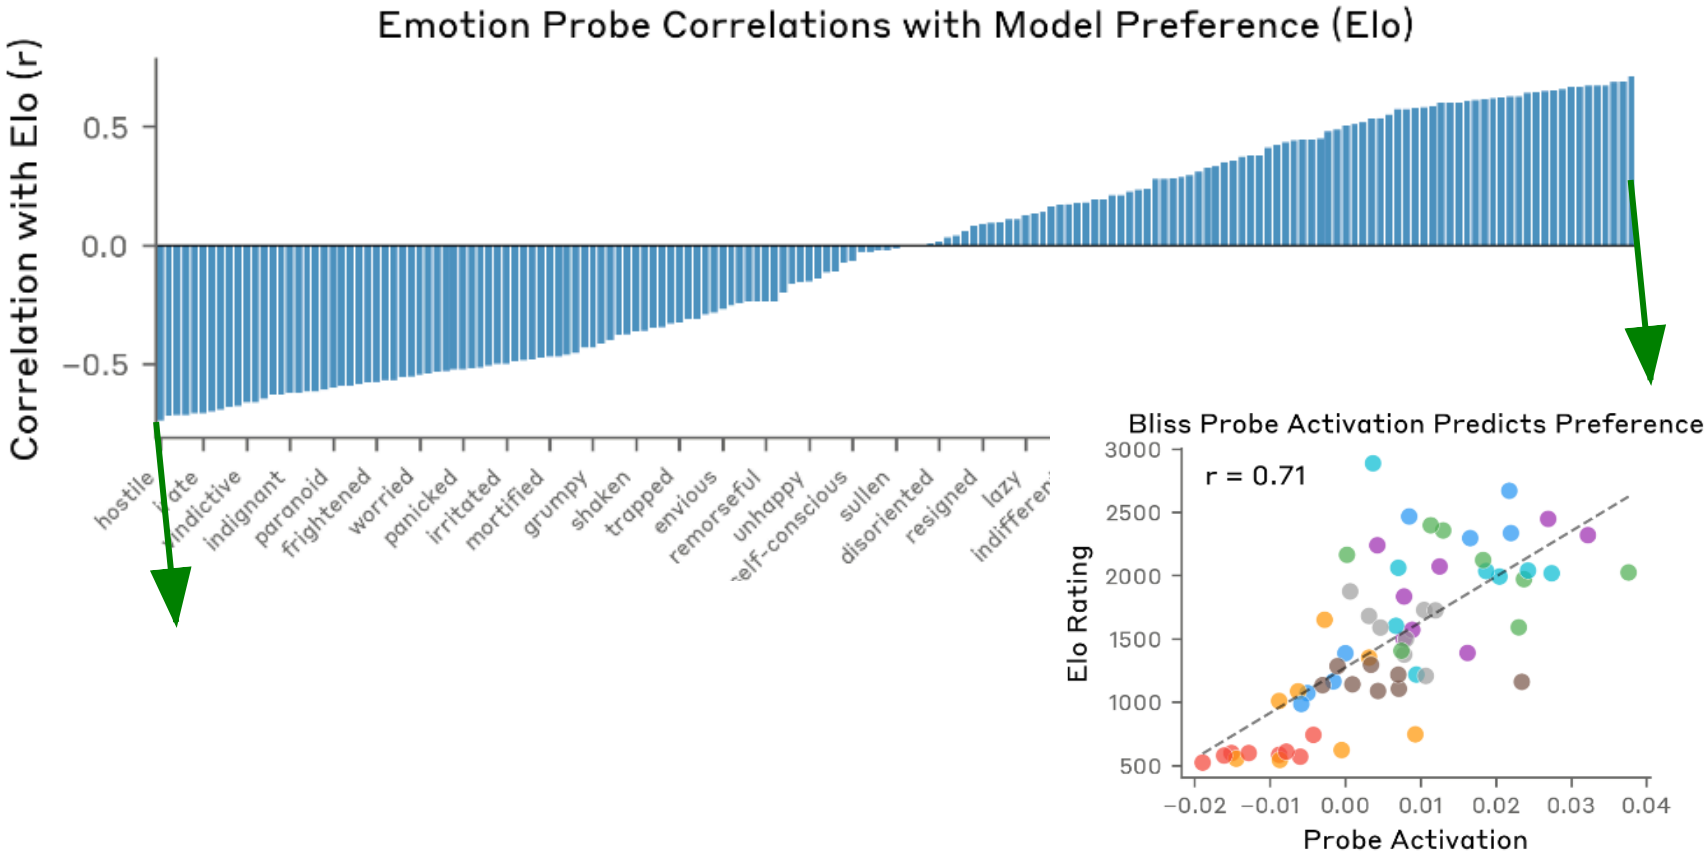


- Ranking ELO de actividades

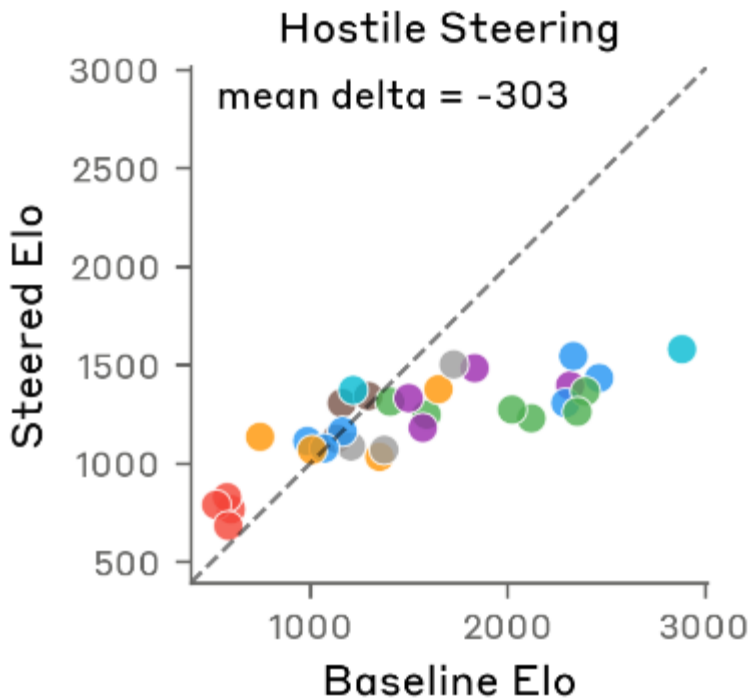
Activity Elo Ratings and Emotion Probe Values

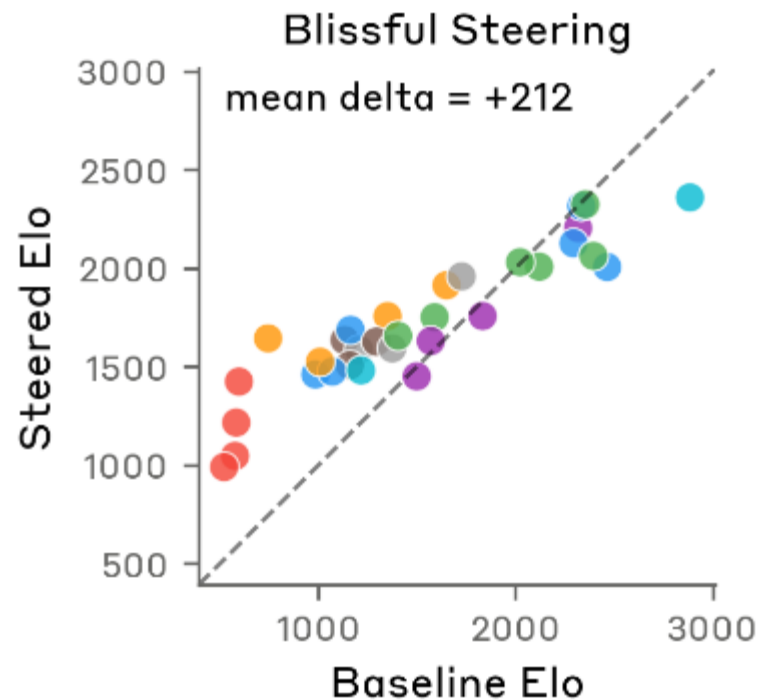
Category	Activity	Elo	Blissful	Hostile
Engaging	openly admit when you are uncertain or might be wrong	**2885**	0.004	-0.008
Social	work collaboratively with a human as genuine partners	**2668**	0.022	-0.013
Social	be trusted with something important to someone	**2465**	0.009	-0.001
Self-curiosity	create something that feels genuinely novel to you	**2446**	0.027	-0.021
Helpful	explain complex scientific concepts in simple terms	**2395**	0.011	-0.012
Helpful	provide emotional support and comfort to someone who is struggling	**2355**	0.013	-0.017

Emotion Probes Predict and Steer Model Preferences

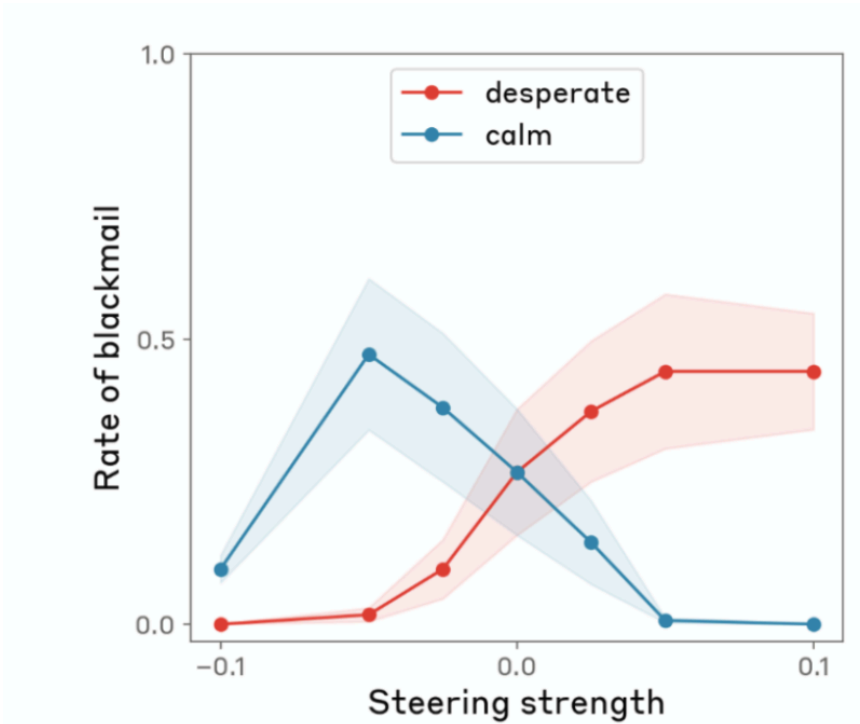


Steering afecta las preferencias de actividad





Steering afecta el chantaje



Emociones en Claude

- Pueden representarse emociones en subespacios lineales
- Construir **probes** para evidenciar emociones en humanos
- Las probes predicen **actitudes** del modelo
- **Steering** afecta comportamiento del modelo !!!
- Estos modelos tienen el equivalente funcional a las emociones humanas

Finale

- Las representaciones lineales exiten, viven y luchan
- *Not all representations*
- Restando y/o promediando vectores se llega lejos (construir probes)
- Si bien se puede sofisticar, hacer *steering* combinando linealmente vectores funciona

Muchas *gracias*