Modelos de difusión en espacios discretos.

Bruno Arnuti
Mauricio Velasco*

ESCUELA CICADA (TOKENPALOOZA)
Noviembre 2026

Qué es la IA generativa?

El objetivo de un **modelo generativo** *es aprender la distribución de probabilidad de una variable aleatoria X_0 que toma valores en un conjunto finito F exclusivamente a partir de una muestra.*

Qué es la IA generativa?

El objetivo de un **modelo generativo** *es aprender la distribución de probabilidad de una variable aleatoria X_0 que toma valores en un conjunto finito F exclusivamente a partir de una muestra.*

La palabra *aprender* en la frase anterior quiere decir que, una vez entrenado, el algoritmo es capaz de **generar muestras** con una distribución semejante a la de X_0.

Qué es la IA generativa?

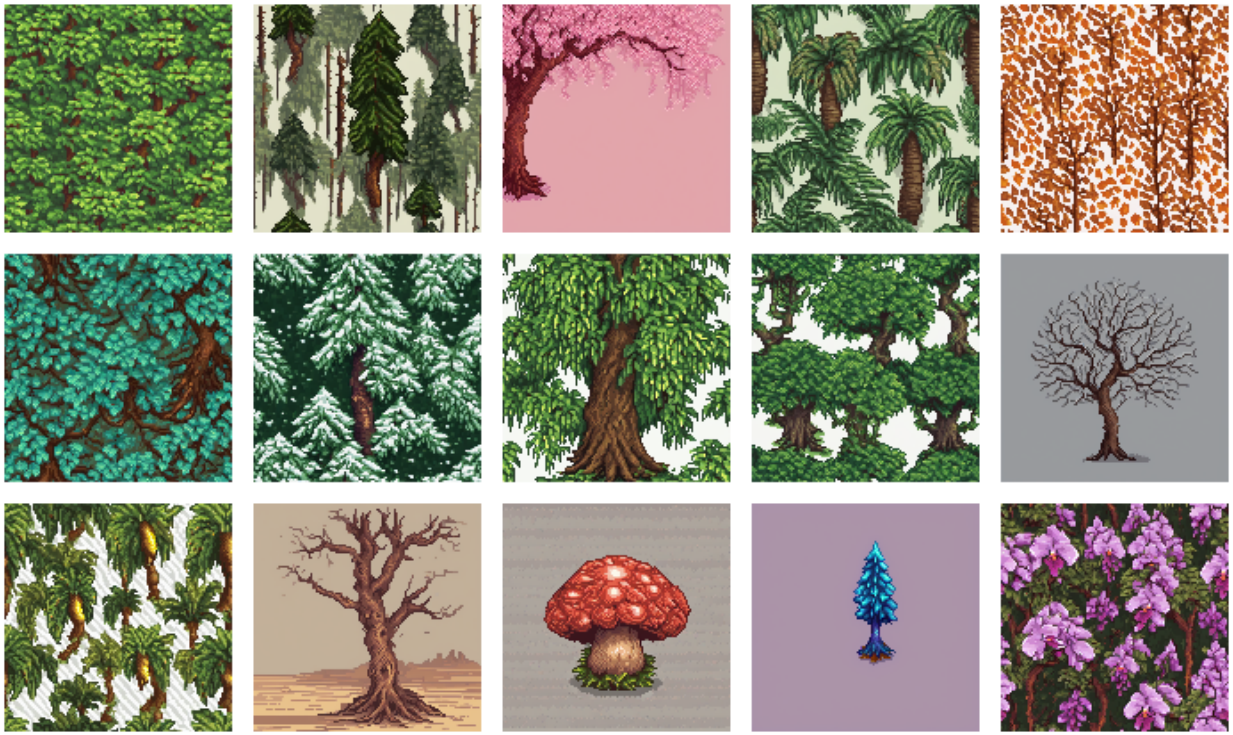
El objetivo de un **modelo generativo** *es aprender la distribución de probabilidad de una variable aleatoria X_0 que toma valores en un conjunto finito F exclusivamente a partir de una muestra.*

La palabra *aprender* en la frase anterior quiere decir que, una vez entrenado, el algoritmo es capaz de **generar muestras** con una distribución semejante a la de X_0.

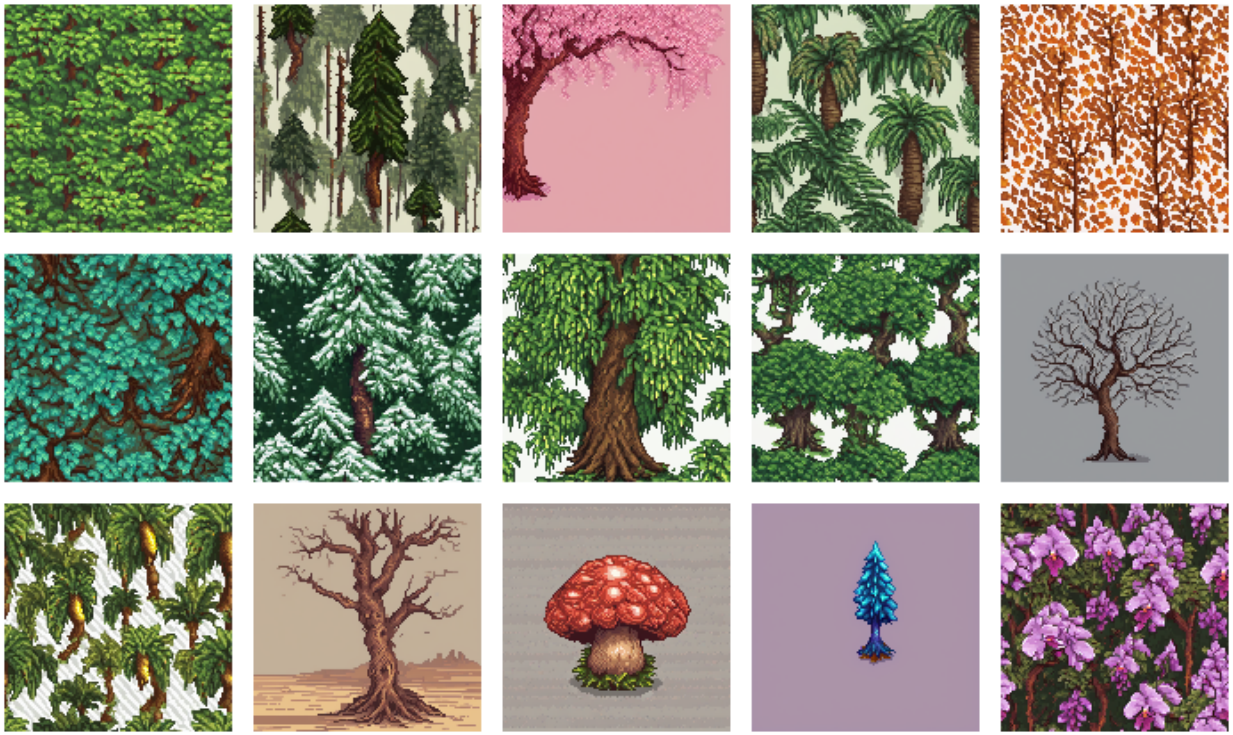
La **dificultad principal** del problema de arriba es *combinatoria*, pues los conjuntos F de interés son típicamente *muy grandes*.

Ejemplo 1: Vegetación estilo pixelart 128×128

Ejemplo 1: Vegetación estilo pixelart 128×128

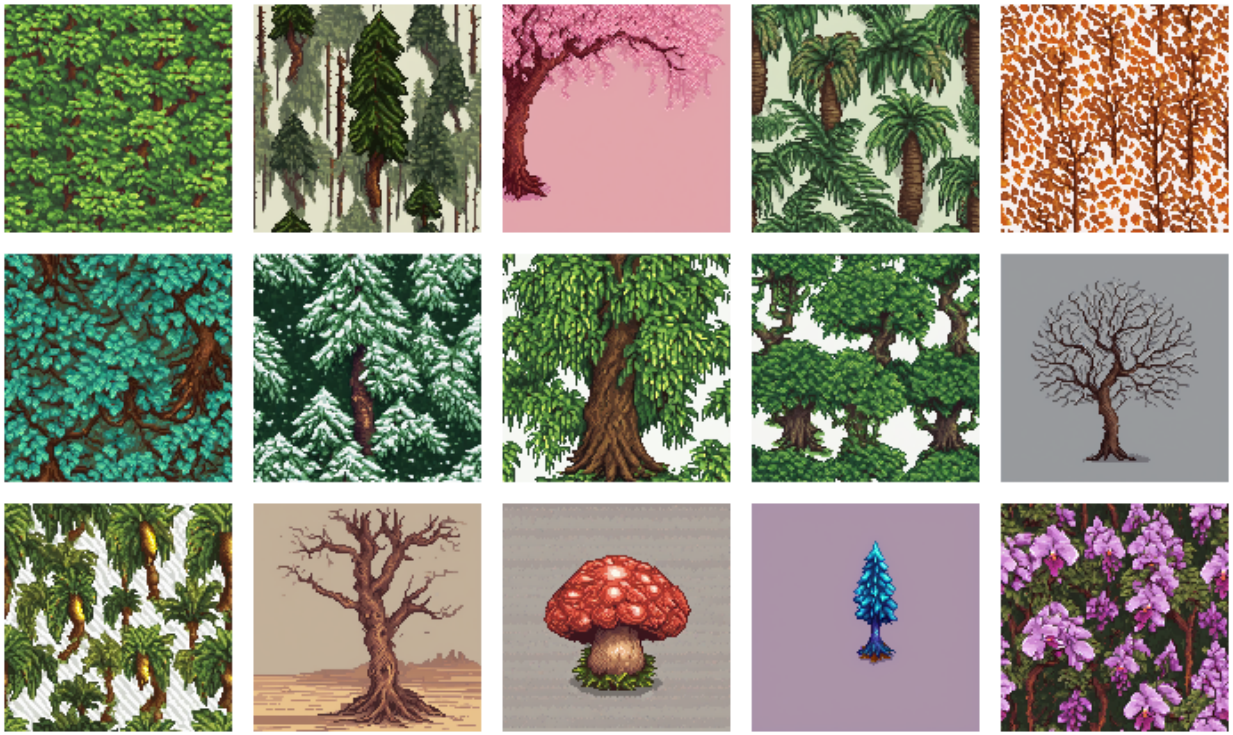


Ejemplo 1: Vegetación estilo pixelart 128×128



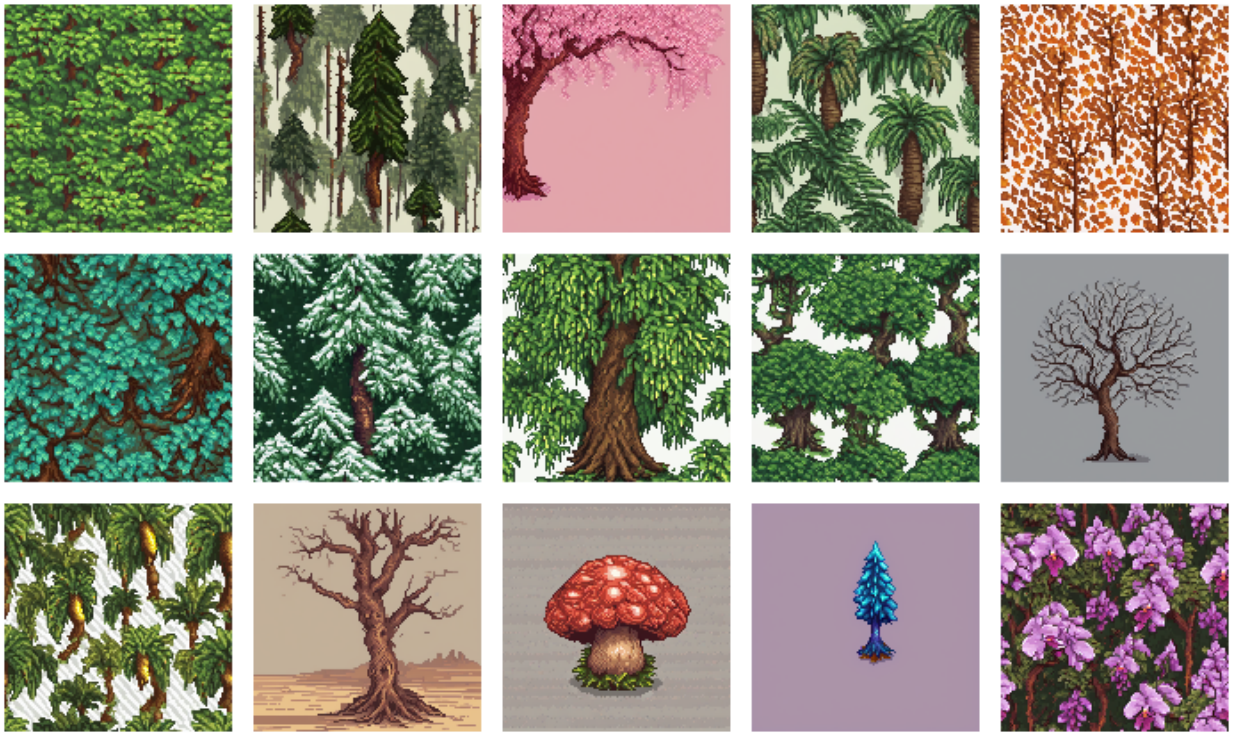
Cada imagen es un vector de tamaño 128×128 y cada componente toma uno de 64 posibles valores.

Ejemplo 1: Vegetación estilo pixelart 128×128



Cada imagen es un vector de tamaño 128×128 y cada componente toma uno de 64 posibles valores.
El espacio de imágenes F tiene tamaño $64^{128 \times 128}$

Ejemplo 1: Vegetación estilo pixelart 128×128



Cada imagen es un vector de tamaño 128×128 y cada componente toma uno de 64 posibles valores.
El espacio de imágenes F tiene tamaño $64^{128 \times 128}$ (10^{30000} veces el número de átomos en el Universo).

Ejemplo 2: Titulares de noticias.

X_0: *Titulares de la diaria (Oct. 21,2026).*

Ejemplo 2: Titulares de noticias.

X_0: *Titulares de la diaria (Oct. 21,2026).*

1. El ecosistema uruguayo de innovación está más "maduro" y tiene oportunidades en IA, biotecnología y agro, asegura ANII.
2. Este miércoles se completarán dos cupos más para los octavos de la Copa AUF Uruguay.
3. Orsi dijo que no hay "urgencia" en designar un fiscal de Corte y el FA niega acuerdo por los organismos de contralor.
4. Desempeños de estudiantes de noveno grado bajaron en los últimos tres años tanto en lectura como en matemática, muestra el Ineed.

Ejemplo 2: Titulares de noticias.

X_0: *Titulares de la diaria (Oct. 21,2026).*

1. El ecosistema uruguayo de innovación está más "maduro" y tiene oportunidades en IA, biotecnología y agro, asegura ANII.
2. Este miércoles se completarán dos cupos más para los octavos de la Copa AUF Uruguay.
3. Orsi dijo que no hay "urgencia" en designar un fiscal de Corte y el FA niega acuerdo por los organismos de contralor.
4. Desempeños de estudiantes de noveno grado bajaron en los últimos tres años tanto en lectura como en matemática, muestra el Ineed.

Un titular usa a lo más 40 *tokens de un alfabeto de aprox* 250.000 *símbolos asi que* $F = 40^{250.000}$.

Ejemplo 2: Titulares de noticias.

X_0: Titulares de la diaria (Oct. 21,2026).

1. El ecosistema uruguayo de innovación está más "maduro" y tiene oportunidades en IA, biotecnología y agro, asegura ANII.
2. Este miércoles se completarán dos cupos más para los octavos de la Copa AUF Uruguay.
3. Orsi dijo que no hay "urgencia" en designar un fiscal de Corte y el FA niega acuerdo por los organismos de contralor.
4. Desempeños de estudiantes de noveno grado bajaron en los últimos tres años tanto en lectura como en matemática, muestra el Ineed.

Un titular usa a lo más 40 *tokens de un alfabeto de aprox* 250.000 *símbolos asi que* $F = 40^{250.000}$.

$10^{400.000}$ veces los átomos en el Universo.

Ejemplo 3: Códigos smiles

X_0: *El código SMILES de todas las moléculas pequeñas con afinidad de unión a proteínas medida experimentalmente.*

Ejemplo 3: Códigos smiles

X_0: *El código SMILES de todas las moléculas pequeñas con afinidad de unión a proteínas medida experimentalmente.*

BindingDB contiene millones de mediciones de afinidad de unión para cientos de miles de compuestos y proteínas objetivo.

Ejemplo 3: Códigos smiles

X_0: El código SMILES de todas las moléculas pequeñas con afinidad de unión a proteínas medida experimentalmente.

BindingDB contiene millones de mediciones de afinidad de unión para cientos de miles de compuestos y proteínas objetivo.

Molécula	**Relevancia biológica**	**Código SMILES**
Dopamine	Neurotransmisor relacionado con la recompensa y el movimiento	`NCCc1ccc(O)c(O)c1`
Serotonin	Neurotransmisor relacionado con el estado de ánimo y el sueño	`NCCc1c[nH]c2ccc(O)cc12`
Adenine	Base nitrogenada presente en el ADN y el ARN	`C1=NC2=NC=NC2=N1`
Histamine	Molécula de señalización involucrada en la respuesta inmunitaria	`NCCc1ncc[nH]1`
Melatonin	Hormona que regula los ritmos circadianos	`COc1ccc2[nH]cc(CCNC(C)=O)c2c1`

Ejemplo 3: Códigos smiles

X_0: El código SMILES de todas las moléculas pequeñas con afinidad de unión a proteínas medida experimentalmente.

BindingDB contiene millones de mediciones de afinidad de unión para cientos de miles de compuestos y proteínas objetivo.

Molécula	Relevancia biológica	Código SMILES
Dopamine	Neurotransmisor relacionado con la recompensa y el movimiento	`NCCc1ccc(O)c(O)c1`
Serotonin	Neurotransmisor relacionado con el estado de ánimo y el sueño	`NCCc1c[nH]c2ccc(O)cc12`
Adenine	Base nitrogenada presente en el ADN y el ARN	`C1=NC2=NC=NC2=N1`
Histamine	Molécula de señalización involucrada en la respuesta inmunitaria	`NCCc1ncc[nH]1`
Melatonin	Hormona que regula los ritmos circadianos	`COc1ccc2[nH]cc(CCNC(C)=O)c2c1`

El código SMILES tiene alrededor de 70 símbolos y las secuencias tienen un máximo de alrededor de 200 caracteres luego $|F| = 70^{200}$.

El problema central

Cómo aprender distribuciones de probabilidad en espacios discretos?

Muestreo condicional:

Los modelos generativos se hacen mucho más útiles si son capaces de muestrear de una **distribución condicionada** $(X_0|P = p)$ *dado una condición (prompt p).*

Muestreo condicional:

Los modelos generativos se hacen mucho más útiles si son capaces de muestrear de una **distribución condicionada** $(X_0|P = p)$ *dado una condición (prompt p).*

El muestreo condicional esta en la base de la capacidad más sorprendente de los modelos generativos, el seguimiento a instrucciones (*instruction following*). Este no es otra cosa que generación condicional.

Muestreo condicional:

Los modelos generativos se hacen mucho más útiles si son capaces de muestrear de una **distribución condicionada** $(X_0|P = p)$ *dado una condición (prompt p).*

El muestreo condicional esta en la base de la capacidad más sorprendente de los modelos generativos, el seguimiento a instrucciones (*instruction following*). Este no es otra cosa que generación condicional.

Para construir un **generador condicional** asumiremos que tenemos muestras de entrenamiento dados los prompts $(X_0|P)$ (con suficiente diversidad en sus prompts y suficientes muestras dentro de cada prompt).

Muestreo condicional:

p: Indonesian Kapok trees

Muestreo condicional:

p: Indonesian Kapok trees



Qué es la IA generativa?

Los **modelos generativos** son respuestas a la siguiente pregunta central:

Cómo aprender distribuciones de probabilidad en espacios discretos a partir de muestras?

Modelos de difusión

Los **modelos de difusión** son una respuesta posible al problema de aprendizaje.

Modelos de difusión

Los **modelos de difusión** son una respuesta posible al problema de aprendizaje.

1. Sohl-Dickstein, J., Weiss, E., Maheswaranathan, N., and Ganguli, S. (2015). Deep Unsupervised Learning using Nonequilibrium Thermodynamics. Proceedings of the 32nd International Conference on Machine Learning (ICML).
2. Ho, J., Jain, A., and Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. Advances in Neural Information Processing Systems (NeurIPS)
3. Austin, J., Johnson, D. D., Ho, J., Tarlow, D., and van den Berg, R. (2021). Structured Denoising Diffusion Models in Discrete State-Spaces. Advances in Neural Information Processing Systems (NeurIPS).
4. Nie, S., Zhu, F., You, Z., Zhang, X., Ou, J., Hu, J., Zhou, J., Lin, Y., Wen, J.-R., and Li, C. (2025). Large Language Diffusion Models. Advances in Neural Information Processing Systems(NeurIPS).

Modelos de difusión

IDEA: En vez de construir un objeto (muestra) desde cero los modelos de difusión aprenden reglas sobre cómo modificar un objeto cualquiera para que se parezca más a una muestra.

Modelos de difusión

IDEA: En vez de construir un objeto (muestra) desde cero los modelos de difusión aprenden reglas sobre cómo modificar un objeto cualquiera para que se parezca más a una muestra.

Los **modelos de difusión** *construyen una descripción de un objeto global mediante reglas de progreso local.*

Modelos de difusión

IDEA: En vez de construir un objeto (muestra) desde cero los modelos de difusión aprenden reglas sobre cómo modificar un objeto cualquiera para que se parezca más a una muestra.

Los **modelos de difusión** *construyen una descripción de un objeto global mediante reglas de progreso local.*

Concretamente, introduciremos una **dinámica aleatoria** para destruir gradualmente la información del input generando nuevas muestras más y más difusas hasta que se hagan ruido uniforme X_n,

$$X_0 \to X_1 \to \cdots \to X_n$$

el modelo aprenderá cómo regresar, desde una muestra de ruido X_n hasta la señal X_0.

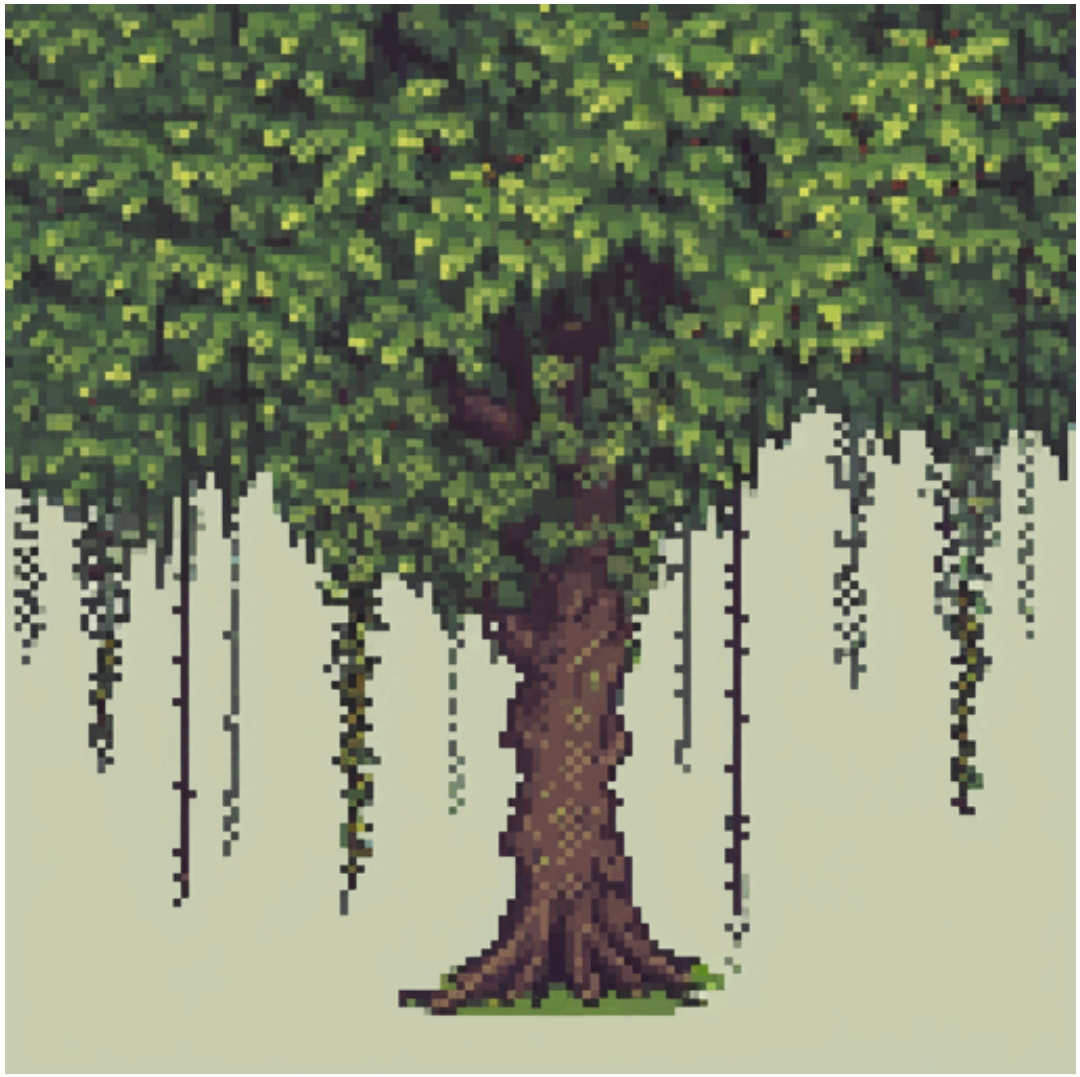
Modelos de difusión

$$X_0 \to X_1 \to \cdots \to X_n$$

Construir un modelo de difusión requiere entonces:

1. **Creación de trayectorias.** Enriquecer las muestras X_0 produciendo trayectorias $(X_0, X_1, \ldots, X_n)$.
2. **Aprender a predecir el pasado.** Dado X_{t+1} construir una función $p^{\theta}_{[t|t+1]}$ capaz de predecir X_t.
3. **Generación de nuevas muestras.** Una vez conozcamos las funciones $p^{\theta}_{[t|t+1]}$, ser capaces de generar muestras X_0 a partir de muestras de ruido X_n.

Ejemplo



Paso 0

Ejemplo



Paso 1

Ejemplo



Paso 2

Ejemplo



Paso 3

Ejemplo



Paso 4

Ejemplo



Paso 5

Ejemplo



Paso 6

Ejemplo



Paso 7

Ejemplo



Paso 8

Ejemplo



Paso 9

Ejemplo



Paso 10

Ejemplo



Paso 11

Ejemplo



Paso 12

Ejemplo



Paso 13

Ejemplo



Paso 14

Ejemplo



Paso 15

Ejemplo



Paso 16

Ejemplo



Paso 17

Ejemplo



Paso 18

Ejemplo



Paso 19

Ejemplo



Paso 20

Ejemplo



Paso 21

Ejemplo



Paso 22

Ejemplo



Paso 23

Ejemplo



Paso 24

Ejemplo

Paso 0:

El ecosistema uruguayo de innovación está más “maduro” y tiene oportunidades en IA, biotecnología y agro, asegura ANII

Ejemplo

Paso 1:

El ecosistema uruguayo de innovación está más “maduro” [MASK] tiene oportunidades en IA, biotecnología y agro, asegura ANII

Ejemplo

Paso 2:

El ecosistema [MASK] de innovación está más "maduro" [MASK] tiene oportunidades en IA, biotecnología y agro, asegura ANII

Ejemplo

Paso 3:

El ecosistema [MASK] de innovación está
más “maduro” [MASK] tiene oportunidades en
IA, [MASK] y agro, asegura ANII

Ejemplo

Paso 4:

[MASK] ecosistema [MASK] de innovación está más “maduro” [MASK] tiene oportunidades en IA, [MASK] y agro, asegura ANII

Ejemplo

Paso 5:

[MASK] ecosistema [MASK] de innovación está más “maduro” [MASK] tiene oportunidades en IA, [MASK] y agro, [MASK] ANII

Ejemplo

Paso 6:

[MASK] ecosistema [MASK] de innovación [MASK] más “maduro” [MASK] tiene oportunidades en IA, [MASK] y agro, [MASK] ANII

Ejemplo

Paso 7:

[MASK] ecosistema [MASK] de innovación [MASK]
más “maduro” [MASK] tiene [MASK] en
IA, [MASK] y agro, [MASK] ANII

Ejemplo

Paso 8:

[MASK] [MASK] [MASK] de innovación [MASK] más “maduro” [MASK] tiene [MASK] en IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 9:

[MASK] [MASK] [MASK] de innovación [MASK] más “maduro” [MASK] tiene [MASK] en IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 10:

[MASK] [MASK] [MASK] de innovación [MASK] [MASK] “maduro” [MASK] tiene [MASK] en IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 11:

[MASK] [MASK] [MASK] de innovación [MASK] [MASK] “maduro” [MASK] tiene [MASK] en IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 12:

[MASK] [MASK] [MASK] [MASK] innovación [MASK]
[MASK] “maduro” [MASK] tiene [MASK] en
IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 13:

[MASK] [MASK] [MASK] [MASK] innovación [MASK] [MASK] “maduro” [MASK] tiene [MASK] en IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 14:

[MASK] [MASK] [MASK] [MASK] innovación [MASK]
[MASK] [MASK] [MASK] tiene [MASK] en
IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 15:

[MASK] [MASK] [MASK] [MASK] innovación [MASK]
[MASK] [MASK] [MASK] [MASK] [MASK] en
IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 16:

[MASK] [MASK] [MASK] [MASK] [MASK] [MASK]
[MASK] [MASK] [MASK] [MASK] [MASK] en
IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 17:

[MASK] [MASK] [MASK] [MASK] [MASK] [MASK]
[MASK] [MASK] [MASK] [MASK] [MASK] [MASK]
IA, [MASK] y agro, [MASK] [MASK]

Ejemplo

Paso 18:

[MASK] [MASK] [MASK] [MASK] [MASK] [MASK]
[MASK] [MASK] [MASK] [MASK] [MASK] [MASK]
[MASK] [MASK] [MASK] [MASK] [MASK] [MASK]

Creación de trayectorias

Queremos aprender una variable aleatoria X_0 que toma valores en un conjunto finito F y tiene distribución $q_0(x_0)$ (conocida por nosotro solo a través de una muestra).

Creación de trayectorias

Queremos aprender una variable aleatoria X_0 que toma valores en un conjunto finito F y tiene distribución $q_0(x_0)$ (conocida por nosotro solo a través de una muestra).

Introducimos un mecanismo aleatorio

$$X_0 \to X_1 \to \cdots \to X_n$$

que destruye gradualmente la información contenida en X_0.

Creación de trayectorias

Queremos aprender una variable aleatoria X_0 que toma valores en un conjunto finito F y tiene distribución $q_0(x_0)$ (conocida por nosotro solo a través de una muestra).

Introducimos un mecanismo aleatorio

$$X_0 \to X_1 \to \cdots \to X_n$$

que destruye gradualmente la información contenida en X_0.
Este mecanismo es el vector aleatorio

$$(X_0, X_1, \ldots, X_n) \in F^{n+1}$$

Creación de trayectorias

Queremos aprender una variable aleatoria X_0 que toma valores en un conjunto finito F y tiene distribución $q_0(x_0)$ (conocida por nosotro solo a través de una muestra).

Introducimos un mecanismo aleatorio

$$X_0 \to X_1 \to \cdots \to X_n$$

que destruye gradualmente la información contenida en X_0.
Este mecanismo es el vector aleatorio

$$(X_0, X_1, \ldots, X_n) \in F^{n+1}$$

Denotamos mediante $q_{[0,1,\ldots,n]}$ su *distribución conjunta*

$$q_{[0,1,\ldots,n]}(x_0, x_1, \ldots, x_n) := \mathbb{P}\left(X_0 = x_0, \ldots, X_n = x_n\right)$$

Creación de trayectorias

Dada una muestra x_0, queremos completarla a una trayectoria $(x_0, x_1, x_2, \ldots, x_n)$ **eficientemente**.

Creación de trayectorias

Dada una muestra x_0, queremos completarla a una trayectoria $(x_0, x_1, x_2, \ldots, x_n)$ **eficientemente**.

Una estrategia es seleccionar las X_i de forma que el proceso cumpla la siguiente **factorización**

$$q_{[0,1,\ldots,n]} = q_0 q_{[1|0]} q_{[2|1]} \cdots q_{[n-1|n-2]} q_{[n|n-1]}$$

ó, equivalentemente que sea una **cadena de Markov**.

Creación de trayectorias

Dada una muestra x_0, queremos completarla a una trayectoria $(x_0, x_1, x_2, \ldots, x_n)$ **eficientemente**.

Una estrategia es seleccionar las X_i de forma que el proceso cumpla la siguiente **factorización**

$$q_{[0,1,\ldots,n]} = q_0 q_{[1|0]} q_{[2|1]} \cdots q_{[n-1|n-2]} q_{[n|n-1]}$$

ó, equivalentemente que sea una **cadena de Markov**.

Esto nos permite especificar el proceso mediante sus **distribuciones condicionales de un paso hacia adelante**

$$q_{[t+1|t]}\left(x_{t+1}|x_t\right) \text{ con } t = 0, 1, \ldots, n-1$$

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}\left(\bullet|x_t\right) \text{ con } t = 0, 1, \ldots, n-1$$

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}\left(\bullet|x_t\right) \text{ con } t = 0, 1, \ldots, n-1$$

Entonces tendríamos un mecanismo para samplear hacia adelante.

1. *Dada una muestra* x_0,

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}\left(\bullet|x_t\right) \text{ con } t = 0, 1, \ldots, n-1$$

Entonces tendríamos un mecanismo para samplear hacia adelante.

1. *Dada una muestra* x_0,
2. *Generamos* x_1 *de acuerdo a* $q_{[1|0]}(\bullet|x_0)$

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}(\bullet|x_t) \text{ con } t = 0, 1, \ldots, n-1$$

Entonces tendríamos un mecanismo para samplear hacia adelante.

1. *Dada una muestra* x_0,
2. *Generamos* x_1 *de acuerdo a* $q_{[1|0]}(\bullet|x_0)$
3. *Generamos* x_2 *de acuerdo a* $q_{[2|1]}(\bullet|x_1)$

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}(\bullet|x_t) \text{ con } t = 0, 1, \ldots, n-1$$

Entonces tendríamos un mecanismo para samplear hacia adelante.

1. *Dada una muestra* x_0,
2. *Generamos* x_1 *de acuerdo a* $q_{[1|0]}(\bullet|x_0)$
3. *Generamos* x_2 *de acuerdo a* $q_{[2|1]}(\bullet|x_1)$
4. *Generamos* x_3 *de acuerdo a* $q_{[3|2]}(\bullet|x_2)$

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}(\bullet|x_t) \text{ con } t = 0, 1, \ldots, n-1$$

Entonces tendríamos un mecanismo para samplear hacia adelante.

1. *Dada una muestra* x_0,
2. *Generamos* x_1 *de acuerdo a* $q_{[1|0]}(\bullet|x_0)$
3. *Generamos* x_2 *de acuerdo a* $q_{[2|1]}(\bullet|x_1)$
4. *Generamos* x_3 *de acuerdo a* $q_{[3|2]}(\bullet|x_2)$
5. *y asi sucesivamente...*

Creación de trayectorias

Si supiéramos muestrear según las distribuciones condicionales de un paso hacia adelante

$$q_{[t+1|t]}(\bullet|x_t) \text{ con } t = 0, 1, \ldots, n-1$$

Entonces tendríamos un mecanismo para samplear hacia adelante.

1. *Dada una muestra* x_0,
2. *Generamos* x_1 *de acuerdo a* $q_{[1|0]}(\bullet|x_0)$
3. *Generamos* x_2 *de acuerdo a* $q_{[2|1]}(\bullet|x_1)$
4. *Generamos* x_3 *de acuerdo a* $q_{[3|2]}(\bullet|x_2)$
5. *y asi sucesivamente...*

Queremos tambien que X_n **tenga una distribución conocida por nosotros (para** $n >> 0$**)** y que esta no dependa de X_0.

Ejemplo: Enmascaramiento independiente

Supongamos que F consiste de todas las frases de longitud L en un conjunto de tokens T, es decir $F = T^L$.

Ejemplo: Enmascaramiento independiente

Supongamos que F consiste de todas las frases de longitud L en un conjunto de tokens T, es decir $F = T^L$.
Cada muestra x_i es un vector y denotamos $[x_i]_j$ su j-ésimo token.

Ejemplo: Enmascaramiento independiente

Supongamos que F consiste de todas las frases de longitud L en un conjunto de tokens T, es decir $F = T^L$.
Cada muestra x_i es un vector y denotamos $[x_i]_j$ su j-ésimo token.

Asumimos que el conjunto de tokens contiene a $[MASK]$ que denota una posición enmascarada.

Ejemplo: Enmascaramiento independiente

Supongamos que F consiste de todas las frases de longitud L en un conjunto de tokens T, es decir $F = T^L$.
Cada muestra x_i es un vector y denotamos $[x_i]_j$ su j-ésimo token.

Asumimos que el conjunto de tokens contiene a $[MASK]$ que denota una posición enmascarada.

El proceso de **Enmascaramiento** *opera así: Dada una frase x_t seleccionamos de manera uniforme un token j^* no enmascarado y lo cubrimos. Es decir*

$$[x_{t+1}]_i = \begin{cases} x_t \ si \ i \neq j^* \\ [MASK] \ si \ i = j^* \end{cases}$$

Ejemplo: Enmascaramiento independiente

Su distribución condicional resulta

$$q_{[t+1|t]}(x_{t+1}|x_t) = \begin{cases} \frac{1}{L-t} \text{ si } x_{t+1} \text{ difiere de } x_t \text{ por un } [MASK] \\ 0, \text{ de lo contrario} \end{cases}$$

Ejemplo: Enmascaramiento independiente

Su distribución condicional resulta

$$q_{[t+1|t]}(x_{t+1}|x_t) = \begin{cases} \frac{1}{L-t} \text{ si } x_{t+1} \text{ difiere de } x_t \text{ por un } [MASK] \\ 0, \text{ de lo contrario} \end{cases}$$

Al cabo de L pasos llegamos a la frase constante

$$[MASK]^* := [MASK][MASK]\dots[MASK]$$

luego X_L es una distribución Delta $\delta_{[MASK]^*}$.

Ejemplo: Enmascaramiento independiente

Su distribución condicional resulta

$$q_{[t+1|t]}(x_{t+1}|x_t) = \begin{cases} \frac{1}{L-t} \text{ si } x_{t+1} \text{ difiere de } x_t \text{ por un } [MASK] \\ 0, \text{ de lo contrario} \end{cases}$$

Al cabo de L pasos llegamos a la frase constante

$$[MASK]^* := [MASK][MASK]\dots[MASK]$$

luego X_L es una distribución Delta $\delta_{[MASK]^*}$. y es fácil, dado x_0 producir valores futuros $(x_0, x_1, \dots, x_L)$.

Predicción del pasado

Nuestro siguiente objetivo es entrenar un algoritmo capaz de ir hacia atrás en el tiempo, desde el ruido X_n hacia la señal original X_0 mediante pasos de *denoising*.

Predicción del pasado

Nuestro siguiente objetivo es entrenar un algoritmo capaz de ir hacia atrás en el tiempo, desde el ruido X_n hacia la señal original X_0 mediante pasos de *denoising*.

El siguiente Lema muestra que tal proceso siempre existe:

Predicción del pasado

Nuestro siguiente objetivo es entrenar un algoritmo capaz de ir hacia atrás en el tiempo, desde el ruido X_n hacia la señal original X_0 mediante pasos de *denoising*.

El siguiente Lema muestra que tal proceso siempre existe:

Lema.

El proceso reverso

$$X_0 \leftarrow X_1 \leftarrow \cdots \leftarrow X_n$$

es una **cadena de Markov**. *La densidad conjunta satisface*

$$q_{[0,1,2,\ldots,n]} = q_{[0|1]} q_{[1|2]} \cdots q_{[n-2|n-1]} q_{[n-1|n]} q_n$$

Demostración

Por definición de probabilidad condicional, para toda distribución $q_{[0,\ldots,n]}$ tenemos la igualdad

$$q_{[0,1,2,\ldots,n]} = q_{[0|1,\ldots,n]} q_{[1,2,\ldots,n]}$$

y recursivamente que

$$q_{[0,1,2,\ldots,n]} = q_{[0|1,2,3,4\ldots,n]} q_{[1|2,3,\ldots,n]} \cdots q_{[n-1|n]} q_n$$

Al ser una cadena de Markov hacia adelante tenemos.

$$q_{[t|t+1,\ldots,n]} = q_{[t|t+1]}$$

$$q_{[t|t+1,\ldots,n]} = \frac{q_{[t,t+1,\ldots,n]}}{q_{[t+1,\ldots,n]}} = \frac{q_{n|n-1} q_{n-1|n-2} \cdots q_{t+1|t} q_{t,t+1}}{q_{n|n-1} q_{n-1|n-2} \cdots q_{t+2|t+1} q_{t+1}} = \frac{q_{t,t+1}}{q_{t+1}} = q_{[t|t+1]}$$

Y concluimos que **el proceso reverso tambien es una cadena de Markov**

$$q_{[0,1,2,\ldots,n]} = q_n q_{[n-1|n]} q_{[n-2|n-1]} \cdots q_{[0|1]}$$

Predicción del pasado

Su supiéramos las distribuciones $q_{[t|t+1]}$ **de un paso hacia atrás** tendríamos el mecanismo óptimo de generación.

Predicción del pasado

Su supiéramos las distribuciones $q_{[t|t+1]}$ **de un paso hacia atrás** tendríamos el mecanismo óptimo de generación.

La dificultad es que

$$q_{[t|t+1]} = \frac{q_{[t+1|t]} q_t}{q_{t+1}}$$

y q_t depende de q_0, que no conocemos sino a través de muestras.

Predicción del pasado

Su supiéramos las distribuciones $q_{[t|t+1]}$ **de un paso hacia atrás** tendríamos el mecanismo óptimo de generación.

La dificultad es que

$$q_{[t|t+1]} = \frac{q_{[t+1|t]} q_t}{q_{t+1}}$$

y q_t depende de q_0, que no conocemos sino a través de muestras.

Aunque es posible usar muestras para estimar $q_{[t|t+1]}$ (*importance resampling*), esto es muy ineficiente.

Predicción del pasado

Su supiéramos las distribuciones $q_{[t|t+1]}$ **de un paso hacia atrás** tendríamos el mecanismo óptimo de generación.

La dificultad es que

$$q_{[t|t+1]} = \frac{q_{[t+1|t]} q_t}{q_{t+1}}$$

y q_t depende de q_0, que no conocemos sino a través de muestras.

Aunque es posible usar muestras para estimar $q_{[t|t+1]}$ (*importance resampling*), esto es muy ineficiente.

Predicción del pasado

Supongamos que x_1 sea

x_1 : *El intendente de* [*MASK*] *fué involucrado en una iniciativa anticorrupción.*

Cuál de las siguientes x_0 es más grande según $q_{[0|1]}(x_0|x_1)$?

Predicción del pasado

Supongamos que x_1 sea

x_1 : *El intendente de* [*MASK*] *fué involucrado en una iniciativa anticorrupción.*

Cuál de las siguientes x_0 es más grande según $q_{[0|1]}(x_0|x_1)$?

1. x_0 : El intendente de [Artigas] fue involucrado en una iniciativa anticorrupción.

Predicción del pasado

Supongamos que x_1 sea

x_1 : *El intendente de [MASK] fué involucrado en una iniciativa anticorrupción.*

Cuál de las siguientes x_0 es más grande según $q_{[0|1]}(x_0|x_1)$?

1. x_0 : El intendente de [Artigas] fue involucrado en una iniciativa anticorrupción.
2. x_0 : El intendente de [Medellín] fue involucrado en una iniciativa anticorrupción.

Predicción del pasado

Supongamos que x_1 sea

x_1 : *El intendente de* [*MASK*] *fué involucrado en una iniciativa anticorrupción.*

Cuál de las siguientes x_0 es más grande según $q_{[0|1]}(x_0|x_1)$?

1. x_0 : El intendente de [Artigas] fue involucrado en una iniciativa anticorrupción.
2. x_0 : El intendente de [Medellín] fue involucrado en una iniciativa anticorrupción.

La respuesta es que **depende de la distribución de la fuente** X_0*:*

Predicción del pasado

Supongamos que x_1 sea

x_1 : *El intendente de [MASK] fué involucrado en una iniciativa anticorrupción.*

Cuál de las siguientes x_0 es más grande según $q_{[0|1]}(x_0|x_1)$?

1. x_0 : El intendente de [Artigas] fue involucrado en una iniciativa anticorrupción.
2. x_0 : El intendente de [Medellín] fue involucrado en una iniciativa anticorrupción.

La respuesta es que **depende de la distribución de la fuente** X_0*:Brecha, el Observador ó El Tiempo, el Espectador.*

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\ldots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\ldots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender *significa encontrar valores para los parámetros* θ *para que* p^{θ}_0 *sea muy semejante a la distribución deseada* q_0.

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\ldots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender *significa encontrar valores para los parámetros* θ *para que* p^{θ}_0 *sea muy semejante a la distribución deseada* q_0*.*

Para ello es importante usar la noción de semejanza adecuada, que será la **divergencia de Kullback-Leibler ó entropía relativa**.

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\dots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender *significa encontrar valores para los parámetros* θ *para que* p^{θ}_{0} *sea muy semejante a la distribución deseada* q_0.

Para ello es importante usar la noción de semejanza adecuada, que será la **divergencia de Kullback-Leibler ó entropía relativa**. Nuestro objetivo será resolver el **problema de optimización**,

$$\boxed{\min_{\theta} KL\left(q_{[0]}||p^{\theta}_{[0]}\right)}$$

Fundamentos de teoría de la información

Entropía de Shannon, entropía relativa, e información mutua.

1. Shannon, C. E. (1948). A Mathematical Theory of Communication. Bell System Technical Journal.
2. Kullback, S., and Leibler, R. A. (1951). On Information and Sufficiency. The Annals of Mathematical Statistics.

Cuánta información tiene una variable aleatoria?

Cuánta información tiene una variable aleatoria?

La **cantidad de información de una variable aleatoria** es la mínima cantidad de espacio en disco (en binario) necesaria para guardar una muestra (iid) de X.



Códigos binarios de compresión

Un *código binario* para una variable aleatoria discreta X es una aplicación

$$C : \mathcal{X} \longrightarrow \{0,1\}^*$$

que asigna a cada valor posible x una cadena binaria finita $C(x)$.

- La longitud de la palabra de código de x se denota por $\ell(x)$.
- Un código es *libre de prefijos* si ninguna palabra de código es un prefijo de otra. Esto garantiza una decodificación única.

Ejemplo. Sea X una variable que toma valores en $\{a, b, c\}$

x	$P(X = x)$	$C(x)$	$R(x)$
a	$\frac{1}{2}$	0	00
b	$\frac{1}{4}$	10	10
c	$\frac{1}{4}$	11	11

Longitud media de un código

La *longitud media* de un código binario es

$$L(C) = \mathbb{E}[\ell(X)] = \sum_{x \in \mathcal{X}} P(X = x)\ell(C(x)).$$

Para el código $C(x)$ anterior:

$$L(C) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 2 =$$

Longitud media de un código

La *longitud media* de un código binario es

$$L(C) = \mathbb{E}[\ell(X)] = \sum_{x \in \mathcal{X}} P(X = x)\ell(C(x)).$$

Para el código $C(x)$ anterior:

$$L(C) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 2 = \boxed{\frac{3}{2} \text{ bits por símbolo.}}$$

Comparación: código de repetición, de longitud fija. Cada símbolo requiere dos bits, por lo que $\boxed{L_{\text{rep}} = 2}$.

La entropía de Shannon

La *entropía de Shannon* de una distribución de probabilidad q en un conjunto finito es

$$\mathcal{H}(q) = \mathbb{E}_{x\sim q}\left[\log_2\left(\frac{1}{q(x)}\right)\right] = \sum_{x\in \mathrm{supp}(q)} q(x)\log_2\left(\frac{1}{q(x)}\right)$$

Teorema. (Shannon)

Se cumple la desigualdad $\mathcal{H}(X) \leq L(C)$ y existe un código óptimo libre de prefijos con

$$\mathcal{H}(X) \leq L(C^*) < \mathcal{H}(X) + 1.$$

La entropía de Shannon

La *entropía de Shannon* de una distribución de probabilidad q en un conjunto finito es

$$\mathcal{H}(q) = \mathbb{E}_{x\sim q}\left[\log_2\left(\frac{1}{q(x)}\right)\right] = \sum_{x\in \mathrm{supp}(q)} q(x)\log_2\left(\frac{1}{q(x)}\right)$$

Teorema. (Shannon)

Se cumple la desigualdad $\mathcal{H}(X) \leq L(C)$ y existe un código óptimo libre de prefijos con

$$\mathcal{H}(X) \leq L(C^*) < \mathcal{H}(X) + 1.$$

Ejemplo. Para la variable del slide anterior,

$$-\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{4}\log_2\frac{1}{4} - \frac{1}{4}\log_2\frac{1}{4} = \frac{1}{2} + \frac{1}{2} + \frac{1}{2} = \boxed{\frac{3}{2}}$$

Entropía relativa: divergencia de Kullback-Leibler

La *entropía relativa* (o divergencia de Kullback-Leibler) de una distribución q respecto de una de referencia p mide la **información extra por elemento** que se necesita para codificar una muestra independiente de q usando un código óptimo para p.

Entropía relativa: divergencia de Kullback-Leibler

La *entropía relativa* (o divergencia de Kullback-Leibler) de una distribución q respecto de una de referencia p mide la **información extra por elemento** que se necesita para codificar una muestra independiente de q usando un código óptimo para p.

Definición.

Para distribuciones de probabilidad p y q en un conjunto finito F,

$$KL(q \,\|\, p) := \mathbb{E}_{x\sim q}\left[\log_2\left(\frac{q(x)}{p(x)}\right)\right] = \sum_{x\in \mathrm{supp}(q)} q(x)\,\log_2\left(\frac{q(x)}{p(x)}\right)$$

Propiedades fundamentales de la entropía relativa

Lema.

Para cualquier par de distribuciones de probabilidad p y q sobre un conjunto finito F:

- *Positividad.* $0 \leq KL(q \,\|\, p)$, *y la igualdad se cumple si y solo si* $q = p$.
- *Sensibilidad al soporte.* $KL(q \,\|\, p) < \infty$ *si y solo si* $\text{supp}(p) \supseteq \text{supp}(q)$.
- *Contracción. Para toda transformación estocástica* $T : F \to F'$ *hacia otro conjunto finito* F',

$$KL(T_* q \,\|\, T_* p) \leq KL(q \,\|\, p).$$

- *Convexidad conjunta.* $KL(q \,\|\, p)$ *es convexa en el par* (p, q).

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\ldots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\ldots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender *significa encontrar valores para los parámetros* θ *para que* p^{θ}_0 *sea muy semejante a la distribución deseada* q_0.

Aprender a aprender

Definiremos una familia paramétrica de funciones $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ *y la usaremos para definir un modelo*

$$p^{\theta}_{[0,\dots,n]} = p^{\theta}_{[0|1]} p^{\theta}_{[1|2]} \cdots p^{\theta}_{[n-2|n-1]} p^{\theta}_{[n-1|n]} p^{\theta}_{n}$$

Aprender *significa encontrar valores para los parámetros* θ *para que* p^{θ}_{0} *sea muy semejante a la distribución deseada* q_0.

Nuestro objetivo será resolver el **problema de optimización**,

$$\boxed{\min_{\theta} KL\left(q_{[0]}||p^{\theta}_{[0]}\right)}$$

Función objetivo

Nuestro objetivo será resolver el **problema de optimización**,

$$\min_{\theta} KL\left(q_{[0]} || p^{\theta}_{[0]}\right)$$

Teorema.

Si $q_{[0,\ldots,n]}$ *y* $p^{\theta}_{[0,\ldots,n]}$ *son las distribuciones conjuntas de dos cadenas de Markov en* F^{n+1} *se cumple que*

$$KL(q_{[0]} \,\|\, p^{\theta}_{[0]}) \leq KL\left(q_{[0,\ldots,n]} \,\|\, p^{\theta}_{[0,\ldots,n]}\right)$$

y adicionalmente el lado derecho es igual a

$$KL(q_{[n]} \,\|\, p^{\theta}_{[n]}) + \sum_{t=0}^{n-1} \mathbb{E}_{x_{t+1}\sim q_{[t+1]}} KL\left(q_{[t|t+1]} \,\|\, p^{\theta}_{[t|t+1]}\right).$$

PROBLEMA

Desafortunadamente no conocemos $q_{[t|t+1]}$, lo que imposibilita calcular los sumandos intermedios de nuestra función objetivo $KL\left(q_{[t|t+1]} \parallel p^{\theta}_{[t|t+1]}\right)$ directamente.

Como predecir el pasado?

Supongamos que conocemos x_2 **y** x_0.

Como predecir el pasado?

Supongamos que conocemos x_2 **y** x_0.

x_2 : *El intendente de [MASK] lideró una [MASK] anticorrupción.*

x_0 : *El intendente de Medellín lideró una iniciativa anticorrupción.*

Cómo es la distribución $p_{[1|2,0]}(\bullet|x_2, x_0)$ de x_1 dados x_2, x_0?

Como predecir el pasado?

Supongamos que conocemos x_2 **y** x_0.

x_2 : *El intendente de [MASK] lideró una [MASK] anticorrupción.*

x_0 : *El intendente de Medellín lideró una iniciativa anticorrupción.*

Cómo es la distribución $p_{[1|2,0]}(\bullet|x_2, x_0)$ de x_1 dados x_2, x_0?

1. x_1 : El intendente de [Medellín] lideró una [MASK] anticorrupción.

Como predecir el pasado?

Supongamos que conocemos x_2 **y** x_0.

x_2 : *El intendente de [MASK] lideró una [MASK] anticorrupción.*

x_0 : *El intendente de Medellín lideró una iniciativa anticorrupción.*

Cómo es la distribución $p_{[1|2,0]}(\bullet|x_2, x_0)$ de x_1 dados x_2, x_0?

1. x_1 : El intendente de [Medellín] lideró una [MASK] anticorrupción.
2. x_1 : El intendente de [MASK] lideró una [iniciativa] anticorrupción.

Como predecir el pasado?

Supongamos que conocemos x_2 **y** x_0.

x_2 : *El intendente de [MASK] lideró una [MASK] anticorrupción.*

x_0 : *El intendente de Medellín lideró una iniciativa anticorrupción.*

Cómo es la distribución $p_{[1|2,0]}(\bullet|x_2, x_0)$ de x_1 dados x_2, x_0?

1. x_1 : El intendente de [Medellín] lideró una [MASK] anticorrupción.
2. x_1 : El intendente de [MASK] lideró una [iniciativa] anticorrupción.

Condicionando al valor de x_0 *podemos saber la distribución* $p_{[1|2,0]}(\bullet|x_2, x_0)$ **completamente**, *sin importar la distribución inicial* X_0. *Es decir* **CONOCEMOS**

$$p_{[t|t+1,0]}(x_t|x_{t+1}, x_0)$$

Condicionamiento a la izquierda (Lema)

Lema.

Si X, Y son variables aleatorias sobre un conjunto finito F con distribución conjunta $q_{[x,y]}$ y p es cualquier distribución de probabilidad sobre F, entonces

$$KL(q_{[x]} \,\|\, p) = \mathbb{E}_{y \sim q_{[y]}} \left[KL\left(q_{[x|y]} \,\|\, p\right) \right] - I_q(X;Y).$$

Donde $I_q(X,Y)$ es la **información mutua** entre X e Y dada por

$$I_q(X;Y) := KL\left(q_{[x,y]} \,\middle\|\, q_{[x]} q_{[y]}\right).$$

Condicionamiento a la izquierda (Lema)

Lema.

Si X, Y son variables aleatorias sobre un conjunto finito F con distribución conjunta $q_{[x,y]}$ y p es cualquier distribución de probabilidad sobre F, entonces

$$KL(q_{[x]} \,\|\, p) = \mathbb{E}_{y \sim q_{[y]}} \left[KL \left(q_{[x|y]} \,\|\, p \right) \right] - I_q(X; Y).$$

Donde $I_q(X, Y)$ es la **información mutua** entre X e Y dada por

$$I_q(X; Y) := KL \left(q_{[x,y]} \,\|\, q_{[x]} q_{[y]} \right).$$

Usando esto:

$$\mathbb{E}_{x_{t+1} \sim q_{[t+1]}} \left[\mathrm{KL} \left(q_{[t,t+1]} \,\|\, p^{\theta}_{[t,t+1]} \right) \right] =$$

Condicionamiento a la izquierda (Lema)

Lema.

Si X, Y son variables aleatorias sobre un conjunto finito F con distribución conjunta $q_{[x,y]}$ y p es cualquier distribución de probabilidad sobre F, entonces

$$KL(q_{[x]} \,\|\, p) = \mathbb{E}_{y \sim q_{[y]}} \left[KL\left(q_{[x|y]} \,\|\, p\right) \right] - I_q(X;Y).$$

Donde $I_q(X,Y)$ es la **información mutua** entre X e Y dada por

$$I_q(X;Y) := KL\left(q_{[x,y]} \,\middle\|\, q_{[x]} q_{[y]}\right).$$

Usando esto:

$$\mathbb{E}_{x_{t+1} \sim q_{[t+1]}} \left[\mathrm{KL}\left(q_{[t,t+1]} \,\|\, p^{\theta}_{[t,t+1]}\right) \right] =$$

$$= \boxed{\mathbb{E}_{(x_0, x_{t+1}) \sim q_{[0,t+1]}} \left[KL(q_{[t|t+1,0]} || p^{\theta}_{[t|t+1]}) \right] - I_q(X_0; X_t || X_{t+1})}$$

La función objetivo de un modelo de difusión

Definimos

$$\Psi(\theta) := KL(q_{[n]} \,\|\, p^{\theta}_{[n]}) + \mathbb{E}_{(x_0,x_1)\sim q_{[0,1]}} \log_2(1/p^{\theta}_{[0|1]}) +$$

$$+ \sum_{t=1}^{n-1} \mathbb{E}_{(x_0,x_{t+1})\sim q_{[0,t+1]}} KL\left(q_{[t|t+1,0]} \,\|\, p^{\theta}_{[t|t+1]}\right),$$

y entrenamos el modelo paramétrico mediante $\boxed{\min_{\theta} \Psi(\theta)}$

La función objetivo de un modelo de difusión

Definimos

$$\Psi(\theta) := KL(q_{[n]} \,\|\, p^{\theta}_{[n]}) + \mathbb{E}_{(x_0,x_1)\sim q_{[0,1]}} \log_2(1/p^{\theta}_{[0|1]}) +$$

$$+ \sum_{t=1}^{n-1} \mathbb{E}_{(x_0,x_{t+1})\sim q_{[0,t+1]}} KL\left(q_{[t|t+1,0]} \,\|\, p^{\theta}_{[t|t+1]}\right),$$

y entrenamos el modelo paramétrico mediante $\boxed{\min_{\theta} \Psi(\theta)}$

Teorema.

La igualdad $KL\left(q_{[0,\ldots,n]} \,\|\, p^{\theta}_{[0,\ldots,n]}\right) = \Psi(\theta) - \mathcal{H}_q(X_0 \,\|\, X_n)$ *ocurre para todo* θ. *En particular la función convexa* Ψ *satisface*

$$\mathcal{H}_q(X_0 \,\|\, X_n) \leq \Psi(\theta)$$

con igualdad si y sólo si $q_{[0,\ldots,n]} = p^{\theta}_{[0,\ldots,n]}$

Parametrizando con redes

Nuestro objetivo es construir una parametrización $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ en el caso de **Masked language diffusion models**.

Parametrizando con redes

Nuestro objetivo es construir una parametrización $p^{\theta}_{[t|t+1]}(x_t|x_{t+1})$ en el caso de **Masked language diffusion models**.

$p^{\theta}_{[t|t+1]}(x_t|x_{t+1} = \text{El intendente de [MASK] lideró una [MASK] anticorrupción.})$

Más concretamente, para cada posición queremos una distribución de probabilidad sobre los tokens que nos diga cómo quitar $[MASK]$

Token	$p([x_t]_1\|x_{t+1})$	$p([x_t]_2\|x_{t+1})$
Artigas	0.3	0.001
Medellín	0.6	0.002
⋮	⋮	⋮
iniciativa	0.003	0.5
investigación	0.002	0.1

Parametrizando con redes

- Dado un embedding de los tokens en x_{t+1}

$$X_{t+1} = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_\ell \\ | & | & \cdots & | \end{pmatrix}$$

- Queremos construir una función de unos parámetros θ que calcule la matriz de probabilidades condicionales sobre los tokens:

$$P^\theta = \begin{pmatrix} | & | & \cdots & | \\ p^\theta(\bullet|X_{t+1})_1 & p^\theta(\bullet|X_{t+1})_2 & \cdots & p^\theta(\bullet|X_{t+1})_\ell \\ | & | & \cdots & | \end{pmatrix}$$

Parametrizando con redes

- Dado un embedding de los tokens en x_{t+1}

$$X_{t+1} = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_\ell \\ | & | & \cdots & | \end{pmatrix}$$

- Calculamos nuevos embeddings contextualizados con parámetros compartidos K, Q, V mediante un bloque de **auto-atención**

$$Y = \begin{pmatrix} | & | & \cdots & | \\ A_\theta(X_{t+1}, x_1) & A_\theta(X_{t+1}, x_2) & \cdots & A_\theta(X_{t+1}, x_\ell) \\ | & | & \cdots & | \end{pmatrix}$$

Auto-Atención

Dado $X \in \mathbb{R}^{k \times \ell}$ y una palabra $w \in \mathbb{R}^k$ definimos tres matrices de parámetros $\theta = (K, Q, V)$ y la **función de atención (self-attention)** dada por

$$\mathrm{A}_\theta(X, w) := \sum_{j=1}^{\ell} \mathbb{B}\left(\langle Qw, Kx_j \rangle\right)_j Vx_j$$

con $Q, K \in \mathbb{R}^{b \times k}$ *y* $V \in \mathbb{R}^{h \times k}$.

Donde $\mathbb{B}$ es la **función de Bolzmann** (ó softmax) $B : \mathbb{R}^N \to \Delta(\mathbb{R}^N)$ dada por la fórmula

$$\mathbb{B}(u_1, \ldots, u_N)_j := \frac{\exp(u_j)}{\sum_{i=1}^{N}(\exp(u_i))}$$

Auto-Atención

Dado $X \in \mathbb{R}^{k\times\ell}$ y una palabra $w \in \mathbb{R}^k$ definimos tres matrices de parámetros $\theta = (K, Q, V)$ y la **función de atención (self-attention)** dada por

$$\mathrm{A}_\theta(X, w) := \sum_{j=1}^{\ell} \mathbb{B}\left(\langle Qw, Kx_j\rangle\right)_j \, Vx_j$$

con $Q, K \in \mathbb{R}^{b\times k}$ *y* $V \in \mathbb{R}^{h\times k}$.

Donde $\mathbb{B}$ es la **función de Bolzmann** (ó softmax) $B : \mathbb{R}^N \to \Delta(\mathbb{R}^N)$ dada por la fórmula

$$\mathbb{B}(u_1, \ldots, u_N)_j := \frac{\exp(u_j)}{\sum_{i=1}^{N}(\exp(u_i))}$$

Se sigue que

$$A_\theta(X, w) : \mathbb{R}^{k\times\ell} \times \mathbb{R}^k \to \mathbb{R}^h$$

Parametrizando con redes

- Aplicamos renormalización y una fully-connected layer *independientemente* en cada columna.

Parametrizando con redes

- Aplicamos renormalización y una fully-connected layer *independientemente* en cada columna.
  Si G_η es la composición

$$\mathbb{R}^k \xrightarrow{\frac{w}{\|w\|}} \mathbb{R}^k \xrightarrow{D} \mathbb{R}^L \xrightarrow{\sigma} \mathbb{R}^L \xrightarrow{E} \mathbb{R}^k \xrightarrow{\frac{w}{\|w\|}} \mathbb{R}^k$$

  con parámetros $\eta := (D, E)$ entonces calculamos

$$Z = \begin{pmatrix} | & | & \cdots & | \\ G_\eta(y_1) & G_\eta(y_2) & \cdots & G_\eta(y_\ell) \\ | & | & \cdots & | \end{pmatrix}$$

Parametrizando con redes

- Aplicamos renormalización y una fully-connected layer *independientemente* en cada columna.
  Si G_η es la composición

$$\mathbb{R}^k \xrightarrow{\frac{w}{\|w\|}} \mathbb{R}^k \xrightarrow{D} \mathbb{R}^L \xrightarrow{\sigma} \mathbb{R}^L \xrightarrow{E} \mathbb{R}^k \xrightarrow{\frac{w}{\|w\|}} \mathbb{R}^k$$

  con parámetros $\eta := (D, E)$ entonces calculamos

$$Z = \begin{pmatrix} | & | & \cdots & | \\ G_\eta(y_1) & G_\eta(y_2) & \cdots & G_\eta(y_\ell) \\ | & | & \cdots & | \end{pmatrix}$$

- Se pueden repetir los dos pasos anteriores tantas veces como queramos produciendo un output Z...

Parametrizando con redes

- Finalmente usando aplicando una matriz de proyección U^T obtenemos distribuciones de probabilidad por tokens en cada columna

$$P = \begin{pmatrix} | & | & \cdots & | \\ \mathbb{B}(U^T z_1) & \mathbb{B}(U^T z_2) & \cdots & \mathbb{B}(U^T z_\ell) \\ | & | & \cdots & | \end{pmatrix}$$

Parametrizando con redes

- Finalmente usando aplicando una matriz de proyección U^T obtenemos distribuciones de probabilidad por tokens en cada columna

$$P = \begin{pmatrix} | & | & \cdots & | \\ \mathbb{B}(U^T z_1) & \mathbb{B}(U^T z_2) & \cdots & \mathbb{B}(U^T z_\ell) \\ | & | & \cdots & | \end{pmatrix}$$

Ejemplo



Ejemplo



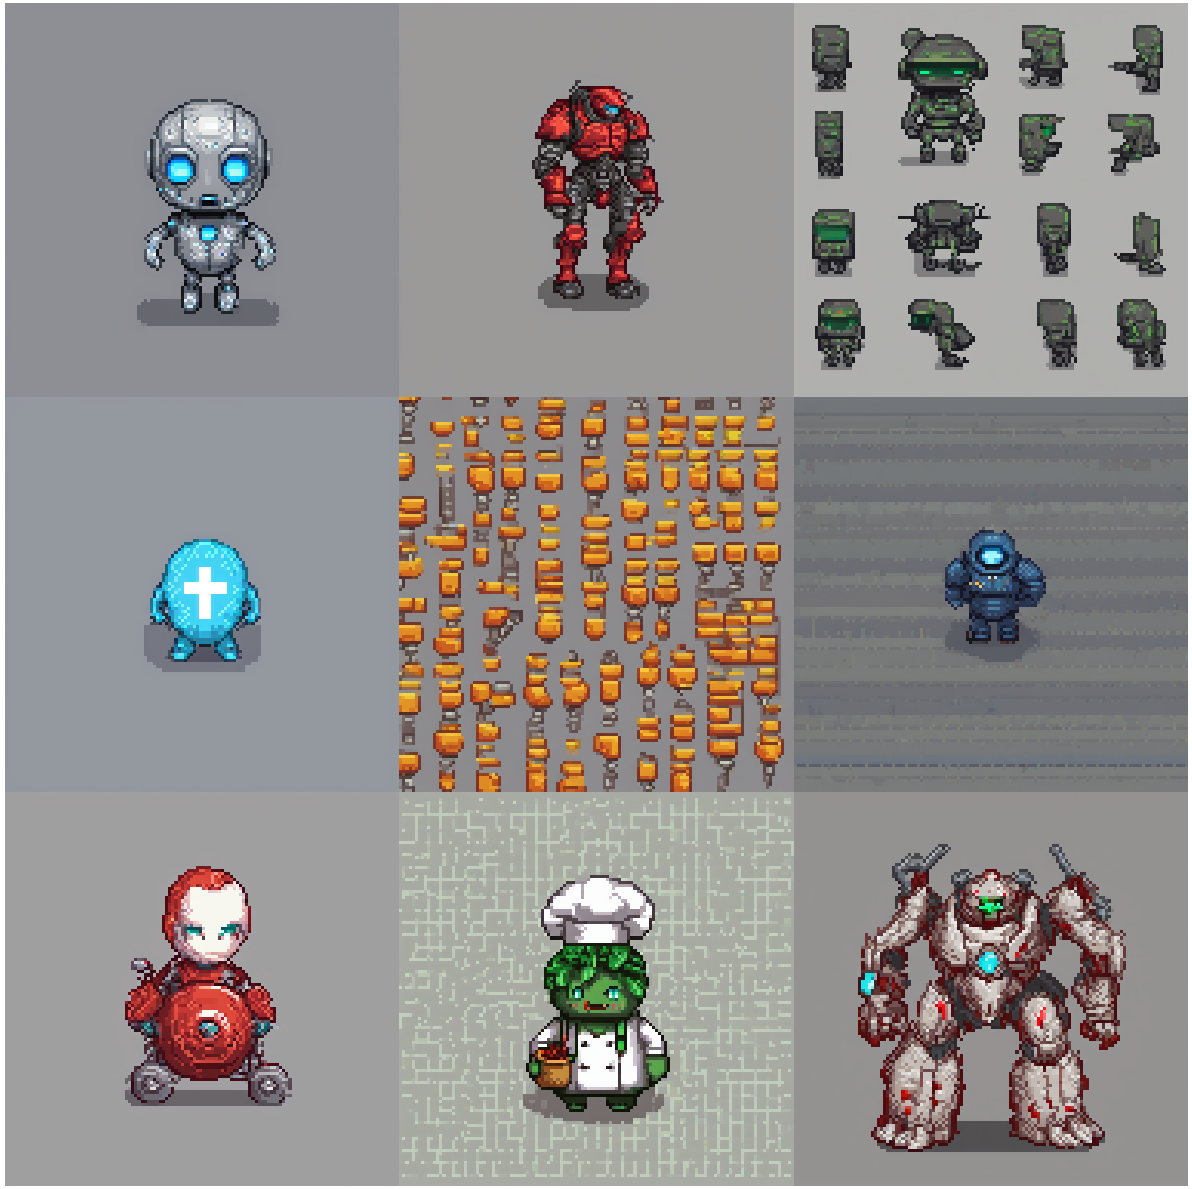
Ejemplo



Ejemplo



Ejemplo



Ejemplo

